

به نام خدا

Project Course Visualization Data

۱۴۰۵ Spring

تحلیل و مصور سازی داده های مسکن شهر Ames با استفاده از مجموعه داده
Ames Housing Dataset

Dr. Omid Karimi استاد درس:

Sara Dehghani دانشجو:

40411403001 شماره دانشجویی:

فهرست مطالب

۲	۱	مقدمه (Introduction)
۲	۲	Task ۱: معرفی و آشنایی با مجموعه داده (Data Understanding)
۲	۱.۲	معرفی متغیرهای مجموعه داده Housing Ames :
۳	۲.۲	بارگذاری کتابخانه ها و داده ها:
۴	۳.۲	نگاهی به داده ها:
۶	۴.۲	آمار توصیفی:
۷	۵.۲	توزیع قیمت فروش:
۸	۶.۲	بررسی مقادیر گمشده :
۱۰	۷.۲	توزیع نوع خانه و سبک معماری :
۱۱	۸.۲	بررسی نرمال بودن (Plot Q-Q)
۱۲	۹.۲	قیمت به تفکیک کیفیت (Boxplot)
۱۳	۱۰.۲	ویژگی های کلیدی (Plot Scatter)
۱۴	۳	Task ۲: پاکسازی و آماده سازی داده ها (Data Cleaning)
۱۴	۱.۳	ذخیره نسخه اصلی و بعد شروع پاکسازی :
۱۵	۲.۳	پر کردن مقادیر گمشده :
۱۶	۳.۳	حذف داده های پرت (Outlier)
۱۶	۴.۳	تبدیل نوع داده :
۱۷	۵.۳	مقایسه قبل و بعد پاکسازی :
۱۸	۴	Task ۳: تحلیل اکتشافی (Exploratory Analysis Data - EDA)
۱۸	۱.۴	آمار توصیفی کامل :
۲۰	۲.۴	توزیع ویژگی های عددی :
۲۲	۳.۴	تأثیر کیفیت بر قیمت :
۲۳	۴.۴	رابطه مساحت با قیمت :
۲۴	۵.۴	تحلیل زمانی :
۲۵	۶.۴	تأثیر ویژگی های دسته ای :
۲۶	۷.۴	ماتریس پراکندگی ویژگی های برتر :
۲۷	۵	Task ۴: مصورسازی داده ها (Data Visualization)
۲۷	۱.۵	رتبه بندی محله ها :
۲۸	۲.۵	Chart Bubble کیفیت :
۲۹	۳.۵	مقایسه violin قبل/بعد :
۳۰	۴.۵	Heatmap محله * کیفیت :
۳۲	۵.۵	تحلیل فصلی :
۳۳	۶.۵	همبستگی نهایی :
۳۴	۶	Task ۵: مدل سازی آماری (Statistical Modeling)
۳۴	۱.۶	رگرسیون خطی (Linear Regression)
۳۵	۲.۶	درخت تصمیم (Decision Tree)
۳۸	۳.۶	خوشه بندی (Clustering K-Means)
۳۹	۷	نتیجه گیری (Conclusion)

۱ مقدمه (Introduction)

تحلیل داده های مسکن یکی از کاربردی ترین حوزه های علم داده است که در آن، الگوهای پنهان در بازار خرید و فروش ملک از طریق روش های آماری و مصورسازی کشف می شوند. درک عوامل مؤثر بر قیمت مسکن نه تنها برای خریداران و فروشندگان ارزشمند است، بلکه برای سیاست گذاران، سرمایه گذاران و محققان اقتصادی نیز اهمیت بالایی دارد. در این پروژه، مجموعه داده Dataset Housing Ames مورد تحلیل قرار گرفته است. این مجموعه داده توسط Cock De Dean در سال ۲۰۱۱ منتشر شده و حاوی اطلاعات واقعی فروش ۱،۴۶۰ خانه در شهر Ames، ایالت Iowa آمریکا، بین سال های ۲۰۰۶ تا ۲۰۱۰ می باشد. این دیتاست با داشتن ۸۰ ویژگی متنوع، یکی از جامع ترین مجموعه داده های حوزه مسکن محسوب می شود و جایگزین مدرن تری برای مجموعه داده معروف Housing Boston به شمار می رود. هدف اصلی این پروژه پاسخ به سؤالات زیر از طریق تحلیل داده و مصورسازی است:

- کدام ویژگی های خانه بیشترین تأثیر را بر قیمت فروش دارند؟
 - آیا موقعیت مکانی (محل) نقش تعیین کننده ای در قیمت گذاری دارد؟
 - خانه های جدیدتر لزوماً گران تر هستند؟
 - آیا بازار مسکن رفتار فصلی دارد؟
 - آیا می توان خانه ها را بر اساس ویژگی هایشان به گروه های معنادار تقسیم کرد؟
- برای پاسخ به این سؤالات، یک جریان کامل تحلیل داده طراحی و اجرا شده است که شامل پاکسازی داده، تحلیل اکتشافی (EDA)، مصورسازی پیشرفته و مدل سازی آماری می باشد. تمامی مراحل با استفاده از زبان برنامه نویسی Python و کتابخانه های Pandas، Matplotlib، Seaborn، Plotly و Scikit-learn پیاده سازی شده اند.

۲ Task ۱: معرفی و آشنایی با مجموعه داده (Data Understanding)

۱.۲ معرفی متغیرهای مجموعه داده Housing Ames :

مجموعه داده Housing Ames شامل ۸۰ متغیر ورودی است که در شش گروه اصلی دسته بندی می شوند:

- مشخصات کلی ملک:
 - شامل نوع واحد مسکونی (MSSubClass)، زون بندی (MSZoning)، مساحت زمین (LotArea)، شکل زمین (LotShape)، شیب زمین (LandSlope) و نوع دسترسی به ملک (Alley Street) می باشد.
- مشخصات فیزیکی ساختمان:
 - شامل نوع ساختمان (BldgType)، سبک معماری (HouseStyle)، سال ساخت (YearBuilt)، سال بازسازی (YearRemodAdd)، نوع سقف (RoofMatl RoofStyle) و پوشش خارجی ساختمان (Exterior1st، Exterior2nd) است.
- کیفیت و وضعیت:
 - کیفیت کلی مصالح و اجرا در مقیاس ۱ تا ۱۰ (OverallQual)، وضعیت کلی ساختمان (OverallCond)، کیفیت نمای خارجی (ExterQual)، کیفیت آشپزخانه (KitchenQual) و کیفیت شومینه (FireplaceQu) در این گروه قرار دارند.

● مساحت ها:

شامل زیربنای طبقه اول و دوم (1stFlrSF، 2ndFlrSF)، زیربنای کل (GrLivArea)، مساحت زیرزمین (TotalBsmtSF) و مساحت گاراژ (GarageArea) است.

● امکانات:

شامل تعداد حمام (HalfBath، FullBath)، تعداد اتاق خواب (BedroomAbvGr)، تعداد شومینه (Fireplaces)، نوع گرمایش (Heating)، تهویه مرکزی (CentralAir)، استخر (PoolArea) و حصار (Fence) می باشد.

● اطلاعات فروش:

شامل ماه و سال فروش (YrSold، MoSold)، نوع سند (SaleType) و شرایط فروش (SaleCondition) است. فروش ها به شش دسته تقسیم می شوند: عادی (Normal)، غیرعادی (Abnormal)، خانوادگی (Family)، تخصیصی (Alloca)، مجاور (AdjLand) و ناتمام (Partial).

متغیر هدف: قیمت نهایی فروش ملک (SalePrice) بر حسب دلار آمریکا.
لینک دانلود data-description:

https://uploadkon.ir/uploads/e0dc15_26data-description.zip

۲.۲ بار گذاری کتابخانه ها و داده ها:

```
# بارگذاری کتابخانه ها و داده ها
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.ticker as mticker
import matplotlib.font_manager as fm
import seaborn as sns
from scipy import stats
import subprocess

subprocess.run(['pip', 'install', 'arabic-reshaper', 'python-bidi'], capture_output=True)

import arabic_reshaper
from bidi.algorithm import get_display

def fa(text):
    reshaped = arabic_reshaper.reshape(text)
    return get_display(reshaped)

import warnings
warnings.filterwarnings('ignore')
plt.rcParams['figure.dpi'] = 120
plt.rcParams['figure.facecolor'] = 'white'
sns.set_style('whitegrid')
BLUE = '#378ADD'
GREEN = '#1D9E75'
ORANGE = '#D85A30'
PURPLE = '#7F77DD'
AMBER = '#BA7517'
PALETTE = [BLUE, GREEN, ORANGE, PURPLE, AMBER]

# بارگذاری دیتاست
df = pd.read_csv('/kaggle/input/datasets/saradehqani/house-prices/train.csv')
print(f'شکل: {df.shape[0]}، سطر: {df.shape[1]} بارگذاری شد')
```

خروجی:

۴ دیتاست بارگذاری شد: ۱۴۶۰ خانه، ۸۱ ستون

تحلیل:

Purpose: بارگذاری کتابخانه های مورد نیاز برای تحلیل داده و مصورسازی، و خواندن مجموعه داده Ames Housing از منبع Kaggle

Findings Main: مجموعه داده با موفقیت بارگذاری شد و شامل ۱۴۶۰ نمونه (خانه) و ۸۱ ستون است که ۸۰ ستون ویژگی ورودی و ۱ ستون متغیر هدف (SalePrice) می باشد. کتابخانه های pandas و numpy برای پردازش داده، matplotlib و seaborn برای مصورسازی، و scipy برای تحلیل آماری بارگذاری شدند.

Interpretation Practical: حجم ۱۴۶۰ نمونه برای انجام تحلیل های آماری معنادار کافی است.

تعداد بالای ویژگی ها (۸۰ ویژگی) نشان می دهد که این دیتاست اطلاعات بسیار جامعی از ابعاد مختلف یک خانه ارائه می دهد (از مشخصات فیزیکی گرفته تا موقعیت مکانی و شرایط فروش، که امکان تحلیل های چند بعدی دقیق را فراهم می کند).

۳.۲ نگاهی به داده ها:

```
#نگاه اول به داده ها
# نمایش ۵ ردیف اول
df.head()
# ابعاد و نوع داده ها
print('=' * 50)
print(f'تعداد نمونه ها (خانه): {df.shape[0]}')
print(f'تعداد ویژگی ها: {df.shape[1] - 1} (+ 1 ستون هدف)')
print('=' * 50)
num_cols = df.select_dtypes(include='number').columns.drop(['Id', 'SalePrice']).tolist()
cat_cols = df.select_dtypes(include='object').columns.tolist()
print(f'ویژگی های عددی: {len(num_cols)}')
print(f'ویژگی های متنی: {len(cat_cols)}')
print(f'ستون هدف: SalePrice')
# اطلاعات کلی
df.info()
```

خروجی:

```
=====
تعداد نمونه ها (خانه): ۱۴۶۰
تعداد ویژگی ها: ۸۰ (+ ۱ ستون هدف)
=====
ویژگی های عددی: ۳۶
ویژگی های متنی: ۴۳
ستون هدف: SalePrice
<class 'pandas.core.frame.DataFrame'>
RangeIndex: ۱۴۵۹ to ۰ entries
Data columns (total ۸۱ columns):
```

#	column	Non-Null count	Dtype	
0	Id	1460 non-null	int64	
1	MSSubClass	1460 non-null	int64	
2	MSZoning	1460 non-null	object	
3	LotFrontage	1201 non-null	float64	
4	LotArea	1460 non-null	int64	
5	Street	1460 non-null	object	

```
object(۴۳) int64(۳۵), float64(۳), dtypes:
KB + ۰.۹۲۴ usage: memory
```

تحلیل:

Purpose: بررسی ساختار کلی دیتاست شامل ابعاد، نوع داده های هر ستون و شناسایی اولیه مقادیر گمشده پیش از شروع پاکسازی.

Findings Main: مجموعه داده شامل ۱۴۶۰ نمونه و ۸۱ ستون است.

از میان ویژگی های ورودی، ۳۶ ویژگی عددی (شامل ۳۵ ستون int64 و ۳ ستون float64) و ۴۳ ویژگی دسته ای (object) وجود دارد. بررسی اولیه نشان داد که برخی ستون ها دارای مقادیر گمشده هستند (LotFrontage با ۱۲۰۱ مقدار غیرخالی از ۱۴۶۰ (یعنی ۱۷٪ مقدار گمشده)، Alley، با ۹۱ مقدار غیرخالی (۸٪ گمشده)، PoolQC با ۷ مقدار غیرخالی (۵٪ گمشده) و MasVnrType با ۵۸۸ مقدار غیرخالی (۷٪ گمشده)). Interpretation Practical: وجود مقادیر گمشده زیاد در ستون هایی مثل PoolQC (۵٪) و Alley (۸٪) احتمالاً به این معناست که اکثر خانه ها اصلاً به استخر یا کوچه دسترسی ندارند یعنی این مقادیر گمشده در واقع نشان دهنده "ندارم" هستند (نه خطای داده).

این تفاوت مفهومی بسیار مهم است و در مرحله پاکسازی باید به درستی مدیریت شود.

همچنین وجود ۴۳ ستون دسته ای نشان می دهد که بخش قابل توجهی از ویژگی ها کیفی هستند.

۴.۲ آمار توصیفی:

```
# 3. آمار توصیفی ستون هدف (SalePrice)
sp = df['SalePrice']
print('آمار توصیفی SalePrice')
print('=' * 40)
print(f'کمترین قیمت: ${sp.min():>10,.0f}')
print(f'چارک اول (Q1): ${sp.quantile(0.25):>10,.0f}')
print(f'میانه: ${sp.median():>10,.0f}')
print(f'میانگین: ${sp.mean():>10,.0f}')
print(f'چارک سوم (Q3): ${sp.quantile(0.75):>10,.0f}')
print(f'بیشترین قیمت: ${sp.max():>10,.0f}')
print(f'انحراف معیار: ${sp.std():>10,.0f}')
print(f'چولگی (Skewness): {sp.skew():>10.2f} ← توزیع راست کج
```

خروجی:

آمار توصیفی SalePrice

```
=====
کمترین قیمت: $ ۳۴,۹۰۰
چارک اول (Q1): $ ۱۲۹,۹۷۵
میانه: $ ۱۶۳,۰۰۰
میانگین: $ ۱۸۰,۹۲۱
چارک سوم (Q3): $ ۲۱۴,۰۰۰
بیشترین قیمت: $ ۷۵۵,۰۰۰
انحراف معیار: $ ۷۹,۴۴۳
چولگی (Skewness): ۸۸.۱ : توزیع راست کج
```

تحلیل:

Purpose: استخراج و بررسی شاخص های آماری پایه متغیر هدف (SalePrice) برای درک توزیع قیمت ها و

شناسایی ویژگی های کلیدی آن پیش از مصورسازی.

Findings Main: قیمت فروش خانه ها در این دیتاست بین ۳۴,۹۰۰ دلار تا ۷۵۵,۰۰۰ دلار متغیر است و

بازه ای بسیار وسیع که نشان دهنده تنوع زیاد در بازار مسکن Ames است.

میانگین قیمت (۱۸۰,۹۲۱ دلار) به طور قابل توجهی از میانه (۱۶۳,۰۰۰ دلار) بالا تر است و این فاصله

۱۷,۹۲۱ دلاری نشان دهنده ی توزیع راست کج است.

فاصله بین چارک اول (۱۲۹,۹۷۵ دلار) و چارک سوم (۲۱۴,۰۰۰ دلار) که یعنی IQR برابر ۸۴,۰۲۵ دلار

است، نشان می دهد ۵۰ درصد میانی خانه ها در این بازه قیمتی قرار دارند.

انحراف معیار ۷۹,۴۴۳ دلاری، پراکندگی قابل توجه قیمت ها را تایید می کند و چولگی ۸۸.۱ هم به وضوح

نشان دهنده توزیع راست کج است.

Interpretation Practical: توزیع راست کج با چولگی ۸۸.۱ به این معناست که اکثر خانه ها در محدوده قیمتی متوسط (\$۱۰۰k تا \$۲۰۰k) قرار دارند اما تعداد محدودی از خانه های لوکس با قیمت های بسیار بالا وجود دارند که میانگین را به سمت بالا کشیده اند.

از دید آماری، این چولگی در مدل سازی رگرسیون خطی مشکل ساز است زیرا اکثر الگوریتم های آماری فرض نرمال بودن توزیع متغیر هدف را دارند، به همین دلیل، در مراحل بعدی از تبدیل لگاریتمی ($\log(\text{SalePrice}+1)$) برای نرمال سازی توزیع استفاده خواهد شد.

همچنین وجود IQR وسیع (\$۸۴k) نشان دهنده این است که عوامل مختلفی مثل محله، کیفیت و مساحت می توانند تفاوت های قیمتی بسیار زیادی ایجاد کنند.

۵.۲ توزیع قیمت فروش:

```
# 4. توزیع قیمت فروش (هیستوگرام)
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# --- هیستوگرام قیمت اصلی ---
ax = axes[0]
ax.hist(df['SalePrice'], bins=40, color=BLUE, edgecolor='white', linewidth=0.5)
ax.axvline(df['SalePrice'].mean(),
           color='#185FA5', linewidth=2, linestyle='--',
           label=f"میانگین: ${df['SalePrice'].mean():.0f}")

ax.axvline(df['SalePrice'].median(),
           color=GREEN, linewidth=2, linestyle='-',
           label=f"میان: ${df['SalePrice'].median():.0f}")
ax.set_title(f"توزیع قیمت فروش")
ax.set_xlabel(f"قیمت (دلار)")
ax.xaxis.set_major_formatter(mticker.FuncFormatter(lambda x, _: f"${x/1000:.0f}K"))
ax.legend(fontsize=10)


# --- توزیع لگاریتمی ---
ax2 = axes[1]
log_price = np.log1p(df['SalePrice'])
ax2.hist(log_price, bins=40, color=GREEN, edgecolor='white', linewidth=0.5)
ax2.axvline(log_price.mean(),
            color='#0F6E56', linewidth=2, linestyle='--',
            label=f"میانگین: (log_price.mean():.2f)")

ax2.axvline(log_price.median(),
            color=BLUE, linewidth=2, linestyle='-',
            label=f"میان: (log_price.median():.2f)")
ax2.set_title(f"توزیع لگاریتم قیمت - log(SalePrice+1)", fontsize=13, pad=12)
ax2.set_xlabel('log(SalePrice + 1)', fontsize=11)
ax2.set_ylabel(f"تعداد خانه", fontsize=11)
ax2.legend(fontsize=10)

plt.suptitle(f"چولگی توزیع قیمت و اصلاح آن با تبدیل لگاریتمی", fontsize=14, y=1.02)
plt.tight_layout()
plt.show()
print(f"چولگی اصلی: {df['SalePrice'].skew():.2f} → بعد از log: {log_price.skew():.2f}")
```

خروجی:

چولگی توزیع قیمت و اصلاح آن با تبدیل لگاریتمی



چولگی اصلی: ۸۸.۱ → بعد از $\log$: ۱۲.۰
تحلیل:

Purpose: مصورسازی توزیع متغیر هدف SalePrice به دو صورت اصلی و لگاریتمی با هدف نمایش دیداری چولگی و ارزیابی اثربخش بودن تبدیل لگاریتمی در نرمال سازی توزیع.

Findings Main: نمودار سمت چپ که توزیع اصلی می باشد، به وضوح ماهیت راست کج توزیع را نشان می دهد، ستون های بلند در سمت چپ (قیمت های پایین تر) و دم بلند در سمت راست (قیمت های بالا). اکثر خانه ها در بازه \$۱۰۰k تا \$۲۰۰k متمرکزند و تعداد معاملات با افزایش قیمت به شدت کاهش می یابد.

خط چین آبی (میانگین ۱۸۰،۹۲۱ دلاری) نسبت به خط سبز (میانگین ۱۶۳،۰۰۰ دلاری) به سمت راست جابجا شده که این جابجایی ۱۷،۹۲۱ دلاری دقیقاً به علت کشش خانه های لوکس است. نمودار سمت راست که توزیع لگاریتمی میباشد، تحول خوبی را نشان می دهد، توزیع به شکل قابل توجهی متقارن تر شده، چولگی از ۸۸.۱ به ۱۲.۰ کاهش یافته و میانگین (۰.۱۲) و میانگین (۰.۱۲) تقریباً برابر شده اند. Interpretation Practical: موفقیت تبدیل لگاریتمی در کاهش چولگی از ۸۸.۱ به ۱۲.۰ (کاهش ۶.۹۳ درصدی)، نشان می دهد که این تبدیل انتخاب مناسبی برای این دیتاست است. در مدل سازی رگرسیون خطی، استفاده از $\log(\text{SalePrice})$ به عنوان متغیر هدف به جای SalePrice اصلی منجر به بهبود قابل توجه دقت مدل می شود. از دید اقتصادی هم این الگوی توزیع نشان می دهد که بازار مسکن Ames عمدتاً یک بازار متوسط است با تعداد محدودی معامله در سطح لوکس.

۶.۲ بررسی مقادیر گمشده

```
# 5. بررسی مقادیر گمشده (Missing Values)
# مقادیر گمشده در این دیتاست اکثراً به معنای «ندارم» هستند، نه خطای داده.
missing = df.isnull().sum()
missing = missing[missing > 0].sort_values(ascending=False)
missing_pct = (missing / len(df) * 100).round(1)

missing_df = pd.DataFrame({'مقدار': missing, 'درصد': missing_pct})
print(f'تعداد ستون‌های دارای مقدار گمشده: {len(missing_df)}')
print()
print(missing_df.to_string())

fig, ax = plt.subplots(figsize=(10, 6))

colors = [ORANGE if p > 50 else AMBER if p > 20 else GREEN for p in missing_pct.values]
bars = ax.barh(missing_df.index, missing_df['درصد'], color=colors, edgecolor='white', linewidth=0.5)

for bar, pct in zip(bars, missing_df['درصد']):
    ax.text(bar.get_width() + 0.5, bar.get_y() + bar.get_height()/2,
            f'{pct}%', va='center', fontsize=9)

ax.axvline(50, color='gray', linestyle='--', linewidth=1, alpha=0.5, label='50%')
ax.set_xlabel(fa('درصد مقادیر گمشده'), fontsize=11)
ax.set_title(fa('مقادیر گمشده به تفکیک ستون'), fontsize=13, pad=12)
ax.set_xlim(0, 105)


from matplotlib.patches import Patch
legend_elements = [
    Patch(facecolor=ORANGE,
          label=f'({fa('احتمالاً «ندارم»')}) 50% بیش از 50%'),
    Patch(facecolor=AMBER,
          label=f'50 تا 20%'),
    Patch(facecolor=GREEN,
          label=f'20% (قابل جبران)')
]
ax.legend(handles=legend_elements, fontsize=9, loc='lower right')
plt.tight_layout()
plt.show()
```

خروجی:

تعداد ستون‌های دارای مقدار گمشده: ۱۹

	درصد	تعداد
PoolQC	۱۴۵۳	۵.۹۹
MiscFeature	۱۴۰۶	۳.۹۶
Alley	۱۳۶۹	۸.۹۳
Fence	۱۱۷۹	۸.۸۰
MasVnrType	۸۷۲	۷.۵۹
FireplaceQu	۶۹۰	۳.۴۷
LotFrontage	۲۵۹	۷.۱۷
GarageType	۸۱	۵.۵
GarageYrBlt	۸۱	۵.۵
GarageFinish	۸۱	۵.۵
GarageQual	۸۱	۵.۵

	تعداد	درصد
GarageCond	۸۱	۵.۵
BsmtExposure	۳۸	۶.۲
BsmtFinType۲	۳۸	۶.۲
BsmtQual	۳۷	۵.۲
BsmtCond	۳۷	۵.۲
BsmtFinType۱	۳۷	۵.۲
MasVnrArea	۸	۵.۰
Electrical	۱	۱.۰



تحلیل:

Purpose: شناسایی و کمی سازی مقادیر گم‌شده در تمام ستون های دیتاست به منظور طراحی برنامه ریزی مناسب برای پاکسازی داده.

Findings Main: ۱۹ ستون از ۸۰ ستون ورودی، دارای مقدار گم‌شده هستند که در سه دسته تقسیم می‌شوند:

- دسته اول ستون هایی با بیش از ۵۰٪ مقدار گم‌شده هستند که شامل PoolQC با ۵.۹۹٪، MiscFeature با ۳.۹۶٪، Alley با ۸.۹۳٪، Fence با ۸.۸۰٪ و MasVnrType با ۷.۵۹٪.

- دسته دوم ستون FireplaceQu با ۳.۴۷٪ مقدار گم‌شده است.

- دسته سوم ستون هایی با کمتر از ۲۰٪ مقدار گم‌شده هستند که شامل LotFrontage با ۷.۱۷٪ و ستون های مربوط به گاراژ با ۵.۵٪ و زیرزمین با ۵.۲٪.

Interpretation Practical: نکته مهم این است که اکثر مقادیر گم‌شده در این دیتاست به معنای واقعی

”گم‌شده” نیستند، نشان دهنده ”ندارم” هستند.

به عنوان مثال، PoolQC با ۵.۹۹٪ مقدار گم‌شده به این معناست که ۵.۹۹٪ خانه ها اصلا استخر ندارند، نه اینکه اطلاعات استخرشان ثبت نشده باشد. (این تفاوت مفهومی بسیار مهم است زیرا اگر این مقادیر را با میانگین یا میانه پر کنیم، اطلاعات نادرستی وارد مدل می‌کنیم. راه حل درست جایگزینی با مقدار ”None” یا ۰ است. تنها ستون LotFrontage نیاز به عملکرد متفاوتی دارد چون عرض معبر در یک محله معمولاً شبیه است، پر کردن با میانه همان محله بهترین انتخاب است.

۷.۲ توزیع نوع خانه و سبک معماری

```
# توزیع نوع خانه و سبک معماری
fig, axes = plt.subplots(1, 3, figsize=(15, 5))




# --- نوع خانه ---
bldg_counts = df['BldgType'].value_counts()
axes[0].pie(bldg_counts.values, labels=bldg_counts.index, autopct='%1.1f%%',
            colors=PALETTE, startangle=140, textprops={'fontsize': 9})
axes[0].set_title(fa('نوع خانه (BldgType)'), fontsize=12)

# --- سبک معماری ---
style_counts = df['HouseStyle'].value_counts()
axes[1].barh(style_counts.index[::-1], style_counts.values[::-1],
             color=BLUE, edgecolor='white', linewidth=0.5)
for i, v in enumerate(style_counts.values[::-1]):
    axes[1].text(v + 5, i, str(v), va='center', fontsize=9)
axes[1].set_title(fa('سبک معماری (HouseStyle)'), fontsize=12)
axes[1].set_xlabel(fa('تعداد'))

# --- زون بندی ---
zone_counts = df['MSZoning'].value_counts()
axes[2].bar(zone_counts.index, zone_counts.values,
            color=PALETTE, edgecolor='white', linewidth=0.5)
for i, v in enumerate(zone_counts.values):
    axes[2].text(i, v + 10, str(v), ha='center', fontsize=9)
axes[2].set_title(fa('زون بندی (MSZoning)'), fontsize=12)
axes[2].set_ylabel(fa('تعداد'))

plt.suptitle(fa('ترکیب کلی خانه های دیتاست'), fontsize=14, y=1.02)
plt.tight_layout()
plt.show()
print(f'رایج ترین نوع خانه: {bldg_counts.index[0]} با {bldg_counts.iloc[0]} خانه ((bldg_counts.iloc[0]/len(df)*100:.0f)%)')
print(f'رایج ترین سبک معماری: {style_counts.index[0]} با {style_counts.iloc[0]} خانه')
```

خروجی:



رایج ترین نوع خانه: Fam ۱ با ۱۲۲۰ خانه (۸۴٪)
رایج ترین سبک معماری: Story ۱ با ۷۲۶ خانه
تحلیل:

Purpose: بررسی توزیع فراوانی انواع خانه (BldgType)، سبک های معماری (HouseStyle) و زون بندی (MSZoning) برای درک ترکیب کلی بازار مسکن شهر Ames.

Findings Main: از نظر نوع خانه، ۶.۸۳٪ از کل نمونه ها (۱۲۲۰ خانه) از نوع تک خانواده مستقل (Fam ۱) هستند و مابقی شامل Unit End Townhouse با ۸.۷٪، Duplex با ۶.۳٪ و Two-Family Conversion با ۱.۲٪ سهم بسیار کمتری دارند.

از نظر سبک معماری، خانه های یک طبقه (Story ۱) با ۷۲۶ نمونه (۷.۴۹٪) بیشترین سبک هستند و خانه های دو طبقه (Story ۲) با ۴۴۵ نمونه (۵.۳۰٪) در رتبه دوم قرار دارند.

از نظر زون بندی نیز اکثریت خانه ها (۱۱۵۱ نمونه، ۸.۷۸٪) در منطقه مسکونی کم تراکم (RL) قرار دارند.

Interpretation Practical: تمرکز بسیار بالای خانه های تک خانواده (۶.۸۳٪) نشان دهنده ماهیت مسکونی و آرام شهر Ames است که یک شهر دانشگاهی کوچک است.

این عدم توازن در توزیع نوع خانه (imbalance class) در مدل سازی باید در نظر قرار گیرد زیرا مدل ها ممکن است برای پیش بینی انواع کمتر مثل Duplex عملکرد ضعیف تری داشته باشند.

همچنین بهتر بودن زون بندی RL نشان می دهد که این دیتاست عمدتاً نماینده بازار مسکن مناطق مسکونی کم تراکم است و نتایج آن را ممکن است نتوانیم برای مناطق تجاری یا صنعتی تعمیم بدهیم.

۸.۲ بررسی نرمال بودن (Plot Q-Q)

```
# 7. Q-Q Plot (بررسی نرمال بودن)
fig, axes = plt.subplots(1, 2, figsize=(12, 5))

# Q-Q plot اصلی قیمت
stats.probplot(df['SalePrice'], dist="norm", plot=axes[0])
axes[0].set_title(fa('Q-Q Plot - SalePrice اصلی'), fontsize=13)
axes[0].get_lines()[0].set(color=BLUE, markersize=3, alpha=0.5)
axes[0].get_lines()[1].set(color=ORANGE, linewidth=2)


# Q-Q plot لگاریتمی
stats.probplot(np.log1p(df['SalePrice']), dist="norm", plot=axes[1])
axes[1].set_title(fa('Q-Q Plot - log(SalePrice)'), fontsize=13)
axes[1].get_lines()[0].set(color=GREEN, markersize=3, alpha=0.5)
axes[1].get_lines()[1].set(color=ORANGE, linewidth=2)

plt.suptitle(fa('بررسی نرمال بودن توزیع قیمت'), fontsize=14, y=1.02)
plt.tight_layout()
plt.show()

# تست آماری
stat, p = stats.shapiro(df['SalePrice'].sample(200, random_state=42))
print(f'Shapiro-Wilk Test: p-value = {p:.6f}')
print(f'توزیع نرمال نیست' if p < 0.05 else f'توزیع نرمال است')
print()
stat2, p2 = stats.shapiro(np.log1p(df['SalePrice'].sample(200, random_state=42)))
print(f'Shapiro-Wilk (log): p-value = {p2:.6f}')
print(f'هنوز نرمال نیست' if p2 > 0.05 else f'تبدیل به نرمال شد log بعد از')
```

خروجی:

بررسی نرمال بودن توزیع قیمت



Shapiro-Wilk Test: p-value = ۰.۰۰۰۰۰۰۰۰ = ۴ توزیع نرمال نیست
Shapiro-Wilk (log): p-value = ۰.۰۰۳۳۱۹۰۰ = ۴ هنوز نرمال نیست

تحلیل:

Purpose: ارزیابی آماری انطباق توزیع SalePrice با توزیع نرمال از طریق نمودار Quantile-Quantile و تست Shapiro-Wilk، و مقایسه آن با نسخه لگاریتمی.

Findings Main: در نمودار Plot Q-Q، اگر داده ها از توزیع نرمال پیروی کنند، تمام نقاط باید روی خط قرمز قرار گیرند.

نمودار سمت چپ (SalePrice اصلی) نشان می دهد که نقاط در ناحیه چپ یعنی چارک های پایین، زیر خط و در ناحیه راست یعنی چارک های بالا، به شدت بالای خط قرار گرفته اند و این الگوی انحراف رایج توزیع راست کج است.

تست آماری Shapiro-Wilk با p-value برابر ۰.۰۰۰۰۰۰۰۰ فرض صفر نرمال بودن را با قاطعیت رد می کند. نمودار سمت راست (log(SalePrice)) بهبود خوبی را نشان می دهد به صورتی که نقاط به مراتب نزدیک تر به خط قرمز قرار گرفته اند (هرچند p-value برابر ۰.۰۰۳۳۱۹۰۰ نشان می دهد که حتی پس از تبدیل لگاریتمی، توزیع کاملاً نرمال نیست).

Interpretation Practical: نتیجه تست Shapiro-Wilk برای SalePrice اصلی (p=۰.۰۰۰۰۰۰۰۰) یعنی احتمال اینکه این داده ها از توزیع نرمال باشند کلاً صفر است.

p-value برابر با ۰.۰۰۳۳۱۹۰۰ برای نسخه لگاریتمی هنوز کمتر از آستانه ۰.۰۵ است اما این موضوع در عمل مشکل جدی ای ایجاد نمی کند زیرا با حجم نمونه بزرگ (n=۱۴۶۰)، تست Shapiro-Wilk بسیار حساس است و حتی انحرافات بسیار کوچک از نرمال را تشخیص می دهد.

نمودار Plot Q-Q نشان می دهد که نسخه لگاریتمی برای اهداف مدل سازی به اندازه کافی به توزیع نرمال نزدیک است و استفاده از آن در رگرسیون خطی دلیل آماری دارد.

۹.۲ قیمت به تفکیک کیفیت (Boxplot)


```
# 8. Boxplot قیمت به تفکیک کیفیت
fig, ax = plt.subplots(figsize=(10, 5))

qual_order = sorted(df['OverallQual'].unique())
sns.boxplot(data=df, x='OverallQual', y='SalePrice', order=qual_order,
            palette='Blues', ax=ax)

ax.set_title('قیمت به تفکیک کیفیت کلی (OverallQual)', fontsize=13)
ax.set_xlabel('کیفیت کلی (احصاف تا 10 عالی)', fontsize=11)
ax.set_ylabel('قیمت فروش (دلار)', fontsize=11)
ax.yaxis.set_major_formatter(mticker.FuncFormatter(lambda x, _ : f'${x/1000:.0f}K'))
plt.tight_layout()
plt.show()

print('میان قیمت به تفکیک کیفیت:')
print(df.groupby('OverallQual')['SalePrice'].median().apply(lambda x: f'${x:.0f}').to_string())
```

خروجی:



میان قیمت به تفکیک کیفیت:

OverallQual	
۱	۵۰,۱۵۰ \$
۲	۶۰,۰۰۰ \$
۳	۸۶,۲۵۰ \$
۴	۱۰۸,۰۰۰ \$
۵	۱۳۳,۰۰۰ \$
۶	۱۶۰,۰۰۰ \$
۷	۲۰۰,۱۴۱ \$
۸	۲۶۹,۷۵۰ \$
۹	۳۴۵,۰۰۰ \$
۱۰	۴۳۲,۳۹۰ \$

تحلیل:

Purpose: بررسی رابطه بین کیفیت کلی خانه (OverallQual) و قیمت فروش از طریق نمودار Boxplot که علاوه بر میانه، پراکندگی و outlier هر گروه را نیز نمایش می دهد.

Findings Main: نمودار Boxplot رابطه یکنواخت و صعودی واضحی بین کیفیت و قیمت نشان می دهد. میان قیمت از ۵۰,۱۵۰ دلار در کیفیت ۱ به ۴۳۲,۳۹۰ دلار در کیفیت ۱۰ رسیده (افزایشی برابر ۶.۸). نکته مهم تر این است که پراکندگی قیمت (ارتفاع جعبه یا IQR) با افزایش کیفیت، بیشتر می شود (IQR برای

کیفیت ۷ تا ۱۰ بسیار وسیع تر از کیفیت ۱ تا ۴ است. همچنین outlier ها در سطوح کیفیت ۵ تا ۱۰ مشاهده می شوند)

ضریب همبستگی پیرسون بین OverallQual و SalePrice برابر ۷۹.۰ است که قوی ترین همبستگی در کل دیتاست است.

Interpretation Practical: رابطه ۷۹.۰ بین کیفیت و قیمت نشان می دهد که OverallQual قوی ترین قدرت پیش بینی قیمت در این دیتاست را دارد.

افزایش هر سطح کیفیت به طور میانگین ۱۴,۸۰۰ دلار به قیمت اضافه می کند (بر طبق ضریب رگرسیون خطی که در بخش مدل سازی به دست آمد).

افزایش پراکندگی قیمت در سطوح کیفیت بالا نشان می دهد که در خانه های لوکس، عوامل دیگری مانند محله و مساحت نقش تعیین کننده تری دارند یعنی کیفیت بالا شرط لازم است اما کافی نیست.

وجود outlier در سطح کیفیت ۵ و ۶ احتمالاً مربوط به خانه هایی در محله های بسیار گران قیمت است که با وجود کیفیت متوسط، قیمت بالایی دارند.

۱۰.۲ ویژگی های کلیدی (Plot Scatter)

```
# 9. Scatter Plot ویژگی های کلیدی
fig, axes = plt.subplots(2, 2, figsize=(13, 10))

pairs = [
    ('GrLivArea', fa('دیرینا (فوت مربع)'),),
    ('TotalBsmtSF', fa('مساحت زیرزمین (فوت مربع)'),),
    ('GarageArea', fa('مساحت گاراژ (فوت مربع)'),),
    ('YearBuilt', fa('سال ساخت (سال)'),),
]

for ax, (col, label) in zip(axes.flatten(), pairs):
    ax.scatter(df[col], df['SalePrice'] / 1000,
              alpha=0.4, s=15, color=BLUE, edgecolors='none')


    # خط رگرسیون
    mask_valid = df[col].notna()
    z = np.polyfit(df.loc[mask_valid, col], df.loc[mask_valid, 'SalePrice'] / 1000, 1)
    p_line = np.poly1d(z)
    x_line = np.linspace(df[col].min(), df[col].max(), 100)
    ax.plot(x_line, p_line(x_line), color=ORANGE, linewidth=2, label=fa('خط رگرسیون'))

    r = df[[col, 'SalePrice']].corr().iloc[0, 1]
    ax.set_title(f'{col} (r = {r:.2f})', fontsize=12)
    ax.set_xlabel(label, fontsize=10)
    ax.set_ylabel(fa('قیمت (هزار دلار)'), fontsize=10)
    ax.legend(fontsize=9)

plt.suptitle(fa('رابطه ویژگی های کلیدی با قیمت فروش'), fontsize=14, y=1.01)
plt.tight_layout()
plt.show()
```

خروجی:

رابطه ویژگی های کلیدی با قیمت فروش



تحلیل:

Purpose: بررسی تصویری رابطه خطی بین چهار ویژگی مهم عددی (GarageArea, TotalBsmtSF, GrLivArea, YearBuilt) و قیمت فروش، همراه با خط رگرسیون برای کمی سازی این رابطه.

Findings Main:

GrLivArea با ضریب همبستگی $r=0.71$ قوی ترین رابطه مساحتی با قیمت را دارد؛ خط رگرسیون نشان می دهد به ازای هر ۱۰۰ فوت مربع افزایش زیربنا، قیمت به طور میانگین ۹,۰۰۰ دلار افزایش می یابد.

TotalBsmtSF با $r=0.61$ رابطه مثبت قابل توجهی دارد اما تجمع نقاط در مساحت صفر (خانه های بدون زیرزمین) توزیع را غیرخطی می کند.

GarageArea با $r=0.62$ رابطه مثبتی نشان می دهد و تجمع نقاط در صفر مربوط به خانه های بدون گاراژ است.

YearBuilt با $r=0.52$ ضعیف ترین رابطه را دارد و پراکندگی زیاد نقاط در خانه های قدیمی تر نشان دهنده تأثیر عوامل دیگر مثل بازسازی است.

Interpretation Practical: وجود چند نقطه پرت در نمودار GrLivArea (خانه هایی با زیربنای بالای ۴۰۰۰ فوت مربع اما قیمت پایین) نشان می دهد که زیربنای بسیار بزرگ به تنهایی قیمت بالا را تضمین نمی کند و عوامل دیگری مثل محله و کیفیت ساخت، نقش تعیین کننده دارند، این نقاط پرت در مرحله پاکسازی با روش IQR حذف شدند.

رابطه ضعیف تر YearBuilt ($r=0.52$) نسبت به مساحت ها نشان می دهد که سن خانه به تنهایی نمیتواند قدرت پیش بینی قوی ای داشته باشد و یک خانه قدیمی بازسازی شده می تواند ارزش بالاتری نسبت به خانه جدید ارزان ساز داشته باشد.

۳ Task ۲: پاکسازی و آماده سازی داده ها (Data Cleaning)

۱.۳ ذخیره نسخه اصلی و بعد شروع پاکسازی

```
# ذخیره نسخه اصلی + شروع پاکسازی 1.
df_raw = df.copy()
df_clean = df.copy()
print(f'نسخه اصلی ذخیره شد {df_raw.shape}')
```

خروجی:

نسخه اصلی ذخیره شد: (۸۱، ۱۴۶۰)

تحلیل:

Purpose: پیش از اعمال هرگونه تغییر بر روی داده ها، یک نسخه کامل از دیتاست اصلی تحت نام df_raw ذخیره می شود تا در مراحل بعدی امکان مقایسه قبل و بعد از پاکسازی فراهم باشد و در صورت نیاز بتوان به داده های اولیه بازگشت.

Findings Main: نسخه اصلی دیتاست با ابعاد (۸۱، ۱۴۶۰) با موفقیت ذخیره شد. این نسخه شامل تمام ۱۴۶۰ نمونه و ۸۱ ستون بدون هیچ گونه تغییری است.

Interpretation Practical: ذخیره نسخه اصلی یکی از اصول بنیادین در علم داده است.

این کار به علت اینکه باعث میشود بتوان تاثیر پاکسازی را به صورت کمی مقایسه کرد و همچنین به علت اینکه اگر پاکسازی بیش از حد باشد و داده های مفیدی حذف شوند میتواند کمک کند به داده های اصلی بازگردیم و کمک میکند بتوانیم در مرحله دیداری سازی تاثیر پاکسازی را به صورت دیداری و مقایسه ای نشان بدهیم در این پروژه انجام شد.

۲.۳ پر کردن مقادیر گمشده

```
# 2. missing values پر کردن
# بر مبنای None یعنی «ندارم» - NA ستون‌هایی که
none_cols = ['PoolQC', 'MiscFeature', 'Alley', 'Fence',
              'FireplaceQu', 'GarageType', 'GarageFinish',
              'GarageQual', 'GarageCond', 'BsmtQual', 'BsmtCond',
              'BsmtExposure', 'BsmtFinType1', 'BsmtFinType2', 'MasVnrType']

for col in none_cols:
    df_clean[col] = df_clean[col].fillna('None')

# ستون‌های عددی گاراژ - با 0 پر می‌شوند
zero_cols = ['GarageYrBlt', 'GarageArea', 'GarageCars',
              'BsmtFinSF1', 'BsmtFinSF2', 'BsmtUnfSF',
              'TotalBsmtSF', 'BsmtFullBath', 'BsmtHalfBath', 'MasVnrArea']

for col in zero_cols:
    df_clean[col] = df_clean[col].fillna(0)

# LotFrontage - میانۀ همون محله پر می‌شود
df_clean['LotFrontage'] = df_clean.groupby('Neighborhood')['LotFrontage']\
    .transform(lambda x: x.fillna(x.median()))

# Electrical - با مد پر می‌شود NA فقط (با 0)
df_clean['Electrical'] = df_clean['Electrical'].fillna(df_clean['Electrical'].mode()[0])

# چک کردن نتیجه
remaining = df_clean.isnull().sum().sum()
print(f'مقادیر گمشده قبل از پاکسازی: {df_raw.isnull().sum().sum()}')
print(f'مقادیر گمشده بعد از پاکسازی: {remaining}')
```

خروجی:

مقادیر گمشده قبل از پاکسازی: ۷۸۲۹

مقادیر گمشده بعد از پاکسازی: ۰

تحلیل:

Purpose: رفع مقادیر گمشده ۱۹ ستون دیتاست با استفاده از سه راهکار متفاوت بر اساس ماهیت هر ستون، به طریقی که اطلاعات واقعی داده حفظ شود و هیچ اطلاعات نادرستی وارد مدل نشود.

Findings Main: در مجموع ۷۸۲۹ مقدار گمشده در دیتاست وجود داشت که با سه روش متفاوت پر شدند.

روش اول: ستون‌هایی که NA در آن‌ها به معنای "ندارم" است (PoolQC، MiscFeature، Alley، Fence، FireplaceQu و ستون‌های گاراژ و زیرزمین) با مقدار "None" یا ۰ جایگزین شدند.

روش دوم: ستون LotFrontage که نشان دهنده عرض معبر است با میانۀ همان محله پر شد زیرا عرض معبر در یک محله معمولاً شبیه است و این روش قابل قبول‌ترین تخمین است.

روش سوم: ستون Electrical که تنها ۱ مقدار گمشده داشت، با مد که رایج‌ترین مقدار است، جایگزین شد.

پس از اعمال این تغییرات، تعداد مقادیر گمشده از ۷۸۲۹ به ۰ رسید.

Interpretation Practical: استفاده از سه راهکار متفاوت به جای یک روش یکسان برای همه ستون‌ها نشان دهنده درک عمیق‌تر از ماهیت داده است.

جایگزینی NA با "None" برای ستون‌هایی مثل PoolQC از یک خطای رایج جلوگیری می‌کند، اگر این مقادیر را با میانگین پر می‌کردیم، به مدل می‌گفتیم خانه‌هایی که اصلاً استخر ندارند، استخری با کیفیت متوسط دارند، که این نادرست است.

پر کردن LotFrontage با میانۀ محله نیز از دانش دامین (knowledge domain) استفاده می‌کند، خانه‌های یک محله معمولاً در خیابان‌هایی با عرض مشابه قرار دارند.

۳.۳ حذف داده های پرت (Outlier)

```
# 3. حذف Outlier
# شناسایی outlier با IQR روی GrLivArea و SalePrice
def remove_outliers_iqr(data, col, factor=1.5):
    Q1 = data[col].quantile(0.25)
    Q3 = data[col].quantile(0.75)
    IQR = Q3 - Q1
    lower = Q1 - factor * IQR
    upper = Q3 + factor * IQR
    return data[(data[col] >= lower) & (data[col] <= upper)]

before = len(df_clean)
df_clean = remove_outliers_iqr(df_clean, 'GrLivArea')
df_clean = remove_outliers_iqr(df_clean, 'SalePrice')
after = len(df_clean)

print(f'outlier: {before} تعداد قبل از حذف')
print(f'outlier: {after} تعداد بعد از حذف')
print(f'تعداد ردیف حذف شده: {before - after}')
```

خروجی:

تعداد قبل از حذف outlier: ۱۴۶۰

تعداد بعد از حذف outlier: ۱۳۷۳

تعداد ردیف حذف شده: ۸۷

تحلیل:

Purpose: شناسایی و حذف داده های پرت (outlier) از دیتاست با استفاده از روش IQR (Interquartile Range) روی دو ستون GrLivArea و SalePrice، به منظور بهبود کیفیت داده و افزایش دقت مدل سازی.

Findings Main: روش IQR برای هر ستون بازه مجاز $[Q1 - IQR \times 1.5, Q3 + IQR \times 1.5]$ را محاسبه کرده و هر مقداری خارج از این بازه را به عنوان outlier شناسایی کرد.

برای SalePrice، کران بالایی برابر ۳۴۰,۰۳۷ دلار محاسبه شد.

برای GrLivArea نیز مقادیر بالای ۲۷۷۶ فوت مربع به عنوان outlier شناسایی شدند.

در نتیجه ی این عملیات، ۸۷ ردیف (۹.۵٪ از کل داده ها) حذف شدند و تعداد نمونه ها از ۱۴۶۰ به ۱۳۷۳ کاهش یافت.

Interpretation Practical: حذف ۹.۵٪ از داده ها توانست تناسب خوبی بین حفظ حجم داده و بهبود کیفیت آن ایجاد کند.

انتخاب روش IQR به جای روش های مبتنی بر میانگین و انحراف معیار (مثل z-score) بهتر است زیرا داده های پرت، خود میانگین را جابجا می کنند و این روش ها را ناپایدار می کنند، در حالی که IQR به عنوان یک معیار مقاوم (robust) تحت تأثیر outlier قرار نمی گیرد.

همچنین اعمال روش IQR روی GrLivArea باعث حذف چند خانه با زیر بنای بسیار بالا (بالای ۴۰۰۰ فوت مربع) اما با قیمت پایین شد، که احتمال دارد ناشی از خطای ثبت داده یا شرایط خاص فروش بوده باشند.

۴.۳ تبدیل نوع داده

```
# 4. تبدیل نوع داده
# MSSubClass عددی ولی باید categorical باشد
df_clean['MSSubClass'] = df_clean['MSSubClass'].astype(str)
df_raw['MSSubClass'] = df_raw['MSSubClass'].astype(str)

print('تبدیل شد string به MSSubClass ✓')
```

خروجی:

MSSubClass به string تبدیل شد.

تحلیل:

Purpose: اصلاح نوع داده ستون MSSubClass از عددی (int64) به دسته ای (string)، چون این ستون کد های نوع خانه را نشان می دهد و ماهیت دسته ای دارد نه عددی.

Findings Main: ستون MSSubClass که کد نوع خانه را نشان می دهد (مثلا کد ۶۰ یعنی خانه دوطبقه ساخته شده بعد از ۱۹۴۶)، به اشتباه به صورت عددی (int64) ذخیره شده بود. این ستون هم در df_clean و هم در df_raw به نوع string تبدیل شد.

Interpretation Practical: این تبدیل از یک خطای رایج در مدل سازی جلوگیری می کند.


اگر MSSubClass به صورت عددی در مدل استفاده شود، الگوریتم فرض می کند که کد ۱۶۰ دو برابر کد ۸۰ است، در حالی که این اعداد فقط کد هستند و هیچ رابطه کمی با یکدیگر ندارند.

با تبدیل به string، در مرحله مدل سازی این ستون به درستی به صورت دسته ای (categorical) با استفاده از Encoding Label یا Encoding One-Hot پردازش خواهد شد.

۵.۳ مقایسه قبل و بعد پاکسازی



خروجی:



خلاصه پاکسازی:

- مقادیر گمشده: ۷۸۲۹ ^۴ ۰
- تعداد ردیفها: ۱۴۶۰ ^۴ ۱۳۷۳
- MSSubClass به categorical تبدیل شد

تحلیل:

Purpose: به تصویر کشیدن تاثیر مراحل پاکسازی از طریق مقایسه بصری توزیع قیمت و رابطه زیربنا، قیمت قبل و بعد از پاکسازی، به منظور ارزیابی کمی و کیفی تاثیر تصمیمات پاکسازی.

Main Findings: نمودار هیستوگرام، تفاوت را به خوبی نشان می دهد.

قبل از پاکسازی (نمودار نارنجی، $n=1460$)، توزیع دم بلندی تا \$ 700k دارد و چند خانه با قیمت بالای \$ 600k مشاهده می شود.

بعد از پاکسازی (نمودار سبز، $n=1373$)، بازه قیمتی در محدوده ی \$ 50k تا \$ 320k کم شده و توزیع متعادل تری دارد.

نمودار Plot Scatter ، تاثیر حذف outlier را بر رابطه زیربنا/قیمت نشان می دهد؛ قبل از پاکسازی، چند نقطه پرت با زیربنای بالای 4000 فوت مربع و قیمت های بسیار بالا وجود دارند که رابطه خطی را مخدوش می کنند.

بعد از پاکسازی، رابطه خطی بسیار واضح تر و منظم تر شده است.

۴ Task ۳: تحلیل اکتشافی (EDA) – Analysis Data

۱.۴ آمار توصیفی کامل

```
# آمار توصیفی کامل 1.
print('== آمار توصیفی ویژگی های عددی ==')
df_clean[num_cols].describe().round(2)
```

خروجی:

== آمار توصیفی ویژگی های عددی ==

	LotFrontage	LotArea	OverallQual	OverallCond	YearBuilt
count	1373	1373	1373	1373	1373
mean	68.75	10021.9	5.95	5.59	1970.07
std	20.62	8197.74	1.26	1.11	29.82
min	21	1300	1	1	1872
0.25	60	7399	5	5	1953
0.5	70	9245	6	5	1971
0.75	80	11248	7	6	1999
max	313	164660	10	9	2009

تحلیل:

Purpose: محاسبه و بررسی شاخص های آماری پایه برای تمام ۳۵ ویژگی عددی دیتاست پاکسازی شده برای درک کلی از توزیع، پراکندگی و دامنه هر ویژگی پیش از تحلیل های عمیق تر.

Findings Main: پس از پاکسازی، دیتاست نهایی شامل ۱۳۷۳ نمونه و ۳۵ ویژگی عددی است. مهم ترین نتایج از جدول آمار توصیفی:

میانگین کیفیت کلی (OverallQual) ۹۵.۵ از ۱۰ است که نشان دهنده تمرکز خانه ها در سطح کیفیت متوسط رو به بالاست.

میانگین سال ساخت ۱۹۷۰ و میانگین سال بازسازی ۱۹۸۳ است که فاصله ۱۳ ساله بین آن ها نشان می دهد بسیاری از خانه ها پس از ساخت باز سازی شده اند.

میانگین مساحت زمین (LotArea) برابر ۱۰۰۲۲ فوت مربع با انحراف معیار ۸۱۹۸ است که پراکندگی بسیار زیادی را نشان می دهد.

میانگین مساحت گاراژ ۴۵۴ فوت مربع و میانگین مساحت زیرزمین تکمیل شده ۴۰۷ فوت مربع است. حداکثر LotArea برابر ۱۶۴۶۶۰ فوت مربع در مقابل میانه ۹۲۴۵ فوت مربع نشان دهنده وجود زمین های

بسیار بزرگ در دیتاست است.

Interpretation Practical: فاصله بزرگ بین میانگین و میانه در ستون LotArea (میانگین ۱۰۰۲۲ در مقابل میانه ۹۲۴۵) و انحراف معیار بالای ۸۱۹۸ نشان می دهد که این ویژگی هنوز دارای چولگی قابل توجهی است و outlier های بزرگ در آن باقی مانده اند، این موضوع توضیح می دهد که چرا همبستگی LotArea با SalePrice نسبتاً پایین ($r=0.26$) است (یک زمین بسیار بزرگ در یک محله ارزان قیمت لزوماً قیمت بالایی ندارد).

همچنین فاصله ۱۳ ساله بین میانگین سال ساخت (۱۹۷۰) و سال بازسازی (۱۹۸۳) نشان می دهد که بازسازی معمولاً حدود یک دهه پس از ساخت انجام می شود که با چرخه های معمول نوسازی مسکن همخوانی دارد.

۲.۴ توزیع ویژگی های عددی

```
# توزیع ویژگی های عددی مهم 2.
important_num = ['SalePrice', 'GrLivArea', 'TotalBsmntSF',
                 'LotArea', 'GarageArea', 'YearBuilt']


fig, axes = plt.subplots(2, 3, figsize=(15, 10))

for ax, col in zip(axes.flatten(), important_num):
    skew = df_clean[col].skew()
    ax.hist(df_clean[col], bins=35, color=BLUE, edgecolor='white', linewidth=0.5, alpha=0.85)
    ax.axvline(df_clean[col].mean(), color=ORANGE, linewidth=2, linestyle='--', label=f'میانگین')
    ax.axvline(df_clean[col].median(), color=GREEN, linewidth=2, linestyle='-', label=f'میانه')
    ax.set_title(f'{col}\nskewness = {skew:.2f}', fontsize=11)
    ax.legend(fontsize=8)
    ax.set_ylabel(f'تعداد', fontsize=9)

plt.suptitle(f'توزیع ویژگی های عددی مهم', fontsize=14, y=1.02)
plt.tight_layout()
plt.show()
```

خروجی:

توزیع ویژگی‌های عددی مهم



تحلیل:

Purpose: بررسی شکل توزیع شش ویژگی عددی مهم (SalePrice، GrLivArea، TotalBsmtSF، LotArea، YearBuilt، GarageArea) از طریق هیستوگرام همراه با خطوط میانگین و میانه، برای شناسایی چولگی و ارزیابی نیاز به تبدیل داده.

Findings Main: هر شش ویژگی، الگوی توزیع متفاوتی دارند.

SalePrice با $skewness = 0.64$ پس از حذف outlier توزیع بهتری نسبت به قبل ($skewness = 1.88$) دارد.

GrLivArea با $skewness = 0.45$ توزیع نسبتاً متقارنی دارد با تمرکز در بازه ۱۰۰۰ تا ۱۵۰۰ فوت مربع.

TotalBsmtSF با $skewness = 0.22$ نزدیک ترین توزیع به نرمال در بین ویژگی‌های مساحتی است.

LotArea با $skewness = 11.72$ شدید ترین چولگی را دارد (اکثر زمین‌ها کوچک هستند اما چند زمین بسیار بزرگ وجود دارد).

GarageArea با $skewness = 0.05$ تقریباً توزیع نرمال دارد با این تفاوت که تجمع نقاط در صفر مربوط به خانه‌های بدون گاراژ است.

YearBuilt با $skewness = -0.56$ توزیع چپ‌کج دارد یعنی خانه‌های جدیدتر (دهه ۱۹۷۰ به بعد) بیشتر هستند.

Interpretation Practical: تنوع در شکل توزیع ویژگی‌ها اهمیت بالایی در مدل‌سازی دارد.

LotArea با $skewness = 11.72$ به تبدیل لگاریتمی نیاز دارد (خیلی زیاد) چون بدون این تبدیل، این ویژگی در مدل رگرسیون خطی مدل را خراب میکند.

چپ‌کج بودن YearBuilt ($skewness = -0.56$) نشان می‌دهد که بازار مسکن Ames در دوره ۲۰۰۶ تا ۲۰۱۰ بیشتر شامل خانه‌های ساخته شده در دهه‌های اخیر بوده است که با رشد شهری پس از جنگ دوم جهانی همخوانی دارد.

همگرایی میانگین و میانه در GarageArea و TotalBsmtSF نشان می‌دهد که این ویژگی‌ها توزیع نسبتاً متقارنی دارند و می‌توان آن‌ها را بدون تبدیل وارد مدل کرد.

۳.۴ تأثیر کیفیت بر قیمت

```
# تأثیر کیفیت کلی روی قیمت 3.
fig, axes = plt.subplots(1, 2, figsize=(14, 5))


# میانگین قیمت به تفکیک کیفیت
qual_mean = df_clean.groupby('OverallQual')['SalePrice'].mean() / 1000
axes[0].bar(qual_mean.index, qual_mean.values, color=PALETTE * 2, edgecolor='white')
for i, (q, v) in enumerate(qual_mean.items()):
    axes[0].text(q, v + 2, f'${v:.0f}K', ha='center', fontsize=8)
axes[0].set_title('میانگین قیمت به تفکیک کیفیت کلی', fontsize=12)
axes[0].set_xlabel('کیفیت (1 تا 10)', fontsize=11)
axes[0].set_ylabel('میانگین قیمت (هزار دلار)', fontsize=11)

# boxplot
sns.boxplot(data=df_clean, x='OverallQual', y='SalePrice',
            palette='Blues', ax=axes[1])
axes[1].set_title('توزیع قیمت به تفکیک کیفیت', fontsize=12)
axes[1].set_xlabel('کیفیت کلی', fontsize=11)
axes[1].set_ylabel('قیمت فروش (دلار)', fontsize=11)
axes[1].yaxis.set_major_formatter(mticker.FuncFormatter(lambda x, _ : f'${x/1000:.0f}K'))

plt.tight_layout()
plt.show()

print('نتیجه: با افزایش هر سطح کیفیت، قیمت به طور میانگین:')
diffs = qual_mean.diff().dropna()
print(f'حدافل افزایش: ${diffs.min():.0f}K')
print(f'حداکثر افزایش: ${diffs.max():.0f}K')
```

خروجی:



نتیجه: با افزایش هر سطح کیفیت، قیمت به طور میانگین:

حدافل افزایشی که یافته: \$ ۲k

حداکثر افزایشی که یافته: \$ ۵۲k

تحلیل:

Purpose: تحلیل کمی رابطه بین OverallQual و SalePrice از طریق دو نمودار که کامل کننده ی همدیگر هستند (Chart Bar برای نمایش میانگین قیمت هر سطح و Boxplot برای نمایش توزیع کامل قیمت در هر سطح کیفیتی)

Findings Main: Chart Bar، میانگین قیمت به تفکیک کیفیت را نشان می دهد که رابطه پله ای و یکنواختی بین کیفیت و قیمت وجود دارد (از \$ ۵۰k در کیفیت ۱ تا \$ ۳۱۰k در کیفیت ۱۰) که حداقل افزایش بین دو سطح متوالی \$ ۲k (بین کیفیت ۱ و ۲) و حداکثر آن \$ ۵۲k (بین کیفیت ۷ و ۸) است.

Boxplot توزیع قیمت در هر سطح را نشان می دهد و یک الگوی مهم را نشان میدهد:

پراکندگی قیمت (ارتفاع جعبه) در سطوح کیفیت ۷ تا ۱۰ بیشتر از سطوح پایین تر است.

همچنین outlier در سطوح ۵ تا ۱۰ نیز مشاهده می شوند.

Interpretation Practical: افزایش ناگهانی \$ ۵۲k بین کیفیت ۷ و ۸ یک نقطه شکست (breakpoint) مهم در بازار مسکن Ames است (خانه هایی که از کیفیت "خوب" به "خیلی خوب" پیشرفت میکنند، جهش قیمتی قابل توجهی تجربه می کنند).

افزایش پراکندگی در سطوح بالاتر این نکته مهم را نشان می دهد که در بازار لوکس، کیفیت ساخت، شرط لازم است اما کافی نیست (یک خانه با کیفیت ۹ در محله MeadowV (ارزان ترین محله) می تواند نصف قیمت همان کیفیت در محله NridgHt (گران ترین محله) باشد)، این نتیجه اهمیت بالای اثر تعاملی (effect interaction) بین کیفیت و محله را نشان می دهد که در Heatmap بخش مصورسازی به آن پرداخته شده.

۴.۴ رابطه مساحت با قیمت

```
# 4. رابطه مساحت و قیمت
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# GrLivArea vs SalePrice
axes[0].scatter(df_clean['GrLivArea'], df_clean['SalePrice']/1000,
               alpha=0.4, s=15, color=BLUE, edgecolor=None)
z = np.polyfit(df_clean['GrLivArea'], df_clean['SalePrice']/1000, 1)
x_line = np.linspace(df_clean['GrLivArea'].min(), df_clean['GrLivArea'].max(), 100)
axes[0].plot(x_line, np.polyd(z)(x_line), color=ORANGE, linewidth=2, label=f'خط رگرسیون')
r = df_clean[['GrLivArea', 'SalePrice']].corr().iloc[0,1]
axes[0].set_title(f'GrLivArea vs SalePrice (r={r:.2f})', fontsize=12)
axes[0].set_xlabel(f'نسبت (فوت مربع)', fontsize=11)
axes[0].set_ylabel(f'قیمت (هزار دلار)', fontsize=11)
axes[0].legend(fontsize=9)


# TotalBsmtSF vs SalePrice
axes[1].scatter(df_clean['TotalBsmtSF'], df_clean['SalePrice']/1000,
               alpha=0.4, s=15, color=PURPLE, edgecolor=None)
z2 = np.polyfit(df_clean['TotalBsmtSF'], df_clean['SalePrice']/1000, 1)
x_line2 = np.linspace(df_clean['TotalBsmtSF'].min(), df_clean['TotalBsmtSF'].max(), 100)
axes[1].plot(x_line2, np.polyd(z2)(x_line2), color=ORANGE, linewidth=2, label=f'خط رگرسیون')
r2 = df_clean[['TotalBsmtSF', 'SalePrice']].corr().iloc[0,1]
axes[1].set_title(f'TotalBsmtSF vs SalePrice (r={r2:.2f})', fontsize=12)
axes[1].set_xlabel(f'نسبت (فوت مربع)', fontsize=11)
axes[1].set_ylabel(f'قیمت (هزار دلار)', fontsize=11)
axes[1].legend(fontsize=9)

plt.suptitle(f'رابطه مساحت با قیمت فروشی', fontsize=14, y=1.02)
plt.tight_layout()
plt.show()
print(f'میانگین قیمت ۱۰۰۰ فوت مربع از برای زیر بنا = $ {z[0]*1000:.0f}K')
print(f'رابطه مثبت را می بینیم در اینجا - (r2={r2:.2f}) - همبستگی زیربنا با قیمت')

```

خروجی:

رابطه مساحت با قیمت فروش



قیمت \$ ۹k بالا میره <= هر ۱۰۰ فوت مربع افزایش زیر بنا

همبستگی زیر زمین با قیمت: ۵۸.۰ یعنی رابطه مثبت ولی ضعیف تر از زیربنا تحلیل:

Purpose: بررسی و کمی سازی رابطه بین دو مساحت مهم (زیر بنای زندگی (GrLivArea) و مساحت

زیر زمین (TotalBsmtSF)) با قیمت فروش از طریق Plot Scatter همراه با خط رگرسیون.

Findings Main: GrLivArea با ضریب همبستگی $r=0.68$ قوی ترین رابطه مساحتی با قیمت را دارد. خط رگرسیون نشان می دهد به ازای هر ۱۰۰ فوت مربع افزایش زیربنا، قیمت به طور میانگین ۹,۰۰۰ دلار افزایش می یابد.

نقاط داده به طور نسبتاً منظمی در اطراف خط رگرسیون پراکنده اند که نشانه رابطه خطی قوی است. To- talBsmtSF با $r=0.58$ رابطه مثبت ضعیف تری دارد. تجمع قابل توجهی از نقاط در مساحت صفر وجود دارد (خانه های بدون زیر زمین) که رابطه را از حالت کاملاً خطی خارج می کند و پراکندگی نقاط در این نمودار بیشتر از GrLivArea است.

Interpretation Practical: تفاوت ضریب همبستگی بین GrLivArea ($r=0.68$) و TotalBsmtSF ($r=0.58$) از منظر اقتصادی معنا دار است (خریداران به زیر بنای بالای زمین (فضای زندگی قابل استفاده روزانه) بیشتر از زیر زمین ارزش می دهند).

این نتیجه همچنین با نتایج Clustering K-Means نیز تأیید شده است: خوشه ۳ با زیر بنای بالا اما زیر زمین کوچک (\$ ۱۸۳k) گران تر از خوشه ۰ با زیر بنای مشابه اما زیر زمین بزرگ تر (\$ ۱۵۸k) است. همچنین پراکندگی بیشتر نقاط در نمودار TotalBsmtSF نشان می دهد که این ویژگی به تنهایی قدرت پیش بینی کمی برای قیمت دارد و تأثیر آن به عوامل دیگری مثل نوع تکمیل زیرزمین (Unf vs GLQ) بستگی دارد.

۵.۴ تحلیل زمانی

```
# تحلیل زمانی
fig, axes = plt.subplots(1, 2, figsize=(14, 5))


# قیمت به تفکیک سال ساخت (میانگین هر دهه)
df_clean['Decade'] = (df_clean['YearBuilt'] // 10 * 10).astype(str) + 's'
decade_price = df_clean.groupby('Decade')['SalePrice'].median() / 1000
axes[0].bar(decade_price.index, decade_price.values, color='PURPLE', edgecolor='white')
axes[0].set_title(fa('میانگین قیمت به تفکیک دهه ساخت'), fontsize=12)
axes[0].set_xlabel(fa('دهه ساخت'), fontsize=11)
axes[0].set_ylabel(fa('میانگین قیمت (هزار دلار)'), fontsize=11)
axes[0].tick_params(axis='x', rotation=45)
for i, v in enumerate(decade_price.values):
    axes[0].text(i, v + 1, f'$({v:.0f})K', ha='center', fontsize=8)

# تعداد فروش به تفکیک ماه
month_count = df_clean['MoSold'].value_counts().sort_index()
month_names = ['دی', 'اسف', 'فرو', 'ارد', 'خرد', 'تیر', 'مرد', 'شهر', 'مهر', 'آب', 'آذر', 'دی']
axes[1].bar(range(1,13), month_count.values, color='AMBER', edgecolor='white')
axes[1].set_xticks(range(1,13))
axes[1].set_xticklabels([fa(m) for m in month_names], fontsize=8)
axes[1].set_title(fa('تعداد فروش به تفکیک ماه'), fontsize=12)
axes[1].set_xlabel(fa('ماه'), fontsize=11)
axes[1].set_ylabel(fa('تعداد معامله'), fontsize=11)

plt.tight_layout()
plt.show()

print(f'معماله {month_count.max()} یا {month_count.idxmax()} پرفروشترین ماه: ماه')
print(f'معماله {month_count.min()} یا {month_count.idxmin()} کمفروشترین ماه: ماه')
```

خروجی:



پرفروش ترین ماه: ماه ۶ با ۲۴۰ معامله
کم فروش ترین ماه: ماه ۲ با ۵۲ معامله
تحلیل:

Purpose: بررسی دو بعد زمانی مهم در دیتاست (روند قیمت به تفکیک دهه ساخت و الگوی فصلی فروش به تفکیک ماه) برای درک تأثیر زمان بر ارزش و رفتار بازار مسکن.

Findings Main: نمودار میانه قیمت به تفکیک دهه ساخت، روند صعودی کلی را نشان می دهد یعنی از \$۱۰۸k برای خانه های دهه ۱۸۷۰ تا \$۲۱۳k برای خانه های دهه ۲۰۰۰، تقریباً دو برابر افزایش یافته. با این حال روند کاملاً خطی نیست (دهه های ۱۸۹۰، ۱۹۱۰ و ۱۹۲۰ کاهش نسبی قیمت نسبت به دهه قبل را نشان می دهند که احتمال دارد مربوط به سبک های معماری آن دوره یا کیفیت مصالح استفاده شده باشد). از نظر فصلی، بیشترین معاملات در ماه های ۵، ۶ و ۷ انجام شده اند (ماه ۷ سال ۲۰۶۶ با ۶۲ معامله پرمعامله ترین دوره بود).

داده های سال ۲۰۱۰ ناقص هستند که دلیل کاهش چشمگیر تعداد معاملات در آن سال است.

میانگین قیمت در ماه ۹ (\$۱۷۹k) نسبت به ماه ۱ (\$۱۴۳k) تفاوت ۲۵ درصدی دارد.

Interpretation Practical: روند صعودی قیمت با افزایش سال ساخت از دید اقتصادی باز هم منطقی است چون خانه های جدید تر از استاندارد های ساخت بهتر، سیستم های عایق بندی مدرن تر و امکانات به روزتری برخوردارند.

نوسانات قیمت بین دهه های مختلف می تواند ناشی از تغییر سبک های معماری، کیفیت مصالح یا موقعیت مکانی خانه های ساخته شده در آن دوره باشد.

تفاوت ۲۵ درصدی میانگین قیمت بین ماه ۹ و ماه ۱ نشان دهنده فصلی بودن بازار مسکن است، با این حال باید

با احتیاط عمل کرد چون این نوسانات ممکن است عاملش این باشد که خانه های فروخته شده در هر ماه از لحاظ ترکیب با هم اختلاف داشته باشند (مثلا در تابستان خانه های بزرگ تر و گران تر بیشتر معامله می شوند)، نه لزوما تغییر واقعی قیمت ها.

۶.۴ تاثیر ویژگی های دسته ای

```
# 6. categorical تحلیل ویژگی‌های
fig, axes = plt.subplots(2, 2, figsize=(18, 12))

cats = [
    ('Neighborhood', fa('محله'), 90),
    ('SaleCondition', fa('شرایط فروش'), 20),
    ('Foundation', fa('نوع بنی'), 20),
    ('GarageType', fa('نوع گاراژ'), 20),
]


for ax, (col, label, rot) in zip(axes.flatten(), cats):
    order = df_clean.groupby(col)['SalePrice'].median().sort_values(ascending=False).index

    sns.boxplot(
        data=df_clean,
        x=col,
        y='SalePrice',
        order=order,
        palette='Blues',
        ax=ax
    )

    ax.set_title(f'{fa("قیمت به تفکیک")} {label}', fontsize=12)
    ax.set_xlabel(label, fontsize=10)
    ax.set_ylabel(fa('قیمت (دلار)'), fontsize=10)
    ax.tick_params(axis='x', rotation=45)

plt.suptitle(fa('تأثیر ویژگی‌های دسته‌ای بر قیمت'), fontsize=14, y=1.02)
plt.tight_layout()
plt.show()
```

خروجی:



تحلیل:

Purpose: بررسی میزان تاثیر چهار ویژگی دسته ای مهم (Neighborhood، SaleCondition، Foundation، GarageType) بر قیمت فروش از طریق Boxplot مرتب شده بر اساس میانه قیمت به منظور کشف الگو های قیمت گذاری در دسته های مختلف.

Findings Main: محله (Neighborhood) بیشترین تفاوت قیمت را ایجاد می کند (NoRidge و NridgHt) با میانه بالای \$ ۲۵۰k گران ترین و MeadowV و BrDale با میانه زیر \$ ۱۰۰k ارزان ترین محله ها هستند.

شرایط فروش (SaleCondition) نشان می دهد فروش های Partial (خانه های نوساز هنگام فروش) بالاترین قیمت را دارند در حالی که AdjLand (خرید زمین مجاور) ارزان ترین است. فروش های Abnormal قیمتشان به صورت قابل توجهی پایین تر از Normal است. نوع پی (Foundation) نشان می دهد خانه های با پی بتون ریخته شده (PConc) و چوبی (Wood) گران ترند در حالی که پی دال (Slab) ارزان ترین نوع است. نوع گاراژ (GarageType) نشان می دهد گاراژ های BuiltIn (داخل ساختمان) بالاترین و خانه های بدون گاراژ (None) پایین ترین قیمت را دارند. Interpretation Practical: تفاوت قیمت بین محله ها (تفاوت بیش از ۳ برابر بین NridgHt و MeadowV) نشان می دهد که موقعیت مکانی مهم ترین عامل دسته ای در تعیین قیمت مسکن است. تفاوت قیمت بین فروش های Normal و Abnormal نیز از دید اقتصادی کاملاً منطقی است، در فروش های اجباری مثل توقیف یا ورشکستگی، فروشنده مجبور است با قیمت پایین تر از ارزش واقعی ملک بفروشد. ارزان تر بودن خانه های با پی Slab نسبت به PConc دلایل می تواند دوام کمتر و هزینه های نگهداری بیشتر این نوع پی در اقلیم Iowa باشد که زمستان های سرد دارد.

۷.۴ ماتریس پراکندگی ویژگی های برتر

```
# 7. Pairplot ویژگی های برتر
top5 = ['SalePrice', 'GrLivArea', 'OverallQual', 'TotalBsmtSF', 'GarageArea']

g = sns.pairplot(df_clean[top5],
                 diag_kind='kde',
                 plot_kws={'alpha': 0.3, 's': 15, 'color': BLUE},
                 diag_kws={'color': GREEN})

g.fig.suptitle(fa('ماتریس پراکندگی ویژگی های برتر'), y=1.02, fontsize=14)
plt.show()
print('دارن SalePrice قوی ترین رابطه خطی با OverallQual و GrLivArea: نتیجه')
print('همبستگی متوسطی وجود داره TotalBsmtSF و GrLivArea: نتیجه: بین')
```

خروجی:



نتیجه: OverallQual و GrLivArea قوی ترین رابطه خطی با SalePrice دارند.

نتیجه: بین GrLivArea و TotalBsmtSF همبستگی متوسطی وجود دارد.
تحلیل:

Purpose: مصورسازی همزمان روابط دو به دو بین پنج ویژگی کلیدی (SalePrice، GrLivArea، OverallQual، GarageArea، TotalBsmtSF) از طریق ماتریس پراکندگی، به منظور کشف الگوهای چند متغیره و شناسایی همخطی چندگانه (Multicollinearity).

Findings Main: رابطه GrLivArea با SalePrice واضح ترین رابطه خطی را در کل ماتریس دارد. رابطه OverallQual با SalePrice به صورت پله ای است چون OverallQual یک متغیر ترتیبی با مقادیر ۱ تا ۱۰ است.

رابطه TotalBsmtSF با GrLivArea همبستگی متوسطی نشان می دهد (خانه های بزرگ تر معمولا زیر زمین بزرگ تری هم دارند).

توزیع GarageArea در قطر ماتریس دو قله دارد، یکی در صفر (بدون گاراژ) و یکی در حدود ۵۰۰ فوت مربع.

توزیع SalePrice در قطر ماتریس چولگی راست را نشان می دهد و GrLivArea توزیع نسبتا نرمالی دارد.

Interpretation Practical: وجود همبستگی بین TotalBsmtSF و GrLivArea (همخطی چندگانه) نکته

ی مهمی برای مدل سازی است زیرا وقتی هر دو ویژگی همزمان در مدل رگرسیون خطی استفاده می شوند، ضرایب آن ها ناپایدار می شوند.

این توضیح می دهد چرا در مدل رگرسیون خطی (بخش مدل سازی)، ضریب بعضی ویژگی ها مثل FullBath

و TotRmsAbvGrd منفی شد (نه به این خاطر که رابطه واقعی منفی است، بلکه به دلیل همخطی چندگانه بین این ویژگی ها).

شکل دو قله ای توزیع GarageArea نیز نشان دهنده وجود دو زیرجمعیت مجزا در دیتاست است:

- خانه های با گاراژ

- خانه های بدون گاراژ

که این تفکیک در خوشه بندی K-Means نیز به خوبی مشاهده شد.

۵ Task ۴: مصورسازی داده ها (Data Visualization)

۱.۵ رتبه بندی محله ها

```
# نقشه حرارتی قیمت محله ها
fig, ax = plt.subplots(figsize=(14, 7))

neigh_stats = df_clean.groupby('Neighborhood')['SalePrice'].agg(['median', 'count', 'std'])
neigh_stats.columns = ['median', 'count', 'std']
neigh_stats = neigh_stats.sort_values('median', ascending=True)

colors_n = [BLUE if v > 200000 else GREEN if v > 150000 else AMBER
            for v in neigh_stats['median']]


bars = ax.barh(neigh_stats.index, neigh_stats['median']/1000,
               color=colors_n, edgecolor='white', linewidth=0.5, height=0.7)

# اضافه کردن تعداد معامله
for i, (idx, row) in enumerate(neigh_stats.iterrows()):
    ax.text(row['median']/1000 + 2, i,
            f'$({row['median']/1000:.0f})K' (n=(int(row['count']))),
            va='center', fontsize=8.5)

ax.axvline(df_clean['SalePrice'].median()/1000, color='gray',
           linestyle='--', linewidth=1.5,
           label=f'میانگین کل: $(df_clean[\"SalePrice\"]').median()/1000:.0f)K'))
ax.set_xlim(0, 380)
ax.set_xlabel(f'میانگین قیمت فروش (هزار دلار)', fontsize=12)
ax.set_title(f'رتبه بندی محله ها بر اساس میانگین قیمت فروش', fontsize=14, pad=15)
ax.legend(fontsize=10)

from matplotlib.patches import Patch
legend_els = [
    Patch(facecolor=BLUE, label=f'200$ (آبی)'),
    Patch(facecolor=GREEN, label=f'$150K 200$ (سبز)'),
    Patch(facecolor=AMBER, label=f'150$ (زرد)'),
]
ax.legend(handles=legend_els, fontsize=9, loc='lower right')
plt.tight_layout()
plt.show()
```

خروجی:



گران ترین محله: NridgHt = \$ ۲۷۰k

ارزان ترین محله: MeadowV = \$ ۸۸k

نسبت گران ترین به ارزان ترین: ۱.۳ x

تحلیل:

Purpose: رتبه بندی و مقایسه بصری ۲۵ محله شهر Ames بر اساس میانه قیمت فروش با استفاده از نمودار

افقی رنگ بندی شده به منظور نمایش تاثیر موقعیت مکانی بر قیمت مسکن و شناسایی محله های گران و ارزان.

Findings Main: NridgHt با میانه \$ ۲۷۰k (۴۸ خانه) و NoRidge با میانه \$ ۲۶۹k (۲۴ خانه) گران

ترین محله ها هستند و در مقابل، MeadowV با میانه تنها \$ ۸۸k ارزان ترین محله است.

نسبت گران ترین به ارزان ترین محله ۱.۳ برابر است.

خط چین عمودی، میانه کل دیتاست (\$ ۱۶۰k) را نشان می دهد که ۱۲ محله بالاتر و ۱۳ محله پایین تر از آن

قرار دارند، رنگ بندی سه گانه نشان می دهد ۵ محله بالای \$ ۲۰۰k (آبی)، ۷ محله بین \$ ۱۵۰k تا \$ ۲۰۰k (سبز)

و ۱۳ محله زیر \$ ۱۵۰k (نارنجی) هستند.

Interpretation Practical: تفاوت ۱.۳ برابری بین گران ترین و ارزان ترین محله نشان می دهد که موقعیت

مکانی یکی از مهم ترین عوامل تعیین کننده قیمت مسکن است، حتی بیشتر از کیفیت ساخت در بسیاری موارد.

محله های گران قیمت مثل NridgHt و StoneBr معمولاً در مناطق جدید تر شهر با دسترسی بهتر به امکانات

رفاهی قرار دارند در حالی که محله های ارزان قیمت مثل MeadowV و IDOTRR اغلب در نزدیکی راه آهن یا

مناطق صنعتی هستند.

این نتایج برای سرمایه گذاران مسکن اهمیت بالایی دارد زیرا انتخاب محله درست می تواند تاثیری بیشتر از

بازسازی خانه بر ارزش ملک داشته باشد.

۲.۵ Chart Bubble کیفیت


```
# 2. (Bubble Chart) تأثیر کیفیت و سال ساخت روی قیمت
fig, ax = plt.subplots(figsize=(13, 7))

qual_groups = df_clean.groupby(['OverallQual', 'Decade']).agg(
    median_price=('SalePrice', 'median'),
    count=('SalePrice', 'count')
).reset_index()

scatter = ax.scatter(
    qual_groups['OverallQual'],
    qual_groups['median_price'] / 1000,
    s=qual_groups['count'] * 5,
    c=qual_groups['median_price'],
    cmap='YlOrRd',
    alpha=0.7,
    edgecolors='white',
    linewidth=0.5
)

plt.colorbar(scatter, ax=ax, label=f'قیمت (دلار)')
ax.set_xlabel(f'کیفیت کلی (1 تا 10)', fontsize=12)
ax.set_ylabel(f'میانه قیمت (هزار دلار)', fontsize=12)
ax.set_title(f'رابطه کیفیت با قیمت - اندازه دایره = تعداد خانه', fontsize=13, pad=12)
ax.set_xticks(range(1, 11))
plt.tight_layout()
plt.show()
print('خانه‌های با کیفیت ۱۰-۸ که بعد از ۲۰۰۰ ساخته شدن گران‌ترین دسته هستند')
```

خروجی:



خانه های با کیفیت ۸ تا ۱۰ که بعد از ۲۰۰۰ ساخته شدند گران ترین دسته هستند.
تحلیل:

Purpose: نمایش همزمان سه بعد اطلاعاتی (کیفیت کلی، میان قیمت و تعداد خانه ها) در یک نمودار به منظور درک توزیع خانه ها در سطوح مختلف کیفیتی و رابطه آن با قیمت.

Findings Main: بزرگ ترین دایره ها در کیفیت ۵، ۶ و ۷ قرار دارند که نشان دهنده تمرکز اکثریت خانه ها در این سطوح کیفیتی است.

با افزایش کیفیت از ۱ تا ۱۰، رنگ دایره ها از زرد (ارزان) به قرمز تیره (گران) تغییر می کند که رابطه مثبت قوی بین کیفیت و قیمت را نشان می دهد.

خانه های با کیفیت ۸ تا ۱۰ که عمدتاً بعد از سال ۲۰۰۰ ساخته شده اند، گران ترین دسته را تشکیل می دهند. دایره های کوچک در سطوح کیفیت ۱ و ۲ نشان می دهند که خانه های با کیفیت بسیار پایین در این بازار بسیار کمیاب هستند.

Interpretation Practical: توزیع نا متوازن خانه ها (تمرکز در کیفیت ۵ تا ۷) نشان می دهد که بازار مسکن Ames عمدتاً یک بازار متوسط است.

این موضوع از دید مدل سازی اهمیت دارد زیرا مدل ها برای پیش بینی خانه های با کیفیت ۱ و ۲ (که داده کمی دارند) دقت کمتری خواهند داشت، همچنین برتری خانه های با کیفیت متوسط در بازار نشان می دهد که این شهر دانشگاهی عمدتاً برای خانواده های با درآمد متوسط طراحی شده است.

۳.۵ مقایسه violin قبل/بعد

```
# 3. مقایسه Violin قبل/بعد با یکسانی با
fig, axes = plt.subplots(1, 2, figsize=(14, 6))


# قبل
data_before = [df_raw[df_raw['OverallQual'] == q]['SalePrice'].values / 1000
                for q in sorted(df_raw['OverallQual'].unique())]
axes[0].violinplot(data_before, positions=range(1, 11), showmedians=True)
axes[0].set_title(fa('توزیع قیمت به تفکیک کیفیت - قبل از پاکسازی'), fontsize=11)
axes[0].set_xlabel(fa('کیفیت کلی'), fontsize=11)
axes[0].set_ylabel(fa('قیمت (هزار دلار)'), fontsize=11)
axes[0].set_xticks(range(1, 11))

# بعد
data_after = [df_clean[df_clean['OverallQual'] == q]['SalePrice'].values / 1000
              for q in sorted(df_clean['OverallQual'].unique())]
vp = axes[1].violinplot(data_after, positions=range(1, 11), showmedians=True)
for body in vp['bodies']:
    body.set_facecolor('green')
    body.set_alpha(0.7)
axes[1].set_title(fa('توزیع قیمت به تفکیک کیفیت - بعد از پاکسازی'), fontsize=11)
axes[1].set_xlabel(fa('کیفیت کلی'), fontsize=11)
axes[1].set_ylabel(fa('قیمت (هزار دلار)'), fontsize=11)
axes[1].set_xticks(range(1, 11))

plt.suptitle(fa('تأثیر پاکسازی داده بر توزیع قیمت'), fontsize=14, y=1.02)
plt.tight_layout()
plt.show()
print(fa('های کیفیت ۴-۶ حذف شدن و توزیع متمایلتر شده outlier بعد از پاکسازی'))
```

خروجی:

تأثیر پاکسازی داده بر توزیع قیمت



بعد از پاکسازی، outlier های کیفیت ۴ تا ۶ حذف شدن و توزیع متعادل تر شده
تحلیل:

Purpose: مقایسه بصری تأثیر پاکسازی داده بر توزیع قیمت در هر سطح کیفیتی از طریق نمودار Violin که شکل کامل توزیع را نمایش می دهد (نه فقط میانه و پراکندگی)

Findings Main: در نمودار چپ (قبل از پاکسازی)، دم های بلند رو به بالا در سطوح کیفیت ۸ تا ۱۰ به وضوح مشاهده می شود، خانه هایی با قیمت های بالای \$۵۰۰k تا \$۷۵۰k که توزیع را مخدوش می کنند. در نمودار راست (بعد از پاکسازی)، این دم های بلند حذف شده و شکل Violin ها متقارن تر و منظم تر است. نکته جالب اینکه کیفیت ۱۰ پس از پاکسازی از دیتاست حذف شده است، نشانه ای از اینکه تمام خانه های کیفیت ۱۰ قیمت های پرت داشتند.

همچنین outlier های کیفیت ۴ تا ۶ حذف شدند و توزیع این گروه ها متعادل تر شد.

Interpretation Practical: حذف کیفیت ۱۰ پس از پاکسازی یک نتیجه مهم است، این خانه ها احتمالا در

محله های بسیار گران قیمت با قیمت هایی بسیار فراتر از حد IQR بودند.

این نشان می دهد که بازار مسکن Ames در سطح کیفیت ۱۰ یک بازار بسیار کوچک است که با قوانین متفاوتی از بقیه بازار عمل می کند.

مقارن تر شدن شکل Violin ها پس از پاکسازی نشان می دهد که داده های پرت واقعا نویز بودند و حذف آن ها باعث شد تصویر واقعی تری از بازار مسکن داشته باشیم.

۴.۵ Heatmap محله * کیفیت


```
# 4. Heatmap محله * کیفیت
pivot = df_clean.pivot_table(
    values='SalePrice',
    index='Neighborhood',
    columns='OverallQual',
    aggfunc='median'
) / 1000

# فقط محله‌هایی که داده کافی دارند
pivot = pivot.dropna(thresh=3)

fig, ax = plt.subplots(figsize=(14, 10))
sns.heatmap(pivot, cmap='YlOrRd', annot=True, fmt='.0f',
            linewidths=0.3, ax=ax,
            cbar_kws={'label': fa('میانگین قیمت (هزار دلار)')})

ax.set_title(fa('میانگین قیمت فروشی (هزار دلار): محله * کیفیت'), fontsize=14, pad=15)
ax.set_xlabel(fa('کیفیت کلی'), fontsize=12)
ax.set_ylabel(fa('محله'), fontsize=12)
plt.tight_layout()
plt.show()
print('با کیفیت ۸+ بالاترین قیمت‌ها رو داره NoRidge محله')
print('در محله‌های ارزاتر حتی کیفیت بالا هم قیمت رو خیلی بالا نمیره')
```

خروجی:



محله NoRidge با کیفیت بالا تر از ۸ بالاترین قیمت ها رو داره
در محله های ارزان تر حتی کیفیت بالا هم قیمت رو خیلی بالا نمیره
تحلیل:

Purpose: بررسی اثر تعاملی (Effect Interaction) دو عامل مهم محله و کیفیت بر قیمت مسکن از طریق Heatmap که برای هر ترکیب محله؛ کیفیت، میانۀ قیمت را نشان می دهد.

Findings Main: گران ترین ترکیب در کل ماتریس، محله NridgHt با کیفیت ۹ است و میانۀ \$ ۳۱۷k. ارزان ترین ترکیب، محله Edwards با کیفیت ۱ است و میانۀ \$ ۶۱k.

سلول های خالی نشان دهنده ترکیب هایی هستند که در دیتاست وجود ندارند، مثلاً هیچ خانه ای با کیفیت ۱۰ در محله MeadowV وجود ندارد.

نکته اینکه در محله های ارزان تر مانند IDOTRR و MeadowV، حتی با افزایش کیفیت تا سطح ۶، قیمت از \$ ۱۵۴k بیشتر نرفته استن و در مقابل، در محله StoneBr حتی خانه های با کیفیت ۷ نیز میانۀ قیمت \$ ۲۳۹k دارند.

Interpretation Practical: این Heatmap مفهوم سقف قیمت محله ای را به خوبی نشان می دهد(در محله های ارزان قیمت، هر چقدر هم کیفیت ساخت را بهبود بدهید، قیمت از یک حد مشخص بالاتر نمی رود).

این نتیجه اهمیت عملی بالایی برای سرمایه گذاران دارد:

سرمایه گذاری در بازسازی یک خانه در محله MeadowV برای افزایش کیفیت از ۴ به ۷ احتمالاً بازگشت سرمایه خوبی نخواهد داشت، چون سقف قیمت محله مانع افزایش متناسب قیمت می شود.

این اثر تعاملی بین محله و کیفیت نشان می دهد که مدل های رگرسیون خطی ساده که این اثر را نادیده می گیرند، دقت کمتری خواهند داشت.

۵.۵ تحلیل فصلی

```
# تحلیل فصلی فروش 5.
fig, axes = plt.subplots(1, 2, figsize=(14, 5))


# تعداد فروش * ماه * سال
pivot_time = df_clean.pivot_table(
    values='SalePrice',
    index='MoSold',
    columns='YrSold',
    aggfunc='count'
)

sns.heatmap(pivot_time, annot=True, fmt='.0f', cmap='Blues',
            ax=axes[0], linewidths=0.3)
axes[0].set_title(fa('تعداد فروش به تفکیک ماه و سال'), fontsize=12)
axes[0].set_xlabel(fa('سال'), fontsize=11)
axes[0].set_ylabel(fa('ماه'), fontsize=11)

# میانگین قیمت * ماه
month_price = df_clean.groupby('MoSold')['SalePrice'].median() / 1000
axes[1].plot(month_price.index, month_price.values,
            color=BLUE, linewidth=2.5, marker='o', markersize=7)
axes[1].fill_between(month_price.index, month_price.values,
                    month_price.min(), alpha=0.15, color=BLUE)
axes[1].set_title(fa('میانگین قیمت به تفکیک ماه فروش'), fontsize=12)
axes[1].set_xlabel(fa('ماه'), fontsize=11)
axes[1].set_ylabel(fa('میانگین قیمت (هزار دلار)'), fontsize=11)
axes[1].set_xticks(range(1, 13))
axes[1].grid(True, alpha=0.3)

plt.tight_layout()
plt.show()
```

خروجی:



تحلیل:

Purpose: بررسی الگوی فصلی بازار مسکن Ames از دو دید (تعداد معاملات به تفکیک ماه و سال (Heatmap) و میانگین قیمت ماهانه (Line Chart)) برای کشف رفتار فصلی بازار.

Findings Main: Heatmap تعداد فروش نشان می دهد که در تمام سال های ۲۰۰۶ تا ۲۰۰۹، ماه های ۵، ۶ و ۷ پر ترافیک ترین ماه های فروش هستند، بیشترین معامله ثبت شده ماه ۷ سال ۲۰۰۶ با ۶۲ معامله است. داده های سال ۲۰۱۰ ناقص هستند (این سال تنها ۶ معامله در ماه ۷ ثبت کرده در حالی که سال های قبل ۴۷ تا ۶۲ معامله داشتند).

نمودار خطی، میانگین قیمت ماهانه نوسانات غیرمنتظره ای را نشان می دهد (ماه ۹ با \$ ۱۷۹k بالا ترین و ماه ۱ با \$ ۱۴۳k پایین ترین میانگین قیمت را دارد). تفاوت ۲۵ درصدی بین این دو ماه قابل توجه است.

Interpretation Practical: الگوی فصلی پر فروش بودن تابستان (ماه های ۵ تا ۷) با رفتار خریداران مسکن در آمریکا همخوانی دارد، خانواده ها ترجیح می دهند قبل از شروع سال تحصیلی جدید نقل مکان کنند تا فرزندان شان در اول ماه تحصیلی در مدرسه جدید حاضر باشند.

نوسانات میانگین قیمت ماهانه احتمالاً ناشی از ترکیب متفاوت خانه های فروخته شده در هر ماه است نه تغییر واقعی قیمت بازار، در تابستان خانه های بزرگ تر و گران تر (مناسب خانواده) بیشتر معامله می شوند در حالی که در زمستان آپارتمان های کوچک تر و ارزان تر بیشتر فروش می روند.


ناقص بودن داده های ۲۰۱۰ باید در تفسیر نتایج مربوط به این سال مدنظر قرار گیرد.

۶.۵ همبستگی نهایی

```
# همبستگی ساده
# SalePrice مهم‌ترین ویژگی‌ها بر اساس همبستگی با
corr_vals = df_clean[num_cols + ['SalePrice']].corr()['SalePrice']\
    .drop('SalePrice').abs().sort_values(ascending=True).tail(15)

fig, ax = plt.subplots(figsize=(10, 7))
colors_fi = [BLUE if v > 0.6 else GREEN if v > 0.4 else '#B5D4F4'
             for v in corr_vals.values]
ax.barh(corr_vals.index, corr_vals.values, color=colors_fi,
        edgecolor='white', linewidth=0.5)
ax.set_title(fa('مهم‌ترین ویژگی‌ها بر اساس همبستگی با قیمت'), fontsize=13, pad=12)
ax.set_xlabel(fa('ضریب همبستگی (قدرمطلق)'), fontsize=11)
ax.axvline(0.6, color='gray', linestyle='--', alpha=0.5, label=f('آستانه ۰.۶'))
ax.legend(fontsize=9)
for i, v in enumerate(corr_vals.values):
    ax.text(v + 0.005, i, f'{v:.2f}', va='center', fontsize=9)
plt.tight_layout()
plt.show()
```

خروجی:



تحلیل:

Purpose: ارائه تصویر جامع از قوی ترین همبستگی های عددی با قیمت فروش از طریق نمودار افقی رنگ بندی شده، به منظور اولویت بندی ویژگی ها برای مدل سازی و تایید یافته های بخش های قبلی.

Findings Main: OverallQual با ضریب همبستگی ۷۹.۰ در پیش بینی قیمت قوی ترین است. GrLivArea با ۶۸.۰ دومین است.

GarageCars با ۶۳.۰ و GarageArea با ۶۱.۰ هر دو در دسته آبی تیره (بالای ۰.۶) قرار دارند. YearBuilt با ۵۹.۰، TotalBsmtSF با ۵۸.۰ و FullBath با ۵۷.۰ در دسته سبز (۰.۴ تا ۰.۶) قرار دارند.

در آخر لیست، MasVnrArea، OpenPorchSF، LotFrontage و GarageYrBlt همگی ضریب همبستگی ۳۲.۰ دارند.

Interpretation Practical: نکته در همبستگی بالای GarageCars (۶۳.۰) نسبت به GarageArea (۶۱.۰) است یعنی تعداد ماشین هایی که گاراژ جا می دهد رابطه قوی تری با قیمت نسبت به مساحت خود گاراژ

دارد.

این به این معناست که خریداران بیشتر به عملکرد (اینکه چند ماشین جا می شود) توجه می کنند تا اندازه. همچنین پایین بودن همبستگی LotFrontage (۳۲۰۰) و LotArea (که در top ۱۵ نیست) نشان می دهد که مساحت زمین در این بازار قدرت پیش بینی قوی ای ندارد و احتمالاً به این دلیل که در Ames زمین های بزرگ اغلب در محله های ارزان قیمت حومه شهر قرار دارند. این ۱۵ ویژگی به عنوان ورودی مدل های آماری بخش بعدی انتخاب شدند.

Task ۵: مدل سازی آماری (Statistical Modeling)

۱.۶ رگرسیون خطی (Linear Regression)

```
# مدل آماری - رگرسیون خطی
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import r2_score, mean_squared_error
from sklearn.preprocessing import LabelEncoder
import numpy as np

# آماده سازی داده
df_model = df_clean.copy()
features = ['OverallQual', 'GrLivArea', 'TotalBsmtSF',
            'GarageCars', 'YearBuilt', 'FullBath',
            'TotRmsAbvGrd', 'Fireplaces']
X = df_model[features]
y = df_model['SalePrice']

# تقسیم داده ها به train و test
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)

print(f'تعداد داده آموزشی: {len(X_train)}')
print(f'تعداد داده تستی: {len(X_test)}')

# آموزش مدل
model = LinearRegression()
model.fit(X_train, y_train)

# پیش بینی
y_pred = model.predict(X_test)

r2 = r2_score(y_test, y_pred)
rmse = np.sqrt(mean_squared_error(y_test, y_pred))
print(f'R² Score: {r2:.3f}')
print(f'RMSE: ${rmse:,.0f}')
print(f'از تغییرات قیمت رو توضیح میده: {r2*100:.1f} پرتی مدل')

# تصویر سازی نتایج
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# Predicted vs Actual
axes[0].scatter(y_test/1000, y_pred/1000,
               alpha=0.4, s=20, color=BLUE, edgecolor='none')
axes[0].plot([y_test.min()/1000, y_test.max()/1000],
             [y_test.min()/1000, y_test.max()/1000],
             color=ORANGE, linewidth=2, linestyle='--', label=f'خط ایده آل')
axes[0].set_title(f'قیمت پیش بینی شده VS قیمت واقعی', fontsize=12)
axes[0].set_xlabel(f'قیمت واقعی (هزار دلار)', fontsize=11)
axes[0].set_ylabel(f'قیمت پیش بینی (هزار دلار)', fontsize=11)
axes[0].legend(fontsize=9)
axes[0].text(0.85, 0.92, f'R² = {r2:.3f}', transform=axes[0].transAxes,
            fontsize=11, color='darkred', fontweight='bold')

# ضرایب ویژگی ها
coef = pd.Series(model.coef_, index=features).sort_values()
colors_c = [GREEN if v > 0 else ORANGE for v in coef.values]
axes[1].barh(coef.index, coef.values, color=colors_c,
             edgecolor='white', linewidth=0.5)
axes[1].axvline(0, color='gray', linewidth=1)
axes[1].set_title(f'تأثیر هر ویژگی بر قیمت (ضرایب مدل)', fontsize=12)
axes[1].set_xlabel(f'ضرایب (رگرسیون)', fontsize=11)

plt.suptitle(f'نتایج مدل رگرسیون خطی', fontsize=14, y=1.02)
plt.tight_layout()
plt.show()

print('\nتفسیر ضرایب:')
for feat, coef_val in sorted(zip(features, model.coef_),
                             key=lambda x: abs(x[1]), reverse=True):
    print(f' {feat}: {coef_val:,.0f} = به ازای هر واحد افزایش
```

خروجی:

تعداد داده آموزشی: ۱۰۹۸


تعداد داده تستی: ۲۷۵

Score: R² ۷۸۳.۰

RMSE: \$۲۵,۹۲۸

یعنی مدل ۷۸.۳٪ از تغییرات قیمت رو توضیح میده

نتایج مدل رگرسیون خطی



تفسیر ضرایب:

OverallQual: به ازای هر واحد افزایش $\leq +14,800$ \$ تغییر قیمت
 GarageCars: به ازای هر واحد افزایش $\leq +8,701$ \$ تغییر قیمت
 Fireplaces: به ازای هر واحد افزایش $\leq +7,563$ \$ تغییر قیمت
 FullBath: به ازای هر واحد افزایش $\leq -3,795$ \$ تغییر قیمت
 TotRmsAbvGrd: به ازای هر واحد افزایش $\leq -2,282$ \$ تغییر قیمت
 YearBuilt: به ازای هر واحد افزایش $\leq +412$ \$ تغییر قیمت
 GrLivArea: به ازای هر واحد افزایش $\leq +53$ \$ تغییر قیمت
 TotalBsmtSF: به ازای هر واحد افزایش $\leq +28$ \$ تغییر قیمت

تحلیل:

Purpose: ساخت یک مدل رگرسیون خطی چندگانه برای پیش بینی قیمت فروش خانه (SalePrice) بر اساس ۸ ویژگی مهم، ارزیابی عملکرد مدل و تفسیر ضرایب برای درک تاثیر کمی هر ویژگی بر قیمت.
 Findings Main: داده ها با نسبت ۸۰ به ۲۰، به ۱۰۹۸ نمونه آموزشی و ۲۷۵ نمونه تستی تقسیم شدند.
 مدل رگرسیون خطی، $R^2=0.783$ و $RMSE=\$25,928$ به دست آورد که یعنی مدل ۳.۷۸ % از تغییرات قیمت را توضیح می دهد و میانگین خطای پیش بینی حدود ۲۶ هزار دلار است.
 ضرایب مدل نشان می دهند OverallQual با ضریب $+14,800$ \$ بیشترین تاثیر مثبت را دارد.
 GarageCars با $+8,701$ \$ و Fireplaces با $+7,563$ \$ در رتبه های بعدی قرار دارند.
 ضرایب منفی FullBath ($-3,795$ \$) و TotRmsAbvGrd ($-2,282$ \$) در نمودار مشاهده می شوند.
 نمودار Actual vs Predicted نشان می دهد که انحراف نقاط از خط مرجع در قیمت های بالای $200k$ \$ بیشتر است.

Interpretation Practical: $R^2=0.783$ برای یک مدل خطی ساده با فقط ۸ ویژگی، عملکرد قابل قبولی است.

$RMSE=\$25,928$ در مقیاس بازار مسکن Ames (میانگین $180k$ \$) معادل خطای ۳.۱۴ % است که برای اهداف عملی قابل استفاده است.

ضریب منفی FullBath و TotRmsAbvGrd پدیده همخطی چندگانه (Multicollinearity) را نشان می دهد (این دو ویژگی با GrLivArea همبستگی بالایی دارند و اطلاعات مشابهی به مدل می دهند، به همین دلیل ضرایب غیرمنطقی به نظر می رسند).

ضعیف تر بودن مدل در پیش بینی خانه های لوکس (بالای $200k$ \$) نشان می دهد که قیمت گذاری در بخش لوکس بازار پیچیدگی های بیشتری دارد که رگرسیون خطی ساده قادر به capture کردن آن ها نیست.

۲.۶ درخت تصمیم (Decision Tree)

```
# درخت تصمیم
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.metrics import classification_report, confusion_matrix

# ساختن مرجع
df_model['PriceCategory'] = (
    df_model['SalePrice'] >= df_model['SalePrice'].median()
).astype(int)

features_dt = ['OverallQual', 'GrLivArea', 'TotalBsmtSF',
               'GarageCars', 'YearBuilt', 'FullBath']

X_dt = df_model[features_dt]
y_dt = df_model['PriceCategory']

X_train_dt, X_test_dt, y_train_dt, y_test_dt = train_test_split(
    X_dt, y_dt, test_size=0.2, random_state=42)

# آموزش
dt = DecisionTreeClassifier(max_depth=4, random_state=42)
dt.fit(X_train_dt, y_train_dt)

y_pred_dt = dt.predict(X_test_dt)
acc = dt.score(X_test_dt, y_test_dt)
print(f'دقت درخت تصمیم: {acc*100:.1f}%')
print()
print(classification_report(y_test_dt, y_pred_dt,
                           target_names=['ارزان', 'گران']))

# رسم درخت
fig, ax = plt.subplots(figsize=(22, 9))
plot_tree(dt,
          feature_names=features_dt,
          class_names=['Cheap', 'Expensive'],
          filled=True, rounded=True,
          fontsize=9, ax=ax)
```

```

        annot=True, fmt='d', cmap='Blues', ax=ax,
        xticklabels=[fa('ارزون'), fa('گران')],
        yticklabels=[fa('ارزون'), fa('گران')])
ax.set_title(fa('ماتریس درهم‌ریختگی (Confusion Matrix)'), fontsize=12)
ax.set_xlabel(fa('پیش‌بینی مدل'), fontsize=11)
ax.set_ylabel(fa('مقدار واقعی'), fontsize=11)
plt.tight_layout()
plt.show()


print(f'تا رو درست دسته‌بندی می‌کنه {acc*100:.0f} از هر ۱۰۰ خانه، مدل')


```

خروجی:
دقت درخت تصمیم: ۴۰.۸۸٪

	precision	recall	F۱-score	support
ارزون	۱۴۹	۸۹.۰	۸۹.۰	۸۹.۰
گران	۱۲۶	۸۷.۰	۸۷.۰	۸۷.۰
Accuracy				۲۷۵
avg Macro		۸۸.۰	۸۸.۰	۲۷۵
avg Weighted		۸۸.۰	۸۸.۰	۲۷۵

درخت تصمیم — دسته‌بندی خانه به گرون و ارزون (max_depth=4)





از هر ۱۰۰ خانه، مدل ۸۸ تا رو درست دسته بندی می‌کند.
تحلیل:

Purpose: ساخت یک مدل دسته بندی برای تفکیک خانه ها به دو دسته گران (بالا تر از میانه قیمت) و ارزان (پایین تر از میانه قیمت) با استفاده از درخت تصمیم با عمق ۴ و تفسیر ساختار درخت برای درک منطق تصمیم گیری مدل.

Findings Main: مدل دقت کلی ۴۰.۸۸٪ به دست آورد که از هر ۱۰۰ خانه، ۸۸ تا درست دسته بندی می شوند.

Precision: برای دسته ارزان ۸۹.۰ و برای دسته گران ۸۷.۰ است.
F1-Score: متعادل برای هر دو دسته نشان دهنده عملکرد یکسان مدل روی هر دو گروه است.
 ساختار درخت نشان می دهد ریشه درخت از $OverallQual \geq 5.5$ تقسیم می شود، در شاخه چپ (کیفیت پایین)، $GrLivArea \geq 5.1382$ معیار تقسیم بعدی است، در شاخه راست (کیفیت بالا)، $GrLivArea \geq 1143$ معیار تقسیم کننده بعدی است و در سطح سوم، $TotalBsmtSF$ ، $YearBuilt$ و $GarageCars$ نقش مهمی دارند.
 ماتریس درهم ریختگی نشان می دهد از ۱۴۹ خانه ارزان، ۱۳۳ تا درست شناسایی شدند (۱۶ خطا) و از ۱۲۶ خانه گران، ۱۱۰ تا درست شناسایی شدند (۱۶ خطا).

Interpretation Practical: انتخاب $OverallQual$ به عنوان اولین گره تقسیم درخت تایید می کند که کیفیت کلی مهم ترین عامل تمایز بین خانه های گران و ارزان است، این نتیجه با نتیجه تحلیل همبستگی ($r=0.79$) کاملاً همخوانی دارد.

تعادل خطاها در دو طرف (هر بار ۱۶ خطا) نشان دهنده عملکرد یکسان مدل روی هر دو دسته است و مدل تمایلی به پیش بینی یک دسته خاص ندارد. محدود کردن عمق درخت به ۴ سطح ($max_depth=4$) یک تصمیم خوب برای جلوگیری از **Overfitting** است زیرا یک درخت عمیق تر ممکن است روی داده های آموزشی دقت ۱۰۰٪ داشته باشد اما روی داده های جدید عملکرد ضعیفی داشته باشد.

۳.۶ خوشه‌بندی (Clustering K-Means)

```
# خوشه بندی
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler

# آماده‌سازی
features_km = ['OverallQual', 'GrLivArea', 'TotalBsmtSF',
               'GarageCars', 'SalePrice']
X_km = df_clean[features_km].dropna()

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X_km)

# آموزش KMeans
kmeans = KMeans(n_clusters=4, random_state=42)
df_clean['Cluster'] = kmeans.fit_predict(X_scaled)

# مصورسازی
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# scatterها
scatter = axes[0].scatter(df_clean['GrLivArea'],
                        df_clean['SalePrice']/1000,
                        c=df_clean['Cluster'],
                        cmap='Set1', alpha=0.5, s=20)
axes[0].set_title(fa('خوشه‌بندی ختم (K-Means, k=4)'), fontsize=12)
axes[0].set_xlabel(fa('زیرینا (فوت مربع)'), fontsize=11)
axes[0].set_ylabel(fa('قیمت (هزار دلار)'), fontsize=11)
plt.colorbar(scatter, ax=axes[0], label=f('خوشه'))

# میانگین هر خوشه
cluster_means = df_clean.groupby('Cluster')[features_km].mean()
cluster_means['SalePrice'] = cluster_means['SalePrice']/1000
axes[1].bar(cluster_means.index.astype(str),
            cluster_means['SalePrice'],
            color=PALETTE, edgecolor='white')
for i, v in enumerate(cluster_means['SalePrice']):
    axes[1].text(i, v+2, f'$({v:.0f})K', ha='center', fontsize=9)
```


```
axes[1].set_title(fa('میانگین قیمت هر خوشه'), fontsize=12)
axes[1].set_xlabel(fa('خوشه'), fontsize=11)
axes[1].set_ylabel(fa('میانگین قیمت (هزار دلار)'), fontsize=11)

plt.suptitle(fa('نتایج خوشه‌بندی K-Means'), fontsize=14, y=1.02)
plt.tight_layout()
plt.show()

print('مشخصات هر خوشه')
print(cluster_means.round(1).to_string())
```

خروجی:

نتایج خوشه‌بندی K-Means



مشخصات هر خوشه:

Cluster	OverallQual	GrLivArea	TotalBsmtSF	GarageCars	SalePrice
۰	۷.۵	۶.۱۲۶۴	۸.۱۱۶۴	۰.۲	۶.۱۵۷
۱	۶.۷	۶.۱۸۶۵	۹.۱۴۷۶	۴.۲	۷.۲۵۶
۲	۸.۴	۷.۱۱۱۷	۹.۷۷۹	۹.۰	۸.۱۱۴
۳	۴.۶	۲.۱۷۶۷	۴.۷۹۹	۹.۱	۸.۱۸۲

تحلیل:

Purpose: کشف الگوهای پنهان در داده‌ها از طریق گروه‌بندی خودکار خانه‌ها به ۴ خوشه بر اساس ۵ ویژگی مهم (OverallQual، GrLivArea، TotalBsmtSF، GarageCars، SalePrice)، بدون استفاده از برچسب

از پیش تعیین شده.

Findings Main: الگوریتم K-Means با $k=4$ چهار خوشه متمایز شناسایی کرد،

خوشه ۲ با میانگین کیفیت ۸.۴، زیربنای ۱۱۱۸ فوت، زیرزمین ۷۸۰ فوت، گاراژ ۹.۰ ماشین و میانگین قیمت \$ ۱۱۵k خوشه اقتصادی و کوچک است.

خوشه ۰ با کیفیت ۷.۵، زیربنای ۱۲۶۵ فوت، زیر زمین ۱۱۶۵ فوت، گاراژ ۲ ماشین و قیمت \$ ۱۵۸k خوشه متوسط با زیرزمین خوب است.

خوشه ۳ با کیفیت ۴.۶، زیر بنای ۱۷۶۷ فوت، زیر زمین ۷۹۹ فوت، گاراژ ۹.۱ ماشین و قیمت \$ ۱۸۳k خوشه بزرگ بدون زیرزمین است.

خوشه ۱ با کیفیت ۶.۷، زیر بنای ۱۸۶۶ فوت، زیر زمین ۱۴۷۷ فوت، گاراژ ۴.۲ ماشین و قیمت \$ ۲۵۷k خوشه لوکس و بزرگ است.

نمودار Plot Scatter نشان می دهد خوشه ها در فضای زیر بنا و قیمت، به خوبی از هم تفکیک شده اند.

Interpretation Practical: مقایسه خوشه های ۰ و ۳، نتایج جالبی را نشان میدهد،

هر دو زیر بنای شبیه به همی دارند اما خوشه ۰ زیر زمین بزرگ تری (۱۱۶۵ فوت) و قیمت پایین تر (\$ ۱۵۸k) دارد، در حالی که خوشه ۳ زیر زمین کوچک تری (۷۹۹ فوت) اما قیمت بالاتر (\$ ۱۸۳k) دارد.

این تفاوت \$ ۲۵k نشان می دهد که خریداران به زیر بنای بالای زمین (فضای زندگی قابل استفاده روزانه) بیشتر از زیرزمین ارزش می دهند،

نتایجی که با نتیجه تحلیل همبستگی (GrLivArea: $r=0.68$ در مقابل TotalBsmntSF: $r=0.58$) نیز همخوانی دارد.

این چهار خوشه می توانند به عنوان بخش بندی بازار (Segmentation Market) برای هدف گذاری برنامه ریزی های بازاریابی و سرمایه گذاری در حوزه مسکن استفاده شوند.

نتیجه گیری (Conclusion)

۷ نتیجه گیری (Conclusion)

این پژوهش با هدف تحلیل و مصور سازی عوامل موثر بر قیمت فروش مسکن در شهر Ames آمریکا انجام شد.

پس از طی مراحل کامل تحلیل داده از پاکسازی تا مدل سازی، مهم ترین نتایج به شرح زیر است:

۱. کیفیت، مهم ترین عامل تعیین کننده قیمت است.

کیفیت کلی خانه (OverallQual) با ضریب همبستگی ۷۹.۰ قوی ترین رابطه را با قیمت دارد. به ازای هر سطح افزایش کیفیت، قیمت به طور میانگین ۱۴۸۰۰ دلار افزایش می یابد. میانه قیمت از ۵۰۱۵۰ دلار در کیفیت ۱ به ۳۱۰،۰۰۰ دلار در کیفیت ۱۰ رسیده (۲.۶ برابر افزایش). این یافته توسط هر سه مدل آماری (رگرسیون خطی، درخت تصمیم و K-Means) تأیید شد.

۲. موقعیت مکانی، تفاوت چشمگیری ایجاد می کند.

اختلاف قیمت بین گران ترین محله (NridgHt با \$ ۲۷۰k) و ارزان ترین محله (MeadowV با \$ ۸۸k) معادل ۱.۳ برابر است.

تحلیل Heatmap محله×کیفیت نشان داد که محله می تواند اثر کیفیت را محدود کند، پدیده سقف قیمت محله ای، به گونه ای که در محله های ارزان تر، افزایش کیفیت تا سطح ۶ قیمت را از \$ ۱۵۴k بالاتر نمی برد.

۳. مساحت، رابطه مستقیم با قیمت دارد.

زیربنای زندگی (GrLivArea) با همبستگی ۶۸.۰ دومین عامل مهم است.

به ازای هر ۱۰۰ فوت مربع افزایش زیربنا، قیمت به طور میانگین ۹،۰۰۰ دلار افزایش می یابد. مقایسه خوشه های K-Means نشان داد که خریداران به زیربنای بالای زمین بیشتر از زیرزمین ارزش می دهند.

۴. خانه های جدید تر، گران تر هستند.

میان قیمت خانه های دهه ۲۰۰۰ (\$ ۲۱۳k) نسبت به دهه ۱۸۷۰ (\$ ۱۰۸k) تقریباً دو برابر است. سال ساخت با ضریب $+412$ به ازای هر سال، تاثیر مثبت پایداری بر قیمت دارد، با این حال، این رابطه خطی نیست و بازسازی های اخیر می توانند ارزش خانه های قدیمی را به طور قابل توجهی افزایش دهند.

۵. بازار مسکن، فصلی است.

بیشترین معاملات در ماه های تابستان انجام می شود، ماه ۷ سال ۲۰۰۶ با ۶۲ معامله پرتراфик ترین دوره بود. میان قیمت در ماه ۹ (\$ ۱۷۹k) نسبت به ماه ۱ (\$ ۱۴۳k) تفاوت ۲۵ درصدی دارد که احتمالاً ناشی از ترکیب متفاوت خانه های فروخته شده در هر ماه است.

۶. مدل رگرسیون خطی، عملکرد قابل قبولی دارد.

مدل رگرسیون خطی با $R^2 = 0.783$ توانست ۷۸٪ از تغییرات قیمت را توضیح دهد. $RMSE = \$25,928$ در مقیاس بازار مسکن Ames (میانگین \$ ۱۸۰k) معادل خطای ۳.۱۴٪ است. مدل در پیش بینی خانه های لوکس (بالای \$ ۲۰۰k) عملکرد ضعیف تری دارد که نشان دهنده پیچیدگی بیشتر قیمت گذاری در بخش لوکس بازار است.

۷. درخت تصمیم، دسته بندی دقیقی ارائه می دهد.

درخت تصمیم با دقت ۴.۸۸٪ توانست خانه ها را به دو دسته گران و ارزان تقسیم کند. مهم ترین معیار تصمیم گیری درخت، کیفیت کلی ($OverallQual \geq 5.5$) است که تایید می کند کیفیت مهم ترین عامل تفاوت و تمایز است. تعادل خطاها در هر دو دسته نشان دهنده عملکرد یکسان و بدون تعصب مدل است.

۸. خوشه بندی، چهار دسته مسکن را شناسایی کرد.

الگوریتم K-Means چهار گروه متمایز شناسایی کرد:

اقتصادی (\$ ۱۱۵k)،

متوسط (\$ ۱۵۸k)،

بزرگ بدون زیرزمین (\$ ۱۸۳k)

و لوکس (\$ ۲۵۷k).

این دسته بندی می تواند برای هدف گذاری بازار مسکن، سیاست گذاری مسکن شهری و برنامه ریزی سرمایه گذاری مفید باشد.

جمع بندی نهایی: قیمت مسکن در شهر Ames نتیجه تعامل پیچیده عوامل متعددی است که در راس آن ها کیفیت ساخت، موقعیت مکانی و مساحت قرار دارند.

هیچ عاملی به تنهایی تعیین کننده نیست، یک خانه با کیفیت بالا در محله نامناسب یا یک زمین بزرگ در موقعیت بد، لزوماً قیمت بالایی ندارند.

این پیچیدگی چندعاملی مشکل اصلی مدل سازی قیمت مسکن است و نشان می دهد که مدل های پیشرفته تر مثل Forest Random یا Boosting Gradient که اثرات تعاملی را بهتر capture می کنند، می توانند دقت پیش بینی را به طور قابل توجهی بهبود بخشند.