

به نام خدا

Data Visualization Course Project
Spring 1405

تحلیل و مصور سازی داده های مسکن شهر Ames با
استفاده از مجموعه داده Ames Housing Dataset

Instructor: Dr. Omid Karimi

Student: Sara Dehghani

Student ID: 40411403001

Kaggle Project :

<https://www.kaggle.com/code/saradehqani/notebook7d0dd672ee>

مقدمه - Introduction

تحلیل داده های مسکن یکی از کاربردی ترین حوزه های علم داده است که در آن، الگوهای پنهان در بازار خرید و فروش ملک از طریق روش های آماری و مصورسازی کشف می شوند.

درک عوامل مؤثر بر قیمت مسکن نه تنها برای خریداران و فروشندگان ارزشمند است، بلکه برای سیاست گذاران، سرمایه گذاران و محققان اقتصادی نیز اهمیت بالایی دارد.

در این پروژه، مجموعه داده Ames Housing Dataset مورد تحلیل قرار گرفته است.

این مجموعه داده توسط Dean De Cock در سال 2011 منتشر شده و حاوی اطلاعات واقعی فروش 1,460 خانه در شهر Ames، ایالت Iowa آمریکا، بین سال های 2006 تا 2010 می باشد. این دیتاست با داشتن 80 ویژگی متنوع، یکی از جامع ترین مجموعه داده های حوزه مسکن محسوب می شود و جایگزین مدرن تری برای مجموعه داده معروف Boston Housing به شمار می رود.

هدف اصلی این پروژه پاسخ به سؤالات زیر از طریق تحلیل داده و مصورسازی است:

- کدام ویژگی های خانه بیشترین تأثیر را بر قیمت فروش دارند؟
- آیا موقعیت مکانی (محله) نقش تعیین کننده ای در قیمت گذاری دارد؟
- خانه های جدیدتر لزوماً گران تر هستند؟
- آیا بازار مسکن رفتار فصلی دارد؟
- آیا می توان خانه ها را بر اساس ویژگی هایشان به گروه های معنادار تقسیم کرد؟

برای پاسخ به این سؤالات، یک جریان کامل تحلیل داده طراحی و اجرا شده است که شامل پاکسازی داده، تحلیل اکتشافی (EDA)، مصورسازی پیشرفته و مدل سازی آماری می باشد. تمامی مراحل با استفاده از زبان برنامه نویسی Python و کتابخانه های Pandas، Matplotlib، Seaborn، Plotly و Scikit-learn پیاده سازی شده اند.

فهرست مطالب

Task 1: Data Understanding - معرفی و آشنایی با مجموعه داده

- معرفی متغیرها
- بارگذاری کتابخانه ها و داده ها
- نگاهی به داده ها
- آمار توصیفی
- توزیع قیمت فروش
- بررسی مقادیر گمشده
- توزیع نوع خانه و سبک معماری
- بررسی نرمال بودن توزیع (Q-Q Plot)
- قسمت به تفکیک کیفیت (Boxplot)
- رابطه ویژگی های کلیدی با قیمت (Scatter Plot)

Task 2: Data Cleaning - پاکسازی و آماده سازی داده ها

- ذخیره نسخه اصلی و بعد شروع پاکسازی
- پر کردن مقادیر گمشده
- حذف داده های پرت (Outlier)
- تبدیل نوع داده
- مقایسه قبل و بعد پاکسازی

Task 3: Exploratory Data Analysis (EDA) - تحلیل اکتشافی

- آمار توصیفی کامل
- توزیع ویژگی های عددی
- تأثیر کیفیت بر قیمت
- رابطه مساحت با قیمت
- تحلیل زمانی
- تأثیر ویژگی های دسته ای
- ماتریس پراکندگی ویژگی های برتر

Task 4: Data Visualization - مصورسازی داده ها

- رتبه بندی محله ها
- Bubble Chart کیفیت
- مقایسه violin قبل/بعد
- Heatmap محله * کیفیت
- تحلیل فصلی
- همبستگی نهایی

Task 5: Statistical Modeling - مدل سازی آماری

- رگرسیون خطی (Linear Regression)
- درخت تصمیم (Decision Tree)
- خوشه بندی (K-Means Clustering)

Conclusion – نتیجه گیری

• معرفی متغیرهای مجموعه داده Ames Housing :

مجموعه داده Ames Housing شامل 80 متغیر ورودی است که در شش گروه اصلی دسته بندی می شوند:

➤ مشخصات کلی ملک:

شامل نوع واحد مسکونی (MSSubClass)، زون بندی (MSZoning)، مساحت زمین (LotArea)، شکل زمین (LotShape)، شیب زمین (LandSlope) و نوع دسترسی به ملک (Street, Alley) می باشد.

➤ مشخصات فیزیکی ساختمان:

شامل نوع ساختمان (BldgType)، سبک معماری (HouseStyle)، سال ساخت (YearBuilt)، سال بازسازی (YearRemodAdd)، نوع سقف (RoofStyle, RoofMatl) و پوشش خارجی ساختمان (Exterior1st, Exterior2nd) است.

➤ کیفیت و وضعیت:

کیفیت کلی مصالح و اجرا در مقیاس 1 تا 10 (OverallQual)، وضعیت کلی ساختمان (OverallCond)، کیفیت نمای خارجی (ExterQual)، کیفیت آشپزخانه (KitchenQual) و کیفیت شومینه (FireplaceQu) در این گروه قرار دارند.

➤ مساحت ها:

شامل زیربنای طبقه اول و دوم (stFlrSF, 2ndFlrSF1)، زیربنای کل (GrLivArea)، مساحت زیرزمین (TotalBsmtSF) و مساحت گاراژ (GarageArea) است.

➤ امکانات:

شامل تعداد حمام (FullBath, HalfBath)، تعداد اتاق خواب (BedroomAbvGr)، تعداد شومینه (Fireplaces)، نوع گرمایش (Heating)، تهویه مرکزی (CentralAir)، استخر (PoolArea) و حصار (Fence) می باشد.

➤ اطلاعات فروش:

شامل ماه و سال فروش (MoSold, YrSold)، نوع سند (SaleType) و شرایط فروش (SaleCondition) است. فروش ها به شش دسته تقسیم می شوند: عادی (Normal)، غیرعادی (Abnormal)، خانوادگی (Family)، تخصیصی (Alloca)، مجاور (AdjLand) و ناتمام (Partial).

متغیر هدف: قیمت نهایی فروش ملک (SalePrice) بر حسب دلار آمریکا.

لینک دانلود data-description:

https://uploadkon.ir/uploads/e0dc15_26data-description.zip

• بارگذاری کتابخانه ها و داده ها:

```
# بارگذاری کتابخانه ها و داده ها
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.ticker as mticker
import matplotlib.font_manager as fm
import seaborn as sns
from scipy import stats
import subprocess

subprocess.run(['pip', 'install', 'arabic-reshaper', 'python-bidi'], capture_output=True)

import arabic_reshaper
from bidi.algorithm import get_display

def fa(text):
    reshaped = arabic_reshaper.reshape(text)
    return get_display(reshaped)

import warnings
warnings.filterwarnings('ignore')
plt.rcParams['figure.dpi'] = 120
plt.rcParams['figure.facecolor'] = 'white'
sns.set_style('whitegrid')
BLUE = '#378ADD'
GREEN = '#1D9E75'
ORANGE = '#D85A39'
PURPLE = '#7F77DD'
AMBER = '#BA7517'
PALETTE = [BLUE, GREEN, ORANGE, PURPLE, AMBER]

# بارگذاری دیتاست
df = pd.read_csv('/kaggle/input/datasets/saradehqani/house-prices/train.csv')
print(f'✓ دیتاست بارگذاری شد: {df.shape[0]} خانه، {df.shape[1]} ستون')
```

خروجی:

✓ دیتاست بارگذاری شد: 1460 خانه، 81 ستون

تحلیل:

Purpose: بارگذاری کتابخانه های مورد نیاز برای تحلیل داده و مصورسازی، و خواندن مجموعه داده

Ames Housing از منبع Kaggle

Main Findings: مجموعه داده با موفقیت بارگذاری شد و شامل 1460 نمونه (خانه) و 81

ستون است که 80 ستون ویژگی ورودی و 1 ستون متغیر هدف (SalePrice) می باشد.

کتابخانه های pandas و numpy برای پردازش داده، matplotlib و seaborn برای

مصورسازی، و scipy برای تحلیل آماری بارگذاری شدند.

Practical Interpretation: حجم 1460 نمونه برای انجام تحلیل های آماری معنادار کافی است.

تعداد بالای ویژگی ها (80 ویژگی) نشان می دهد که این دیتاست اطلاعات بسیار جامعی از ابعاد مختلف یک خانه ارائه می دهد (از مشخصات فیزیکی گرفته تا موقعیت مکانی و شرایط فروش، که امکان تحلیل های چند بعدی دقیق را فراهم می کند).

• نگاهی به داده ها:

```
# نگاه اول به داده ها . #2
# نمایش ۵ ردیف اول
df.head()
# ابعاد و نوع داده ها
print('=' * 50)
print(f'تعداد نمونه ها (خانه): {df.shape[0]}')
print(f'تعداد ویژگی ها: {df.shape[1] - 1} (+ 1 ستون هدف)')
print('=' * 50)
num_cols = df.select_dtypes(include='number').columns.drop(['Id', 'SalePrice']).tolist()
cat_cols = df.select_dtypes(include='object').columns.tolist()
print(f'ویژگی های عددی: {len(num_cols)}')
print(f'ویژگی های متنی: {len(cat_cols)}')
print(f'ستون هدف: SalePrice')
# اطلاعات کلی
df.info()
```

خروجی :

تعداد نمونه ها (خانه): 1460

تعداد ویژگی ها: 80 (+ 1 ستون هدف)

ویژگی های عددی: 36

ویژگی های متنی: 43

ستون هدف: SalePrice

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 1460 entries, 0 to 1459

Data columns (total 81 columns):

#	column	Non-Null count	Dtype		
0	Id	1460 non-null	int64		
1	MSSubClass	1460 non-null	int64		
2	MSZoning	1460 non-null	object		
3	LotFrontage	1201 non-null	float64		
4	LotArea	1460 non-null	int64		
5	Street	1460 non-null	object		

dtypes: float64(3), int64(35), object(43)

memory usage: 924.0+ KB

تحلیل :

Purpose: بررسی ساختار کلی دیتاست شامل ابعاد، نوع داده های هر ستون و شناسایی اولیه مقادیر گم شده پیش از شروع پاکسازی.

Main Findings: مجموعه داده شامل 1460 نمونه و 81 ستون است.

از میان ویژگی های ورودی، 36 ویژگی عددی (شامل 35 ستون int64 و 3 ستون float64) و 43 ویژگی دسته ای (object) وجود دارد. بررسی اولیه نشان داد که برخی ستون ها دارای مقادیر گم شده هستند (LotFrontage با 1201 مقدار غیر خالی از 1460 (یعنی 17.7٪ مقدار گم شده)، Alley با 91 مقدار غیر خالی (93.8٪ گم شده)، PoolQC با 7 مقدار غیر خالی (99.5٪ گم شده) و MasVnrType با 588 مقدار غیر خالی (59.7٪ گم شده)).

Practical Interpretation: وجود مقادیر گم شده زیاد در ستون هایی مثل PoolQC (99.5٪) و Alley (93.8٪) احتمالاً به این معناست که اکثر خانه ها اصلاً به استخر یا کوچه دسترسی ندارند یعنی این مقادیر گم شده در واقع نشان دهنده "ندارم" هستند (نه خطای داده)

این تفاوت مفهومی بسیار مهم است و در مرحله پاکسازی باید به درستی مدیریت شود.

همچنین وجود 43 ستون دسته ای نشان می دهد که بخش قابل توجهی از ویژگی ها کیفی هستند.

• آمار توصیفی:

```
# آمار توصیفی ستون هف. 3
sp = df['SalePrice']
print('آمار توصیفی SalePrice')
print('=' * 40)
print(f'کمترین قیمت:      ${sp.min():>10,.0f}')
print(f'چارک اول (Q1):      ${sp.quantile(0.25):>10,.0f}')
print(f'میانه:              ${sp.median():>10,.0f}')
print(f'میانگین:             ${sp.mean():>10,.0f}')
print(f'چارک سوم (Q3):      ${sp.quantile(0.75):>10,.0f}')
print(f'بیشترین قیمت:      ${sp.max():>10,.0f}')
print(f'انحراف معیار:         ${sp.std():>10,.0f}')
print(f'چولگی (Skewness):      {sp.skew():>10.2f} ← توزیع راست‌کج
```

خروجی:

آمار توصیفی SalePrice

=====

کمترین قیمت : \$ 34,900

چارک اول (Q1) : \$ 129,975

میانه : \$ 163,000

میانگین : \$ 180,921

چارک سوم (Q3) : \$ 214,000

بیشترین قیمت : \$ 755,000

انحراف معیار : \$ 79,443

چولگی (Skewness) : توزیع راست کج ← 1.88

تحلیل:

Purpose: استخراج و بررسی شاخص های آماری پایه متغیر هدف (SalePrice) برای درک توزیع قیمت ها و شناسایی ویژگی های کلیدی آن پیش از مصورسازی.

Main Findings: قیمت فروش خانه ها در این دیتاست بین 34,900 دلار تا 755,000 دلار متغیر است و بازه ای بسیار وسیع که نشان دهنده تنوع زیاد در بازار مسکن Ames است.

میانگین قیمت (180,921 دلار) به طور قابل توجهی از میانه (163,000 دلار) بالا تر است و این فاصله 17,921 دلاری نشان دهنده ی توزیع راست کج است.

فاصله بین چارک اول (129,975 دلار) و چارک سوم (214,000 دلار) که یعنی IQR برابر 84,025 دلار است، نشان می دهد 50 درصد میانی خانه ها در این بازه قیمتی قرار دارند.

انحراف معیار 79,443 دلاری، پراکندگی قابل توجه قیمت ها را تایید می کند و چولگی 1.88 هم به وضوح نشان دهنده توزیع راست کج است.

Practical Interpretation: توزیع راست کج با چولگی 1.88 به این معناست که اکثر خانه ها در محدوده قیمتی متوسط (100k \$ تا 200k \$) قرار دارند اما تعداد محدودی از خانه های لوکس با قیمت های بسیار بالا وجود دارند که میانگین را به سمت بالا کشیده اند.

از دید آماری، این چولگی در مدل سازی رگرسیون خطی مشکل ساز است زیرا اکثر الگوریتم های آماری فرض نرمال بودن توزیع متغیر هدف را دارند، به همین دلیل، در مراحل بعدی از تبدیل لگاریتمی $\log(\text{SalePrice}+1)$ برای نرمال سازی توزیع استفاده خواهد شد.

همچنین وجود IQR وسیع (84k \$) نشان دهنده این است که عوامل مختلفی مثل محله، کیفیت و مساحت می توانند تفاوت های قیمتی بسیار زیادی ایجاد کنند.

• توزیع قیمت فروش:

```
# 4. توزیع قیمت فروش (هیستوگرام)
fig, axes = plt.subplots(1, 2, figsize=(14, 5))


# --- هیستوگرام قیمت اصلی ---
ax = axes[0]
ax.hist(df['SalePrice'], bins=40, color=BLUE, edgecolor='white', linewidth=0.5)
ax.axvline(df['SalePrice'].mean(),
           color='#185FA5', linewidth=2, linestyle='--',
           label=f"میانگین: ${df['SalePrice'].mean():.0f}")

ax.axvline(df['SalePrice'].median(),
           color=GREEN, linewidth=2, linestyle='-',
           label=f"میانگین: ${df['SalePrice'].median():.0f}")
ax.set_title(f"توزیع قیمت فروش")
ax.set_xlabel(f"قیمت (دلار)")
ax.xaxis.set_major_formatter(mticker.FuncFormatter(lambda x, _ : f'${x/1000:.0f}K'))
ax.legend(fontsize=10)

# --- توزیع لگاریتمی ---
ax2 = axes[1]
log_price = np.log1p(df['SalePrice'])
ax2.hist(log_price, bins=40, color=GREEN, edgecolor='white', linewidth=0.5)
ax2.axvline(log_price.mean(),
            color='#0F6E56', linewidth=2, linestyle='--',
            label=f"میانگین: {log_price.mean():.2f}")
ax2.axvline(log_price.median(),
            color=BLUE, linewidth=2, linestyle='-',
            label=f"میانگین: {log_price.median():.2f}")
ax2.set_title(f"توزیع لگاریتم قیمت - log(SalePrice+1)")
ax2.set_xlabel('log(SalePrice + 1)', fontsize=11)
ax2.set_ylabel(f"تعداد خانه", fontsize=11)
ax2.legend(fontsize=10)

plt.suptitle(f"چولگی توزیع قیمت و اصلاح آن با تبدیل لگاریتمی", fontsize=14, y=1.02)
plt.tight_layout()
plt.show()
print(f'چولگی اصلی: {df["SalePrice"].skew():.2f} → log بعد از: {log_price.skew():.2f}')
```

خروجی:



log: 0.12 چولگی اصلی: 1.88 → بعد از

تحلیل:

Purpose: مصورسازی توزیع متغیر هدف SalePrice به دو صورت اصلی و لگاریتمی با هدف نمایش دیداری چولگی و ارزیابی اثربخش بودن تبدیل لگاریتمی در نرمال سازی توزیع.

Main Findings: نمودار سمت چپ که توزیع اصلی میباشد، به وضوح ماهیت راست کج توزیع را نشان می دهد، ستون های بلند در سمت چپ (قیمت های پایین تر) و دم بلند در سمت راست (قیمت های بالا). اکثر خانه ها در بازه \$ 100k تا \$ 200k متمرکزند و تعداد معاملات با افزایش قیمت به شدت کاهش می یابد.

خط چین آبی (میانگین 180,921 دلاری) نسبت به خط سبز (میانگین 163,000 دلاری) به سمت راست جابجا شده که این جابجایی 17,921 دلاری دقیقا به علت کشش خانه های لوکس است.

نمودار سمت راست که توزیع لگاریتمی میباشد، تحول خوبی را نشان می دهد، توزیع به شکل قابل توجهی متقارن تر شده، چولگی از 1.88 به 0.12 کاهش یافته و میانگین (12.02) و میانگین (12.00) تقریبا برابر شده اند.

Practical Interpretation: موفقیت تبدیل لگاریتمی در کاهش چولگی از 1.88 به 0.12 (کاهش 93.6 درصدی)، نشان می دهد که این تبدیل انتخاب مناسبی برای این دیتاست است.

در مدل سازی رگرسیون خطی، استفاده از $\log(\text{SalePrice})$ به عنوان متغیر هدف به جای SalePrice اصلی منجر به بهبود قابل توجه دقت مدل می شود.

از دید اقتصادی هم این الگوی توزیع نشان می دهد که بازار مسکن Ames عمدتاً یک بازار متوسط است با تعداد محدودی معامله در سطح لوکس.

• بررسی مقادیر گمشده

```
# 5. بررسی مقادیر گمشده (Missing Values)
# مقادیر گمشده در این دیتاست اگرچه به معنای «ندارم» هستند، نه خطای داده
missing = df.isnull().sum()
missing = missing[missing > 0].sort_values(ascending=False)
missing_pct = (missing / len(df) * 100).round(1)

missing_df = pd.DataFrame({'تعداد': missing, 'درصد': missing_pct})
print(f'تعداد ستون‌های دارای مقدار گمشده: {len(missing_df)}')
print()
print(missing_df.to_string())

fig, ax = plt.subplots(figsize=(10, 6))

colors = [ORANGE if p > 50 else AMBER if p > 20 else GREEN for p in missing_pct.values]
bars = ax.barh(missing_df.index, missing_df['درصد'], color=colors, edgecolor='white', linewidth=0.5)

for bar, pct in zip(bars, missing_df['درصد']):
    ax.text(bar.get_width() + 0.5, bar.get_y() + bar.get_height()/2,
            f'{pct}%', va='center', fontsize=9)


ax.axvline(50, color='gray', linestyle='--', linewidth=1, alpha=0.5, label='50%')
ax.set_xlabel(fa('درصد مقادیر گمشده'), fontsize=11)
ax.set_title(fa('مقادیر گمشده به تفکیک ستون'), fontsize=13, pad=12)
ax.set_xlim(0, 105)

from matplotlib.patches import Patch
legend_elements = [
    Patch(facecolor=ORANGE,
          label=f'بیش از 50٪ احتمالاً «ندارم»'),
    Patch(facecolor=AMBER,
          label=f'20 تا 50٪'),
    Patch(facecolor=GREEN,
          label=f'کمتر از 20٪ (قابل جبران)')
]
ax.legend(handles=legend_elements, fontsize=9, loc='lower right')
plt.tight_layout()
plt.show()
```

خروجی:

تعداد ستون‌های دارای مقدار گمشده: 19

تعداد	درصد	
PoolQC	1453	99.5
MiscFeature	1406	96.3
Alley	1369	93.8
Fence	1179	80.8
MasVnrType	872	59.7
FireplaceQu	690	47.3
LotFrontage	259	17.7
GarageType	81	5.5
GarageYrBlt	81	5.5
GarageFinish	81	5.5
GarageQual	81	5.5
GarageCond	81	5.5
BsmtExposure	38	2.6
BsmtFinType2	38	2.6
BsmtQual	37	2.5
BsmtCond	37	2.5
BsmtFinType1	37	2.5
MasVnrArea	8	0.5
Electrical	1	0.1



تحلیل:

Purpose: شناسایی و کمی سازی مقادیر گمشده در تمام ستون های دیتاست به منظور طراحی برنامه ریزی مناسب برای پاکسازی داده.

Main Findings: 19 ستون از 80 ستون ورودی، دارای مقدار گمشده هستند که در سه دسته تقسیم می شوند:

- دسته اول ستون هایی با بیش از 50% مقدار گمشده هستند که شامل PoolQC با 99.5%، MiscFeature با 96.3%، Alley با 93.8%، Fence با 80.8% و MasVnrType با 59.7%.
- دسته دوم ستون FireplaceQu با 47.3% مقدار گمشده است.
- دسته سوم ستون هایی با کمتر از 20% مقدار گمشده هستند که شامل LotFrontage با 17.7% و ستون های مربوط به گاراژ با 5.5% و زیرزمین با 2.5%.

Practical Interpretation: نکته مهم این است که اکثر مقادیر گمشده در این دیتاست به معنای واقعی "گمشده" نیستند، نشان دهنده "ندارم" هستند.

به عنوان مثال، PoolQC با 99.5% مقدار گمشده به این معناست که 99.5% خانه ها اصلا استخر ندارند، نه اینکه اطلاعات استخرشان ثبت نشده باشد. (این تفاوت مفهومی بسیار مهم است زیرا اگر این مقادیر را با

میانگین یا میانه پر کنیم، اطلاعات نادرستی وارد مدل می کنیم. راه حل درست جایگزینی با مقدار “None” یا 0 است. تنها ستون LotFrontage نیاز به عملکرد متفاوتی دارد چون عرض معبر در یک محله معمولاً شبیه است، پر کردن با میانه همان محله بهترین انتخاب است.

• توزیع نوع خانه و سبک معماری

```
# توزیع نوع خانه و سبک معماری 6.
fig, axes = plt.subplots(1, 3, figsize=(15, 5))


# --- نوع خانه ---
bldg_counts = df['BldgType'].value_counts()
axes[0].pie(bldg_counts.values, labels=bldg_counts.index, autopct='%1.1f%%',
            colors=PALETTE, startangle=140, textprops={'fontsize': 9})
axes[0].set_title(fa('نوع خانه'), fontsize=12)

# --- سبک معماری ---
style_counts = df['HouseStyle'].value_counts()
axes[1].barh(style_counts.index[::-1], style_counts.values[::-1],
             color=BLUE, edgecolor='white', linewidth=0.5)
for i, v in enumerate(style_counts.values[::-1]):
    axes[1].text(v + 5, i, str(v), va='center', fontsize=9)
axes[1].set_title(fa('سبک معماری (HouseStyle)'), fontsize=12)
axes[1].set_xlabel(fa('تعداد'))

# --- زون بندی ---
zone_counts = df['MSZoning'].value_counts()
axes[2].bar(zone_counts.index, zone_counts.values,
            color=PALETTE, edgecolor='white', linewidth=0.5)
for i, v in enumerate(zone_counts.values):
    axes[2].text(i, v + 10, str(v), ha='center', fontsize=9)
axes[2].set_title(fa('زون بندی (MSZoning)'), fontsize=12)
axes[2].set_ylabel(fa('تعداد'))

plt.suptitle(fa('ترکیب کلی خانه های دیتاست'), fontsize=14, y=1.02)
plt.tight_layout()
plt.show()
print(f'رایج ترین نوع خانه: {bldg_counts.index[0]} با {bldg_counts.iloc[0]} خانه ({bldg_counts.iloc[0]/len(df)*100:.0f}%)')
print(f'رایج ترین سبک معماری: {style_counts.index[0]} با {style_counts.iloc[0]} خانه')
```

خروجی:



رایج ترین نوع خانه: Fam1 با 1220 خانه (84%)

رایج ترین سبک معماری : Story1 با 726 خانه

تحلیل:

Purpose: بررسی توزیع فراوانی انواع خانه (BldgType)، سبک های معماری (HouseStyle) و زون بندی (MSZoning) برای درک ترکیب کلی بازار مسکن شهر Ames.

Main Findings: از نظر نوع خانه، 83.6٪ از کل نمونه ها (1220 خانه) از نوع تک خانواده مستقل (Fam1) هستند و مابقی شامل Townhouse End Unit با 7.8٪، Duplex با 3.6٪ و Two-Family Conversion با 2.1٪ سهم بسیار کمتری دارند.

از نظر سبک معماری، خانه های یک طبقه (Story1) با 726 نمونه (49.7٪) بیشترین سبک هستند و خانه های دو طبقه (Story2) با 445 نمونه (30.5٪) در رتبه دوم قرار دارند. از نظر زون بندی نیز اکثریت خانه ها (1151 نمونه، 78.8٪) در منطقه مسکونی کم تراکم (RL) قرار دارند.

Practical Interpretation: تمرکز بسیار بالای خانه های تک خانواده (83.6٪) نشان دهنده ماهیت مسکونی و آرام شهر Ames است که یک شهر دانشگاهی کوچک است.

این عدم توازن در توزیع نوع خانه (class imbalance) در مدل سازی باید در نظر قرار گیرد زیرا مدل ها ممکن است برای پیش بینی انواع کمتر مثل Duplex عملکرد ضعیف تری داشته باشند.

همچنین بهتر بودن زون بندی RL نشان می دهد که این دیتاست عمدتاً نماینده بازار مسکن مناطق مسکونی کم تراکم است و نتایج آن را ممکن است نتوانیم برای مناطق تجاری یا صنعتی تعمیم بدهیم.

• بررسی نرمال بودن (Q-Q Plot)

```
# 7. Q-Q Plot (بررسی نرمال بودن)
fig, axes = plt.subplots(1, 2, figsize=(12, 5))


# Q-Q plot قیمت اصلی
stats.probplot(df['SalePrice'], dist="norm", plot=axes[0])
axes[0].set_title(fa('Q-Q Plot - SalePrice اصلی'), fontsize=13)
axes[0].get_lines()[0].set(color=BLUE, markersize=3, alpha=0.5)
axes[0].get_lines()[1].set(color=ORANGE, linewidth=2)

# Q-Q plot لگاریتمی
stats.probplot(np.log1p(df['SalePrice']), dist="norm", plot=axes[1])
axes[1].set_title('Q-Q Plot - log(SalePrice)', fontsize=13)
axes[1].get_lines()[0].set(color=GREEN, markersize=3, alpha=0.5)
axes[1].get_lines()[1].set(color=ORANGE, linewidth=2)

plt.suptitle(fa('بررسی نرمال بودن توزیع قیمت'), fontsize=14, y=1.02)
plt.tight_layout()
plt.show()

# تست آماری
stat, p = stats.shapiro(df['SalePrice'].sample(200, random_state=42))
print(f'Shapiro-Wilk Test: p-value = {p:.6f}')
print(f'→ توزیع نرمال نیست if p < 0.05 else → توزیع نرمال است')
print()
stat2, p2 = stats.shapiro(np.log1p(df['SalePrice'].sample(200, random_state=42)))
print(f'Shapiro-Wilk (log): p-value = {p2:.6f}')
print(f'→ هنوز نرمال نیست if p2 > 0.05 else → تبدیل به نرمال شد log بعد از')
```

خروجی:



Shapiro-Wilk Test: p-value = 0.000000 → توزیع نرمال نیست

Shapiro-Wilk (log): p-value = 0.003319 → هنوز نرمال نیست

تحلیل:

Purpose: ارزیابی آماری انطباق توزیع SalePrice با توزیع نرمال از طریق نمودار Quantile-Quantile و تست Shapiro-Wilk، و مقایسه آن با نسخه لگاریتمی.

Main Findings: در نمودار Q-Q Plot، اگر داده ها از توزیع نرمال پیروی کنند، تمام نقاط باید روی خط قرمز قرار گیرند.

نمودار سمت چپ (SalePrice اصلی) نشان می دهد که نقاط در ناحیه چپ یعنی چارک های پایین، زیر خط و در ناحیه راست یعنی چارک های بالا، به شدت بالای خط قرار گرفته اند و این الگوی انحراف رایج توزیع راست کج است.

تست آماری Shapiro-Wilk با p-value برابر 0.0000 فرض صفر نرمال بودن را با قاطعیت رد می کند. نمودار سمت راست ($\log(\text{SalePrice})$) بهبود خوبی را نشان می دهد به صورتی که نقاط به مراتب نزدیک تر به خط قرمز قرار گرفته اند (هرچند p-value برابر 0.003 نشان می دهد که حتی پس از تبدیل لگاریتمی، توزیع کاملاً نرمال نیست).

Practical Interpretation: نتیجه تست Shapiro-Wilk برای SalePrice اصلی ($p=0.000000$) یعنی احتمال اینکه این داده ها از توزیع نرمال باشند کلاً صفر است.

p-value برابر با 0.003 برای نسخه لگاریتمی هنوز کمتر از آستانه 0.05 است اما این موضوع در عمل مشکل جدی ای ایجاد نمی کند زیرا با حجم نمونه بزرگ ($n=1460$)، تست Shapiro-Wilk بسیار حساس است و حتی انحرافات بسیار کوچک از نرمال را تشخیص می دهد.

نمودار Q-Q Plot نشان می دهد که نسخه لگاریتمی برای اهداف مدل سازی به اندازه کافی به توزیع نرمال نزدیک است و استفاده از آن در رگرسیون خطی دلیل آماری دارد.


• **قیمت به تفکیک کیفیت (Boxplot)**

```
# قیمت به تفکیک کیفیت
fig, ax = plt.subplots(figsize=(10, 5))

qual_order = sorted(df['OverallQual'].unique())
sns.boxplot(data=df, x='OverallQual', y='SalePrice', order=qual_order,
            palette='Blues', ax=ax)
ax.set_title(fa('قیمت به تفکیک کیفیت کلی'), fontsize=13)
ax.set_xlabel(fa('کیفیت کلی (1=ضعیف تا 10=عالی)'), fontsize=11)
ax.set_ylabel(fa('قیمت فروش (دلار)'), fontsize=11)
ax.yaxis.set_major_formatter(mticker.FuncFormatter(lambda x, _: f'${x/1000:.0f}K'))
plt.tight_layout()
plt.show()

print('میان قیمت به تفکیک کیفیت:')
print(df.groupby('OverallQual')['SalePrice'].median().apply(lambda x: f'${x:.0f}').to_string())
```

خروجی:



میان قیمت به تفکیک کیفیت:

	OverallQual
1	\$ 50,150
2	\$ 60,000
3	\$ 86,250
4	\$ 108,000
5	\$ 133,000
6	\$ 160,000
7	\$ 200,141
8	\$ 269,750
9	\$ 345,000
10	\$ 432,390

تحلیل:

Purpose: بررسی رابطه بین کیفیت کلی خانه (OverallQual) و قیمت فروش از طریق نمودار Boxplot که علاوه بر میانه، پراکندگی و outlier هر گروه را نیز نمایش می دهد.

Main Findings: نمودار Boxplot رابطه یکنواخت و صعودی واضحی بین کیفیت و قیمت نشان می دهد.

میانه قیمت از 50,150 دلار در کیفیت 1 به 432,390 دلار در کیفیت 10 رسیده (افزایشی برابر 8.6).

نکته مهم تر این است که پراکندگی قیمت (ارتفاع جعبه یا IQR) با افزایش کیفیت، بیشتر می شود (IQR برای کیفیت 7 تا 10 بسیار وسیع تر از کیفیت 1 تا 4 است. همچنین outlier ها در سطوح کیفیت 5 تا 10 مشاهده می شوند)

ضریب همبستگی پیرسون بین OverallQual و SalePrice برابر 0.79 است که قوی ترین همبستگی در کل دیتاست است.

Practical Interpretation: رابطه 0.79 بین کیفیت و قیمت نشان می دهد که OverallQual قوی ترین قدرت پیش بینی قیمت در این دیتاست را دارد.

افزایش هر سطح کیفیت به طور میانگین 14,800 دلار به قیمت اضافه می کند (بر طبق ضریب رگرسیون خطی که در بخش مدل سازی به دست آمد).

افزایش پراکندگی قیمت در سطوح کیفیت بالا نشان می دهد که در خانه های لوکس، عوامل دیگری مانند محله و مساحت نقش تعیین کننده تری دارند یعنی کیفیت بالا شرط لازم است اما کافی نیست.

وجود outlier در سطح کیفیت 5 و 6 احتمالاً مربوط به خانه هایی در محله های بسیار گران قیمت است که با وجود کیفیت متوسط، قیمت بالایی دارند.

• ویژگی های کلیدی (Scatter Plot)

```
# 9. ویژگی‌های کلیدی Scatter Plot
fig, axes = plt.subplots(2, 2, figsize=(13, 10))

pairs = [
    ('GrLivArea', fa('زیربنا (فوت مربع)'),
    ('TotalBsmtSF', fa('مساحت زیرزمین (فوت مربع)'),
    ('GarageArea', fa('مساحت گاراژ (فوت مربع)'),
    ('YearBuilt', fa('سال ساخت')),
]


for ax, (col, label) in zip(axes.flatten(), pairs):
    ax.scatter(df[col], df['SalePrice'] / 1000,
              alpha=0.4, s=15, color=BLUE, edgecolors='none')

    # خط رگرسیون
    mask_valid = df[col].notna()
    z = np.polyfit(df.loc[mask_valid, col], df.loc[mask_valid, 'SalePrice'] / 1000, 1)
    p_line = np.poly1d(z)
    x_line = np.linspace(df[col].min(), df[col].max(), 100)
    ax.plot(x_line, p_line(x_line), color=ORANGE, linewidth=2, label=fa('خط رگرسیون'))

    r = df[[col, 'SalePrice']].corr().iloc[0, 1]
    ax.set_title(f'{col} (r = {r:.2f})', fontsize=12)
    ax.set_xlabel(label, fontsize=10)
    ax.set_ylabel(fa('قیمت (هزار دلار)'), fontsize=10)
    ax.legend(fontsize=9)

plt.suptitle(fa('رابطه ویژگی‌های کلیدی با قیمت فروش'), fontsize=14, y=1.01)
plt.tight_layout()
plt.show()
```

خروجی:



تحلیل:

Purpose: بررسی تصویری رابطه خطی بین چهار ویژگی مهم عددی (GrLivArea, TotalBsmtSF, GarageArea, YearBuilt) و قیمت فروش، همراه با خط رگرسیون برای کمی سازی این رابطه.

:Main Findings

GrLivArea با ضریب همبستگی $r=0.71$ قوی ترین رابطه مساحتی با قیمت را دارد؛

خط رگرسیون نشان می دهد به ازای هر 100 فوت مربع افزایش زیربنا، قیمت به طور میانگین 9,000 دلار افزایش می یابد.

TotalBsmtSF با $r=0.61$ رابطه مثبت قابل توجهی دارد اما تجمع نقاط در مساحت صفر (خانه های بدون زیرزمین) توزیع را غیرخطی می کند.

GarageArea با $r=0.62$ رابطه مثبتی نشان می دهد و تجمع نقاط در صفر مربوط به خانه های بدون گاراژ است.

YearBuilt با $r=0.52$ ضعیف ترین رابطه را دارد و پراکندگی زیاد نقاط در خانه های قدیمی تر نشان دهنده تأثیر عوامل دیگر مثل بازسازی است.

Practical Interpretation: وجود چند نقطه پرت در نمودار GrLivArea (خانه هایی با زیربنای بالای 4000 فوت مربع اما قیمت پایین) نشان می دهد که زیربنای بسیار بزرگ به تنهایی قیمت بالا را تضمین نمی کند و عوامل دیگری مثل محله و کیفیت ساخت، نقش تعیین کننده دارند، این نقاط پرت در مرحله پاکسازی با روش IQR حذف شدند.

رابطه ضعیف تر (YearBuilt $r=0.52$) نسبت به مساحت ها نشان می دهد که سن خانه به تنهایی نمیتواند قدرت پیش بینی قوی ای داشته باشد و یک خانه قدیمی بازسازی شده می تواند ارزش بالاتری نسبت به خانه جدید ارزان ساز داشته باشد.

• ذخیره نسخه اصلی و بعد شروع پاکسازی

```
# ذخیره نسخه اصلی + شروع پاکسازی 1.  
df_raw = df.copy()  
df_clean = df.copy()  
print(f'✅ نسخه اصلی ذخیره شد: {df_raw.shape}')
```

خروجی:

نسخه اصلی ذخیره شد: (1460, 81)

تحلیل:

Purpose: پیش از اعمال هرگونه تغییر بر روی داده ها، یک نسخه کامل از دیتاست اصلی تحت نام df_raw ذخیره می شود تا در مراحل بعدی امکان مقایسه قبل و بعد از پاکسازی فراهم باشد و در صورت نیاز بتوان به داده های اولیه بازگشت.

Main Findings: نسخه اصلی دیتاست با ابعاد (1460, 81) با موفقیت ذخیره شد. این نسخه شامل تمام 1460 نمونه و 81 ستون بدون هیچ گونه تغییری است.

Practical Interpretation: ذخیره نسخه اصلی یکی از اصول بنیادین در علم داده است.

این کار به علت اینکه باعث میشود بتوان تاثیر پاکسازی را به صورت کمی مقایسه کرد و همچنین به علت اینکه اگر پاکسازی بیش از حد باشد و داده های مفیدی حذف شوند میتواند کمک کند به داده های اصلی بازگردیم و کمک میکند بتوانیم در مرحله دیداری سازی تاثیر پاکسازی را به صورت دیداری و مقایسه ای نشان بدهیم در این پروژه انجام شد.

• پر کردن مقادیر گم شده

```
# 2. missing values پر کردن
# پر می‌شوند None یعنی «ندارم» - با NA ستون‌هایی که
none_cols = ['PoolQC', 'MiscFeature', 'Alley', 'Fence',
              'FireplaceQu', 'GarageType', 'GarageFinish',
              'GarageQual', 'GarageCond', 'BsmtQual', 'BsmtCond',
              'BsmtExposure', 'BsmtFinType1', 'BsmtFinType2', 'MasVnrType']

for col in none_cols:
    df_clean[col] = df_clean[col].fillna('None')

# ستون‌های عددی گاراژ - با 0 پر می‌شوند
zero_cols = ['GarageYrBlt', 'GarageArea', 'GarageCars',
              'BsmtFinSF1', 'BsmtFinSF2', 'BsmtUnfSF',
              'TotalBsmtSF', 'BsmtFullBath', 'BsmtHalfBath', 'MasVnrArea']

for col in zero_cols:
    df_clean[col] = df_clean[col].fillna(0)

# LotFrontage - میانگین همون محله پر می‌شه
df_clean['LotFrontage'] = df_clean.groupby('Neighborhood')['LotFrontage']\
    .transform(lambda x: x.fillna(x.median()))

# Electrical - با مد پر می‌شه NA فقط (با)
df_clean['Electrical'] = df_clean['Electrical'].fillna(df_clean['Electrical'].mode()[0])

# چک کردن نتیجه
remaining = df_clean.isnull().sum().sum()
print(f'مقادیر گمشده قبل از پاکسازی: {df_raw.isnull().sum().sum()}')
print(f'مقادیر گمشده بعد از پاکسازی: {remaining}')
```

خروجی:

مقادیر گمشده قبل از پاکسازی: 7829

مقادیر گمشده بعد از پاکسازی: 0

تحلیل:

Purpose: رفع مقادیر گمشده 19 ستون دیتاست با استفاده از سه راهکار متفاوت بر اساس ماهیت هر ستون، به طریقی که اطلاعات واقعی داده حفظ شود و هیچ اطلاعات نادرستی وارد مدل نشود.

Main Findings: در مجموع 7829 مقدار گمشده در دیتاست وجود داشت که با سه روش متفاوت پر شدند.

روش اول: ستون‌هایی که NA در آن‌ها به معنای "ندارم" است (PoolQC، MiscFeature، Alley، Fence، FireplaceQu و ستون‌های گاراژ و زیرزمین) با مقدار "None" یا 0 جایگزین شدند.

روش دوم: ستون LotFrontage که نشان دهنده عرض معبر است با میانگین همان محله پر شد زیرا عرض معبر در یک محله معمولاً شبیه است و این روش قابل قبول‌ترین تخمین است.

روش سوم: ستون Electrical که تنها 1 مقدار گمشده داشت، با مد که رایج ترین مقدار است، جایگزین شد.

پس از اعمال این تغییرات، تعداد مقادیر گمشده از 7829 به 0 رسید.

Practical Interpretation: استفاده از سه راهکار متفاوت به جای یک روش یکسان برای همه ستون ها نشان دهنده درک عمیق تر از ماهیت داده است.

جایگزینی NA با "None" برای ستون هایی مثل PoolQC از یک خطای جلوگیری می کند، اگر این مقادیر را با میانگین پر می کردیم، به مدل می گفتیم خانه هایی که اصلاً استخر ندارند، استخری با کیفیت متوسط دارند، که این نادرست است.

پر کردن LotFrontage با میانگین محله نیز از دانش دامین (domain knowledge) استفاده می کند، خانه های یک محله معمولاً در خیابان هایی با عرض مشابه قرار دارند.

• حذف داده های پرت (Outlier)

```
# 3. حذف Outlier
# شناسایی outlier با IQR روی GrLivArea و SalePrice
def remove_outliers_iqr(data, col, factor=1.5):
    Q1 = data[col].quantile(0.25)
    Q3 = data[col].quantile(0.75)
    IQR = Q3 - Q1
    lower = Q1 - factor * IQR
    upper = Q3 + factor * IQR
    return data[(data[col] >= lower) & (data[col] <= upper)]

before = len(df_clean)
df_clean = remove_outliers_iqr(df_clean, 'GrLivArea')
df_clean = remove_outliers_iqr(df_clean, 'SalePrice')
after = len(df_clean)

print(f'outlier: {before} تعداد قبل از حذف')
print(f'outlier: {after} تعداد بعد از حذف')
print(f'تعداد ردیف حذف شده: {before - after}')
```

خروجی:

تعداد قبل از حذف outlier : 1460

تعداد بعد از حذف outlier : 1373

تحلیل:

Purpose: شناسایی و حذف داده های پرت (outlier) از دیتاست با استفاده از روش IQR (Interquartile Range) روی دو ستون GrLivArea و SalePrice، به منظور بهبود کیفیت داده و افزایش دقت مدل سازی.

Main Findings: روش IQR برای هر ستون بازه مجاز $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$ را محاسبه کرده و هر مقداری خارج از این بازه را به عنوان outlier شناسایی کرد.

برای SalePrice، کران بالایی برابر 340,037 دلار محاسبه شد.

برای GrLivArea نیز مقادیر بالای 2776 فوت مربع به عنوان outlier شناسایی شدند.

در نتیجه ی این عملیات، 87 ردیف (5.9٪ از کل داده ها) حذف شدند و تعداد نمونه ها از 1460 به 1373 کاهش یافت.

Practical Interpretation: حذف 5.9٪ از داده ها توانست تناسب خوبی بین حفظ حجم داده و بهبود کیفیت آن ایجاد کند.

انتخاب روش IQR به جای روش های مبتنی بر میانگین و انحراف معیار (مثل z-score) بهتر است زیرا داده های پرت، خود میانگین را جابجا می کنند و این روش ها را ناپایدار می کنند، در حالی که IQR به عنوان یک معیار مقاوم (robust) تحت تأثیر outlier قرار نمی گیرد.

همچنین اعمال روش IQR روی GrLivArea باعث حذف چند خانه با زیر بنای بسیار بالا (بالای 4000 فوت مربع) اما با قیمت پایین شد، که احتمال دارد ناشی از خطای ثبت داده یا شرایط خاص فروش بوده باشند.

• تبدیل نوع داده

```
# تبدیل نوع داده 4.
# MSSubClass عددیه ولی باید categorical باشه
df_clean['MSSubClass'] = df_clean['MSSubClass'].astype(str)
df_raw['MSSubClass'] = df_raw['MSSubClass'].astype(str)

print('✅ MSSubClass به string تبدیل شد')
```

خروجی:

MSSubClass به string تبدیل شد.

تحلیل:

Purpose: اصلاح نوع داده ستون MSSubClass از عددی (int64) به دسته ای (string)، چون این ستون کد های نوع خانه را نشان می دهد و ماهیت دسته ای دارد نه عددی.

Main Findings: ستون MSSubClass که کد نوع خانه را نشان می دهد (مثلا کد 60 یعنی خانه دو طبقه ساخته شده بعد از 1946)، به اشتباه به صورت عددی (int64) ذخیره شده بود.

این ستون هم در df_clean و هم در df_raw به نوع string تبدیل شد.

Practical Interpretation: این تبدیل از یک خطای رایج در مدل سازی جلوگیری می کند.

اگر MSSubClass به صورت عددی در مدل استفاده شود، الگوریتم فرض می کند که کد 160 دو برابر کد 80 است، در حالی که این اعداد فقط کد هستند و هیچ رابطه کمی با یکدیگر ندارند.

با تبدیل به string، در مرحله مدل سازی این ستون به درستی به صورت دسته ای (categorical) با استفاده از Label Encoding یا One-Hot Encoding پردازش خواهد شد.

• مقایسه قبل و بعد پاکسازی


```
# 5. مقایسه قبل و بعد پاکسازی
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# قبل از پاکسازی
axes[0].hist(df_raw['SalePrice'], bins=40, color=ORANGE, edgecolor='white', linewidth=0.5)
axes[0].set_title(fa('توزیع قیمت - قبل از پاکسازی'), fontsize=13)
axes[0].set_xlabel(fa('قیمت (دلار)'), fontsize=11)
axes[0].set_ylabel(fa('تعداد خانه'), fontsize=11)
axes[0].xaxis.set_major_formatter(mticker.FuncFormatter(lambda x, _: f'$({x/1000:.0f})K'))
axes[0].set_title(axes[0].get_title() + f'\n(n={len(df_raw)})', fontsize=12)

# بعد از پاکسازی
axes[1].hist(df_clean['SalePrice'], bins=40, color=GREEN, edgecolor='white', linewidth=0.5)
axes[1].set_title(fa('توزیع قیمت - بعد از پاکسازی'), fontsize=13)
axes[1].set_xlabel(fa('قیمت (دلار)'), fontsize=11)
axes[1].set_ylabel(fa('تعداد خانه'), fontsize=11)
axes[1].xaxis.set_major_formatter(mticker.FuncFormatter(lambda x, _: f'$({x/1000:.0f})K'))
axes[1].set_title(axes[1].get_title() + f'\n(n={len(df_clean)})', fontsize=12)

plt.suptitle(fa('مقایسه توزیع قیمت قبل و بعد از پاکسازی'), fontsize=14, y=1.02)
plt.tight_layout()
plt.show()


# مقایسه outlier - scatter plot
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

axes[0].scatter(df_raw['GrLivArea'], df_raw['SalePrice']/1000,
                alpha=0.4, s=15, color=ORANGE)
axes[0].set_title(fa('قیمت - قبل vs زیربنا'), fontsize=12)
axes[0].set_xlabel(fa('زیربنا (فوت مربع)'), fontsize=11)
axes[0].set_ylabel(fa('قیمت (هزار دلار)'), fontsize=11)

plt.suptitle(fa('مقایسه Outlier قبل و بعد از پاکسازی'), fontsize=14, y=1.02)
plt.tight_layout()
plt.show()

print(f'خلاصه پاکسازی:')
print(f'مقادیر گمشده: {df_raw.isnull().sum().sum()} → {df_clean.isnull().sum().sum()}')
print(f'تعداد ردیفها: {len(df_raw)} → {len(df_clean)}')
print(f'تبدیل شد categorical به MSSubClass')
```

خروجی:



خلاصه پاکسازی:

- مقادیر گمشده: 0 → 7829
- تعداد ردیفها: 1373 → 1460

• MSSubClass به categorical تبدیل شد

تحلیل:

Purpose: به تصویر کشیدن تاثیر مراحل پاکسازی از طریق مقایسه بصری توزیع قیمت و رابطه زیربنا،

قیمت قبل و بعد از پاکسازی، به منظور ارزیابی کمی و کیفی تاثیر تصمیمات پاکسازی.

Main Findings: نمودار هیستوگرام، تفاوت را به خوبی نشان می دهد.

قبل از پاکسازی (نمودار نارنجی، $n=1460$)، توزیع دم بلندی تا \$ 700k دارد و چند خانه با قیمت بالای \$ 600k مشاهده می شود.

بعد از پاکسازی (نمودار سبز، $n=1373$)، بازه قیمتی در محدوده ی \$ 50k تا \$ 320k کم شده و توزیع متعادل تری دارد.

نمودار Scatter Plot، تاثیر حذف outlier را بر رابطه زیربنا/قیمت نشان می دهد؛ قبل از پاکسازی، چند نقطه پرت با زیربنای بالای 4000 فوت مربع و قیمت های بسیار بالا وجود دارند که رابطه خطی را مخدوش می کنند.

بعد از پاکسازی، رابطه خطی بسیار واضح تر و منظم تر شده است.

• آمار توصیفی کامل

```
# آمار توصیفی کامل 1.  
print('== آمار توصیفی ویژگی های عددی ==')  
df_clean[num_cols].describe().round(2)
```

خروجی:

=== آمار توصیفی ویژگی های عددی ===

	LotFrontage	LotArea	OverallQual	OverallCond	YearBuilt	YearRemodAdd
count	1373	1373	1373	1373	1373	1373
mean	68.75	10021.9	5.95	5.59	1970.07	1983.85
std	20.62	8197.74	1.26	1.11	29.82	20.72
min	21	1300	1	1	1872	1950
0.25	60	7399	5	5	1953	1965
0.5	70	9245	6	5	1971	1992
0.75	80	11248	7	6	1999	2003
max	313	164660	10	9	2009	2010

تحلیل:

Purpose: محاسبه و بررسی شاخص های آماری پایه برای تمام 35 ویژگی عددی دیتاست پاکسازی شده برای درک کلی از توزیع، پراکندگی و دامنه هر ویژگی پیش از تحلیل های عمیق تر.

Main Findings: پس از پاکسازی، دیتاست نهایی شامل 1373 نمونه و 35 ویژگی عددی است.

مهم ترین نتایج از جدول آمار توصیفی:

میانگین کیفیت کلی (OverallQual) 5.95 از 10 است که نشان دهنده تمرکز خانه ها در سطح کیفیت متوسط رو به بالاست.

میانگین سال ساخت 1970 و میانگین سال بازسازی 1983 است که فاصله 13 ساله بین آن ها نشان می دهد بسیاری از خانه ها پس از ساخت باز سازی شده اند.

میانگین مساحت زمین (LotArea) برابر 10022 فوت مربع با انحراف معیار 8198 است که پراکندگی بسیار زیادی را نشان می دهد.

میانگین مساحت گاراژ 454 فوت مربع و میانگین مساحت زیرزمین تکمیل شده 407 فوت مربع است.

حداکثر LotArea برابر 164660 فوت مربع در مقابل میانه 9245 فوت مربع نشان دهنده وجود زمین های بسیار بزرگ در دیتاست است.

Practical Interpretation: فاصله بزرگ بین میانگین و میانه در ستون LotArea (میانگین 10022 در مقابل میانه 9245) و انحراف معیار بالای 8198 نشان می دهد که این ویژگی هنوز دارای چولگی قابل توجهی است و outlier های بزرگ در آن باقی مانده اند، این موضوع توضیح می دهد که چرا همبستگی LotArea با SalePrice نسبتاً پایین ($r=0.26$) است (یک زمین بسیار بزرگ در یک محله ارزان قیمت لزوماً قیمت بالایی ندارد).

همچنین فاصله ۱۳ ساله بین میانگین سال ساخت (1970) و سال بازسازی (1983) نشان می دهد که بازسازی معمولاً حدود یک دهه پس از ساخت انجام می شود که با چرخه های معمول نوسازی مسکن همخوانی دارد.

• توزیع ویژگی های عددی


```
# توزیع ویژگی های عددی مهم - 2.
important_num = ['SalePrice', 'GrLivArea', 'TotalBsmstSF',
                 'LotArea', 'GarageArea', 'YearBuilt']

fig, axes = plt.subplots(2, 3, figsize=(15, 10))

for ax, col in zip(axes.flatten(), important_num):
    skew = df_clean[col].skew()
    ax.hist(df_clean[col], bins=35, color=BLUE, edgecolor='white', linewidth=0.5, alpha=0.85)
    ax.axvline(df_clean[col].mean(), color=ORANGE, linewidth=2, linestyle='--', label=f'میانگین')
    ax.axvline(df_clean[col].median(), color=GREEN, linewidth=2, linestyle='-', label=f'میانه')
    ax.set_title(f'{col}\nskewness = {skew:.2f}', fontsize=11)
    ax.legend(fontsize=8)
    ax.set_ylabel(f'تعداد', fontsize=9)

plt.suptitle(f'توزیع ویژگی های عددی مهم', fontsize=14, y=1.02)
plt.tight_layout()
plt.show()
```

خروجی:



تحلیل:

Purpose: بررسی شکل توزیع شش ویژگی عددی مهم (SalePrice, GrLivArea, TotalBsmtSF, LotArea, GarageArea, YearBuilt) از طریق هیستوگرام همراه با خطوط میانگین و میانه، برای شناسایی چولگی و ارزیابی نیاز به تبدیل داده.

Main Findings: هر شش ویژگی، الگوی توزیع متفاوتی دارند.

SalePrice با skewness=0.64 پس از حذف outlier توزیع بهتری نسبت به قبل (skewness=1.88) دارد.

GrLivArea با skewness=0.45 نسبتاً متقارنی دارد با تمرکز در بازه 1000 تا 1500 فوت مربع.

TotalBsmtSF با skewness=0.22 نزدیک ترین توزیع به نرمال در بین ویژگی‌های مساحتی است.

LotArea با $skewness=11.72$ شدید ترین چولگی را دارد (اکثر زمین ها کوچک هستند اما چند زمین بسیار بزرگ وجود دارد).

GarageArea با $skewness=0.05$ تقریبا توزیع نرمال دارد با این تفاوت که تجمع نقاط در صفر مربوط به خانه های بدون گاراژ است.

YearBuilt با $skewness=-0.56$ توزیع چپ کج دارد یعنی خانه های جدید تر (دهه 1970 به بعد) بیشتر هستند.

Practical Interpretation: تنوع در شکل توزیع ویژگی ها اهمیت بالایی در مدل سازی دارد.

LotArea با $skewness=11.72$ به تبدیل لگاریتمی نیاز دارد (خیلی زیاد) چون بدون این تبدیل، این ویژگی در مدل رگرسیون خطی مدل را خراب میکند.

چپ کج بودن (YearBuilt ($skewness=-0.56$) نشان می دهد که بازار مسکن Ames در دوره 2006 تا 2010 بیشتر شامل خانه های ساخته شده در دهه های اخیر بوده است که با رشد شهری پس از جنگ دوم جهانی همخوانی دارد.

همگرایی میانگین و میانه در GarageArea و TotalBsmtSF نشان می دهد که این ویژگی ها توزیع نسبتا متقارنی دارند و می توان آن ها را بدون تبدیل وارد مدل کرد.

• تأثیر کیفیت بر قیمت

```
# تأثیر کیفیت کلی روی قیمت 3.
fig, axes = plt.subplots(1, 2, figsize=(14, 5))


# میانگین قیمت به تفکیک کیفیت
qual_mean = df_clean.groupby('OverallQual')['SalePrice'].mean() / 1000
axes[0].bar(qual_mean.index, qual_mean.values, color=PALETTE * 2, edgecolor='white')
for i, (q, v) in enumerate(qual_mean.items()):
    axes[0].text(q, v + 2, f'${v:.0f}K', ha='center', fontsize=8)
axes[0].set_title(fa('میانگین قیمت به تفکیک کیفیت کلی'), fontsize=12)
axes[0].set_xlabel(fa('کیفیت (1 تا 10)'), fontsize=11)
axes[0].set_ylabel(fa('میانگین قیمت (هزار دلار)'), fontsize=11)

# boxplot
sns.boxplot(data=df_clean, x='OverallQual', y='SalePrice',
            palette='Blues', ax=axes[1])
axes[1].set_title(fa('توزیع قیمت به تفکیک کیفیت'), fontsize=12)
axes[1].set_xlabel(fa('کیفیت کلی'), fontsize=11)
axes[1].set_ylabel(fa('قیمت فروش (دلار)'), fontsize=11)
axes[1].yaxis.set_major_formatter(mticker.FuncFormatter(lambda x, _ : f'${x/1000:.0f}K'))

plt.tight_layout()
plt.show()

print('نتیجه: با افزایش هر سطح کیفیت، قیمت به طور میانگین:')
diffs = qual_mean.diff().dropna()
print(f'حدافل افزایش: ${diffs.min():.0f}K')
print(f'حداکثر افزایش: ${diffs.max():.0f}K')
```

خروجی:



نتیجه: با افزایش هر سطح کیفیت، قیمت به طور میانگین:

حدافل افزایشی که یافته: \$ 2k

حداکثر افزایشی که یافته: \$ 52k

تحلیل:

Purpose: تحلیل کمی رابطه بین OverallQual و SalePrice از طریق دو نمودار که کامل کننده ی همدیگر هستند (Bar Chart برای نمایش میانگین قیمت هر سطح و Boxplot برای نمایش توزیع کامل قیمت در هر سطح کیفیتی)

Bar Chart : Main Findings، میانگین قیمت به تفکیک کیفیت را نشان می دهد که رابطه پله ای و یکنواختی بین کیفیت و قیمت وجود دارد (از \$ 50k در کیفیت 1 تا \$ 310k در کیفیت 10) که حداقل افزایش بین دو سطح متوالی \$ 2k (بین کیفیت 1 و 2) و حداکثر آن \$ 52k (بین کیفیت 7 و 8) است.

Boxplot توزیع قیمت در هر سطح را نشان می دهد و یک الگوی مهم را نشان میدهد:

پراکندگی قیمت (ارتفاع جعبه) در سطوح کیفیت 7 تا 10 بیشتر از سطوح پایین تر است.

همچنین outlier در سطوح 5 تا 10 نیز مشاهده می شوند.

Practical Interpretation: افزایش ناگهانی \$ 52k بین کیفیت 7 و 8 یک نقطه شکست (breakpoint)

مهم در بازار مسکن Ames است (خانه هایی که از کیفیت "خوب" به "خیلی خوب" پیشرفت میکنند، جهش قیمتی قابل توجهی تجربه می کنند).

افزایش پراکندگی در سطوح بالاتر این نکته مهم را نشان می دهد که در بازار لوکس، کیفیت ساخت، شرط لازم است اما کافی نیست (یک خانه با کیفیت 9 در محله MeadowV (ارزان ترین محله) می تواند نصف قیمت همان کیفیت در محله NridgHt (گران ترین محله) باشد). این نتیجه اهمیت بالای اثر تعاملی (interaction effect) بین کیفیت و محله را نشان می دهد که در Heatmap بخش مصورسازی به آن پرداخته شده.

• رابطه مساحت با قیمت

```
# 4. مساحت و قیمت
fig, axes = plt.subplots(1, 2, figsize=(14, 5))


# GrLivArea vs SalePrice
axes[0].scatter(df_clean['GrLivArea'], df_clean['SalePrice']/1000,
               alpha=0.4, s=15, color=BLUE, edgecolors='none')
z = np.polyfit(df_clean['GrLivArea'], df_clean['SalePrice']/1000, 1)
x_line = np.linspace(df_clean['GrLivArea'].min(), df_clean['GrLivArea'].max(), 100)
axes[0].plot(x_line, np.polyval(z)(x_line), color=ORANGE, linewidth=2, label=f'خط رگرسیون')
r = df_clean[['GrLivArea', 'SalePrice']].corr().iloc[0,1]
axes[0].set_title(f'GrLivArea vs SalePrice (r={r:.2f})', fontsize=12)
axes[0].set_xlabel(f'مساحت (فوت مربع)', fontsize=11)
axes[0].set_ylabel(f'قیمت (هزار دلار)', fontsize=11)
axes[0].legend(fontsize=9)

# TotalBmsSF vs SalePrice
axes[1].scatter(df_clean['TotalBmsSF'], df_clean['SalePrice']/1000,
               alpha=0.4, s=15, color=PURPLE, edgecolors='none')
z2 = np.polyfit(df_clean['TotalBmsSF'], df_clean['SalePrice']/1000, 1)
x_line2 = np.linspace(df_clean['TotalBmsSF'].min(), df_clean['TotalBmsSF'].max(), 100)
axes[1].plot(x_line2, np.polyval(z2)(x_line2), color=ORANGE, linewidth=2, label=f'خط رگرسیون')
r2 = df_clean[['TotalBmsSF', 'SalePrice']].corr().iloc[0,1]
axes[1].set_title(f'TotalBmsSF vs SalePrice (r={r2:.2f})', fontsize=12)
axes[1].set_xlabel(f'مساحت زیرزمین (فوت مربع)', fontsize=11)
axes[1].set_ylabel(f'قیمت (هزار دلار)', fontsize=11)
axes[1].legend(fontsize=9)

plt.suptitle(f'رابطه مساحت با قیمت فروش', fontsize=14, y=1.02)
plt.tight_layout()
plt.show()

print(f'مربع 750 ~ $ {z[0]*100:.0f}K ~ هر 1000 فوت مربع افزایش در قیمت = قیمت {z[1]:.2f}')
print(f'رابطه مثبت واری همبستگی از قیمت = {r2:.2f} : همبستگی زیرزمین با قیمت')
```


خروجی:



قیمت \$ 9k بالا میره <= هر ۱۰۰ فوت مربع افزایش زیر بنا

همبستگی زیر زمین با قیمت: 0.58 یعنی رابطه مثبت ولی ضعیف تر از زیر بنا

تحلیل:

Purpose: بررسی و کمی سازی رابطه بین دو مساحت مهم (زیر بنای زندگی (GrLivArea) و مساحت زیر زمین (TotalBsmtSF)) با قیمت فروش از طریق Scatter Plot همراه با خط رگرسیون.

Main Findings: GrLivArea با ضریب همبستگی $r=0.68$ قوی ترین رابطه مساحتی با قیمت را دارد. خط رگرسیون نشان می دهد به ازای هر 100 فوت مربع افزایش زیر بنا، قیمت به طور میانگین 9,000 دلار افزایش می یابد.

نقاط داده به طور نسبتاً منظمی در اطراف خط رگرسیون پراکنده اند که نشانه رابطه خطی قوی است. TotalBsmtSF با $r=0.58$ رابطه مثبت ضعیف تری دارد. تجمع قابل توجهی از نقاط در مساحت صفر وجود دارد (خانه های بدون زیر زمین) که رابطه را از حالت کاملاً خطی خارج می کند و پراکندگی نقاط در این نمودار بیشتر از GrLivArea است.

Practical Interpretation: تفاوت ضریب همبستگی بین GrLivArea ($r=0.68$) و TotalBsmtSF ($r=0.58$)

از منظر اقتصادی معنا دار است (خریداران به زیر بنای بالای زمین (فضای زندگی قابل استفاده روزانه) بیشتر از زیر زمین ارزش می دهند).

این نتیجه همچنین با نتایج K-Means Clustering نیز تأیید شده است: خوشه 3 با زیر بنای بالا اما زیر زمین کوچک (\$ 183k) گران تر از خوشه 0 با زیر بنای مشابه اما زیر زمین بزرگتر (\$ 158k) است.

همچنین پراکندگی بیشتر نقاط در نمودار TotalBsmtSF نشان می دهد که این ویژگی به تنهایی قدرت پیش بینی کمی برای قیمت دارد و تاثیر آن به عوامل دیگری مثل نوع تکمیل زیرزمین (GLQ vs Unf) بستگی دارد.

• تحلیل زمانی

```
# 5. تحلیل زمانی
fig, axes = plt.subplots(1, 2, figsize=(14, 5))


# قیمت به تفکیک سال ساخت (میانگین هر دهه)
df_clean['Decade'] = (df_clean['YearBuilt'] // 10 * 10).astype(str) + 's'
decade_price = df_clean.groupby('Decade')['SalePrice'].median() / 1000
axes[0].bar(decade_price.index, decade_price.values, color='PURPLE', edgecolor='white')
axes[0].set_title(fa('میانگین قیمت به تفکیک دهه ساخت'), fontsize=12)
axes[0].set_xlabel(fa('دهه ساخت'), fontsize=11)
axes[0].set_ylabel(fa('میانگین قیمت (هزار دلار)'), fontsize=11)
axes[0].tick_params(axis='x', rotation=45)
for i, v in enumerate(decade_price.values):
    axes[0].text(i, v + 1, f'${v:.0f}K', ha='center', fontsize=8)

# تعداد فروش به تفکیک ماه
month_count = df_clean['MoSold'].value_counts().sort_index()
month_names = ['فر', 'سف', 'فرو', 'ارد', 'خرد', 'تیر', 'مرد', 'شهر', 'مهر', 'آب', 'آذر', 'دی']
axes[1].bar(range(1,13), month_count.values, color='AMBER', edgecolor='white')
axes[1].set_xticks(range(1,13))
axes[1].set_xticklabels([fa(m) for m in month_names], fontsize=8)
axes[1].set_title(fa('تعداد فروش به تفکیک ماه'), fontsize=12)
axes[1].set_xlabel(fa('ماه'), fontsize=11)
axes[1].set_ylabel(fa('تعداد معامله'), fontsize=11)

plt.tight_layout()
plt.show()

print(fa('معامله {month_count.max()} با {month_count.idxmax()} پرفروشترین ماه: ماه {month_count.index[month_count.idxmax()]}'))
print(fa('معامله {month_count.min()} با {month_count.idxmin()} کمترین ماه: ماه {month_count.index[month_count.idxmin()]}'))
```

خروجی:



پر فروش ترین ماه : ماه 6 با 240 معامله

کم فروش ترین ماه : ماه 2 با 52 معامله

تحلیل:

Purpose: بررسی دو بعد زمانی مهم در دیتاست (روند قیمت به تفکیک دهه ساخت و الگوی فصلی فروش به تفکیک ماه) برای درک تأثیر زمان بر ارزش و رفتار بازار مسکن.

Main Findings: نمودار میان‌ه قیمت به تفکیک دهه ساخت، روند صعودی کلی را نشان می‌دهد یعنی از \$ 108k برای خانه های دهه 1870 تا \$ 213k برای خانه های دهه 2000، تقریباً دو برابر افزایش یافته.

با این حال روند کاملاً خطی نیست (دهه های 1890، 1910 و 1920 کاهش نسبی قیمت نسبت به دهه قبل را نشان می‌دهند که احتمال دارد مربوط به سبک های معماری آن دوره یا کیفیت مصالح استفاده شده باشد).

از نظر فصلی، بیشترین معاملات در ماه های 5، 6 و 7 انجام شده اند (ماه 7 سال 2066 با 62 معامله پر معامله ترین دوره بود).

داده های سال 2010 ناقص هستند که دلیل کاهش چشمگیر تعداد معاملات در آن سال است.

میان‌ه قیمت در ماه 9 (\$ 179k) نسبت به ماه 1 (\$ 143k) تفاوت 25 درصدی دارد.

Practical Interpretation: روند صعودی قیمت با افزایش سال ساخت از دید اقتصادی باز هم منطقی

است چون خانه های جدید تر از استاندارد های ساخت بهتر، سیستم های عایق بندی مدرن تر و امکانات به روزتری برخوردارند.

نوسانات قیمت بین دهه های مختلف می تواند ناشی از تغییر سبک های معماری، کیفیت مصالح یا موقعیت مکانی خانه های ساخته شده در آن دوره باشد.

تفاوت 25 درصدی میانه قیمت بین ماه 9 و ماه 1 نشان دهنده فصلی بودن بازار مسکن است، با این حال باید با احتیاط عمل کرد چون این نوسانات ممکن است عاملش این باشد که خانه های فروخته شده در هر ماه از لحاظ ترکیب با هم اختلاف داشته باشند(مثلا در تابستان خانه های بزرگ تر و گران تر بیشتر معامله می شوند)، نه لزوما تغییر واقعی قیمت ها.

• تاثیر ویژگی های دسته ای

```
# 6. categorical تحلیل ویژگی‌های
fig, axes = plt.subplots(2, 2, figsize=(18, 12))

cats = [
    ('Neighborhood', fa('محله'), 90),
    ('SaleCondition', fa('شرایط فروش'), 20),
    ('Foundation', fa('نوع پی'), 20),
    ('GarageType', fa('نوع گاراژ'), 20),
]


for ax, (col, label, rot) in zip(axes.flatten(), cats):
    order = df_clean.groupby(col)['SalePrice'].median().sort_values(ascending=False).index

    sns.boxplot(
        data=df_clean,
        x=col,
        y='SalePrice',
        order=order,
        palette='Blues',
        ax=ax
    )

    ax.set_title(f'{fa("قیمت به تکنیک")} {label}', fontsize=12)
    ax.set_xlabel(label, fontsize=10)
    ax.set_ylabel(fa('قیمت (دلار)'), fontsize=10)
    ax.tick_params(axis='x', rotation=45)

plt.suptitle(fa('تاثیر ویژگی‌های دسته‌ای بر قیمت'), fontsize=14, y=1.02)
plt.tight_layout()
plt.show()
```

خروجی:



تحلیل:

Purpose: بررسی میزان تاثیر چهار ویژگی دسته ای مهم (Neighborhood, SaleCondition, GarageType, Foundation) بر قیمت فروش از طریق Boxplot مرتب شده بر اساس میانه قیمت به منظور کشف الگوهای قیمت گذاری در دسته های مختلف.

Main Findings: محله (Neighborhood) بیشترین تفاوت قیمت را ایجاد می کند (NridgHt و NoRidge با میانه بالای \$ 250k گران ترین و MeadowV و BrDale با میانه زیر \$ 100k ارزان ترین محله ها هستند).

شرایط فروش (SaleCondition) نشان می دهد فروش های Partial (خانه های نوساز هنگام فروش) بالاترین قیمت را دارند در حالی که AdjLand (خرید زمین مجاور) ارزان ترین است.

فروش های Abnormal قیمتشان به صورت قابل توجهی پایین تر از Normal است.

نوع پی (Foundation) نشان می دهد خانه های با پی بتون ریخته شده (PConc) و چوبی (Wood) گران ترند در حالی که پی دال (Slab) ارزان ترین نوع است.

نوع گاراژ (GarageType) نشان می دهد گاراژ های BuiltIn (داخل ساختمان) بالاترین و خانه های بدون گاراژ (None) پایین ترین قیمت را دارند.

Practical Interpretation: تفاوت قیمت بین محله ها (تفاوت بیش از 3 برابر بین NridgHt و MeadowV) نشان می دهد که موقعیت مکانی مهم ترین عامل دسته ای در تعیین قیمت مسکن است.

تفاوت قیمت بین فروش های Normal و Abnormal نیز از دید اقتصادی کاملاً منطقی است، در فروش های اجباری مثل توقیف یا ورشکستگی، فروشنده مجبور است با قیمت پایین تر از ارزش واقعی ملک بفروشد. ارزان تر بودن خانه های با پی Slab نسبت به PConc دلیلش میتواند دوام کمتر و هزینه های نگهداری بیشتر این نوع پی در اقلیم Iowa باشد که زمستان های سرد دارد.


• ماتریس پراکندگی ویژگی های برتر

```
# 7. Pairplot برتر ویژگی های
top5 = ['SalePrice', 'GrLivArea', 'OverallQual', 'TotalBsmtSF', 'GarageArea']

g = sns.pairplot(df_clean[top5],
                 diag_kind='kde',
                 plot_kws={'alpha': 0.3, 's': 15, 'color': BLUE},
                 diag_kws={'color': GREEN})

g.fig.suptitle(fa('ماتریس پراکندگی ویژگی های برتر'), y=1.02, fontsize=14)
plt.show()
print('دارن SalePrice قویترین رابطه خطی با OverallQual و GrLivArea نتیجه:')
print('همبستگی متوسطی وجود داره TotalBsmtSF و GrLivArea نتیجه: بین')
```

خروجی:



نتیجه: GrLivArea و OverallQual قوی ترین رابطه خطی با SalePrice دارند.

نتیجه: بین GrLivArea و TotalBsmntSF همبستگی متوسطی وجود دارد.

تحلیل:

Purpose: هم‌سازی همزمان روابط دو به دو بین پنج ویژگی کلیدی (SalePrice، GrLivArea، OverallQual، TotalBsmntSF، GarageArea) از طریق ماتریس پراکندگی، به منظور کشف الگوهای چند متغیره و شناسایی همخطی چندگانه (Multicollinearity).

Main Findings: رابطه GrLivArea با SalePrice واضح ترین رابطه خطی را در کل ماتریس دارد. رابطه OverallQual با SalePrice به صورت پله ای است چون OverallQual یک متغیر ترتیبی با مقادیر 1 تا 10 است.

رابطه TotalBsmtSF با GrLivArea همبستگی متوسطی نشان می‌دهد (خانه‌های بزرگ‌تر معمولاً زیر زمین بزرگ‌تری هم دارند).

توزیع GarageArea در قطر ماتریس دو قله دارد. یکی در صفر (بدون گاراژ) و یکی در حدود ۵۰۰ فوت مربع.

توزیع SalePrice در قطر ماتریس چولگی راست را نشان می‌دهد و GrLivArea توزیع نسبتاً نرمالی دارد.

Practical Interpretation: وجود همبستگی بین TotalBsmtSF و

GrLivArea (همخطی چندگانه) نکته‌ی مهمی برای مدل‌سازی است زیرا وقتی هر دو ویژگی همزمان در مدل رگرسیون خطی استفاده می‌شوند، ضرایب آن‌ها ناپایدار می‌شوند. این توضیح می‌دهد چرا در مدل رگرسیون خطی (بخش مدل‌سازی)، ضریب بعضی ویژگی‌ها مثل FullBath و TotRmsAbvGrd منفی شد (نه به این خاطر که رابطه واقعی منفی است، بلکه به دلیل همخطی چندگانه بین این ویژگی‌ها).

شکل دو قله‌ای توزیع GarageArea نیز نشان‌دهنده وجود دو زیرجمعیت مجزا در دیتاست است:

- خانه‌های با گاراژ
- خانه‌های بدون گاراژ

که این تفکیک در خوشه‌بندی K-Means نیز به خوبی مشاهده شد.

• رتبه‌بندی محله‌ها


```
# نقشه جرایمی قیمت محله‌ها
fig, ax = plt.subplots(figsize=(14, 7))

neigh_stats = df_clean.groupby('Neighborhood')['SalePrice'].agg(['median', 'count', 'std'])
neigh_stats.columns = ['median', 'count', 'std']
neigh_stats = neigh_stats.sort_values('median', ascending=True)

colors_n = [BLUE if v > 200000 else GREEN if v > 150000 else AMBER
             for v in neigh_stats['median']]


bars = ax.barh(neigh_stats.index, neigh_stats['median']/1000,
               color=colors_n, edgecolor='white', linewidth=0.5, height=0.7)

# اضافه کردن تعداد معامله
for i, (idx, row) in enumerate(neigh_stats.iterrows()):
    ax.text(row['median']/1000 + 2, i,
            f'$({row['median']/1000:.0f})K (n={int(row['count'])})',
            va='center', fontsize=8.5)

ax.axvline(df_clean['SalePrice'].median()/1000, color='gray',
           linestyle='--', linewidth=1.5,
           label=f'میانگین کل: ${df_clean['SalePrice'].median()/1000:.0f}K')
ax.set_xlim(0, 380)
ax.set_xlabel(f'میانگین قیمت فروش (هزار دلار)', fontsize=12)
ax.set_title(f'رتبه‌بندی محله‌ها بر اساس میانگین قیمت فروش', fontsize=14, pad=15)
ax.legend(fontsize=10)

from matplotlib.patches import Patch
legend_els = [
    Patch(facecolor=BLUE, label=f'200$ بالای (K)'),
    Patch(facecolor=GREEN, label=f'$150K 200$ (K)'),
    Patch(facecolor=AMBER, label=f'$150$ زیر (K)'),
]
ax.legend(handles=legend_els, fontsize=9, loc='lower right')
plt.tight_layout()
plt.show()
```

خروجی:



گران ترین محله: NridgHt = \$ 270k

ارزان ترین محله: MeadowV = \$ 88k

X نسبت گران ترین به ارزان ترین: 3.1

تحلیل:

Purpose: رتبه بندی و مقایسه بصری 25 محله شهر Ames بر اساس میانه قیمت فروش با استفاده از نمودار افقی رنگ بندی شده به منظور نمایش تاثیر موقعیت مکانی بر قیمت مسکن و شناسایی محله های گران و ارزان.

Main Findings: NridgHt با میانه \$ 270k (48 خانه) و NoRidge با میانه \$ 269k (24 خانه) گران ترین محله ها هستند و در مقابل، MeadowV با میانه تنها \$ 88k ارزان ترین محله است. نسبت گران ترین به ارزان ترین محله 3.1 برابر است.

خط چین عمودی، میانه کل دیتاست (\$ 160k) را نشان می دهد که 12 محله بالاتر و 13 محله پایین تر از آن قرار دارند، رنگ بندی سه گانه نشان می دهد 5 محله بالای \$ 200k (آبی)، 7 محله بین \$ 150k تا \$ 200k (سبز) و 13 محله زیر \$ 150k (نارنجی) هستند.

Practical Interpretation: تفاوت 3.1 برابری بین گران ترین و ارزان ترین محله نشان می دهد که موقعیت مکانی یکی از مهم ترین عوامل تعیین کننده قیمت مسکن است، حتی بیشتر از کیفیت ساخت در بسیاری موارد.

محله های گران قیمت مثل NridgHt و StoneBr معمولاً در مناطق جدید تر شهر با دسترسی بهتر به امکانات رفاهی قرار دارند در حالی که محله های ارزان قیمت مثل MeadowV و IDOTRR اغلب در نزدیکی راه آهن یا مناطق صنعتی هستند.

این نتایج برای سرمایه گذاران مسکن اهمیت بالایی دارد زیرا انتخاب محله درست می تواند تاثیری بیشتر از بازسازی خانه بر ارزش ملک داشته باشد.

• Bubble Chart کیفیت


```
# 2. بابلر کیفیت و سال ساخت روی قیمت (Bubble Chart)
fig, ax = plt.subplots(figsize=(13, 7))

qual_groups = df_clean.groupby(['OverallQual', 'Decade']).agg(
    median_price=('SalePrice', 'median'),
    count=('SalePrice', 'count')
).reset_index()

scatter = ax.scatter(
    qual_groups['OverallQual'],
    qual_groups['median_price'] / 1000,
    s=qual_groups['count'] * 5,
    c=qual_groups['median_price'],
    cmap='YlOrRd',
    alpha=0.7,
    edgecolors='white',
    linewidth=0.5
)

plt.colorbar(scatter, ax=ax, label=fa('قیمت (دلار)'))
ax.set_xlabel(fa('کیفیت کلی (1 تا 10)'), fontsize=12)
ax.set_ylabel(fa('میانگین قیمت (هزار دلار)'), fontsize=12)
ax.set_title(fa('رابطه کیفیت با قیمت - اندازه دایره = تعداد خانه'), fontsize=13, pad=12)
plt.xticks(range(1, 11))
plt.tight_layout()
plt.show()
print('خانه‌های با کیفیت ۸-۱۰ که بعد از ۲۰۰۰ ساخته شدن گران‌ترین دسته هستند')
```

خروجی:



خانه های با کیفیت 8 تا 10 که بعد از 2000 ساخته شدند گران ترین دسته هستند.

تحلیل:

Purpose: نمایش همزمان سه بعد اطلاعاتی (کیفیت کلی، میانه قیمت و تعداد خانه ها) در یک نمودار به منظور درک توزیع خانه ها در سطوح مختلف کیفیتی و رابطه آن با قیمت.

Main Findings: بزرگ ترین دایره ها در کیفیت 5، 6 و 7 قرار دارند که نشان دهنده تمرکز اکثریت خانه ها در این سطوح کیفیتی است.

با افزایش کیفیت از 1 تا 10، رنگ دایره ها از زرد (ارزان) به قرمز تیره (گران) تغییر می کند که رابطه مثبت قوی بین کیفیت و قیمت را نشان می دهد.

خانه های با کیفیت 8 تا 10 که عمدتاً بعد از سال 2000 ساخته شده اند، گران ترین دسته را تشکیل می دهند. دایره های کوچک در سطوح کیفیت 1 و 2 نشان می دهند که خانه های با کیفیت بسیار پایین در این بازار بسیار کمیاب هستند.

Practical Interpretation: توزیع نا متقارن خانه ها (تمرکز در کیفیت 5 تا 7) نشان می دهد که بازار مسکن Ames عمدتاً یک بازار متوسط است.

این موضوع از دید مدل سازی اهمیت دارد زیرا مدل ها برای پیش بینی خانه های با کیفیت 1 و 2 (که داده کمی دارند) دقت کمتری خواهند داشت، همچنین برتری خانه های با کیفیت متوسط در بازار نشان می دهد که این شهر دانشگاهی عمدتاً برای خانواده های با درآمد متوسط طراحی شده است.

• مقایسه violin قبل/بعد


```
# مقایسه Violin قبل/بعد پاکسازی با 3.
fig, axes = plt.subplots(1, 2, figsize=(14, 6))

# قبل
data_before = [df_raw[df_raw['OverallQual'] == q]['SalePrice'].values / 1000
                 for q in sorted(df_raw['OverallQual'].unique())]
axes[0].violinplot(data_before, positions=range(1, 11), showmedians=True)
axes[0].set_title(fa('توزیع قیمت به تفکیک کیفیت - قبل از پاکسازی'), fontsize=11)
axes[0].set_xlabel(fa('کیفیت کلی'), fontsize=11)
axes[0].set_ylabel(fa('قیمت (مزار دلار)'), fontsize=11)
axes[0].set_xticks(range(1, 11))

# بعد
data_after = [df_clean[df_clean['OverallQual'] == q]['SalePrice'].values / 1000
               for q in sorted(df_clean['OverallQual'].unique())]
vp = axes[1].violinplot(data_after, positions=range(1, 11), showmedians=True)
for body in vp['bodies']:
    body.set_facecolor(GREEN)
    body.set_alpha(0.7)
axes[1].set_title(fa('توزیع قیمت به تفکیک کیفیت - بعد از پاکسازی'), fontsize=11)
axes[1].set_xlabel(fa('کیفیت کلی'), fontsize=11)
axes[1].set_ylabel(fa('قیمت (مزار دلار)'), fontsize=11)
axes[1].set_xticks(range(1, 11))

plt.suptitle(fa('تأثیر پاکسازی داده بر توزیع قیمت'), fontsize=14, y=1.02)
plt.tight_layout()
plt.show()
print(fa('های کیفیت ۴-۶ حذف شدن و توزیع متعادلتر شده outlier بعد از پاکسازی'))
```

خروجی:



بعد از پاکسازی، outlier های کیفیت 4 تا 6 حذف شدن و توزیع متعادل تر شده

تحلیل:

Purpose: مقایسه بصری تأثیر پاکسازی داده بر توزیع قیمت در هر سطح کیفیتی از طریق نمودار Violin که شکل کامل توزیع را نمایش می دهد(نه فقط میانه و پراکندگی)

Main Findings: در نمودار چپ (قبل از پاکسازی)، دم های بلند رو به بالا در سطوح کیفیت 8 تا 10 به وضوح مشاهده می شود، خانه هایی با قیمت های بالای \$ 500k تا \$ 750k که توزیع را مخدوش می کنند. در نمودار راست (بعد از پاکسازی)، این دم های بلند حذف شده و شکل Violin ها متقارن تر و منظم تر است.

نکته جالب اینکه کیفیت 10 پس از پاکسازی از دیتاست حذف شده است، نشانه ای از اینکه تمام خانه های کیفیت 10 قیمت های پرت داشتند.

همچنین outlier های کیفیت 4 تا 6 حذف شدند و توزیع این گروه ها متعادل تر شد.

Practical Interpretation: حذف کیفیت 10 پس از پاکسازی یک نتیجه مهم است، این خانه ها احتمالا در محله های بسیار گران قیمت با قیمتی بسیار فراتر از حد IQR بودند.

این نشان می دهد که بازار مسکن Ames در سطح کیفیت 10 یک بازار بسیار کوچک است که با قوانین متفاوتی از بقیه بازار عمل می کند.

مقارن تر شدن شکل Violin ها پس از پاکسازی نشان می دهد که داده های پرت واقعا نویز بودند و حذف آن ها باعث شد تصویر واقعی تری از بازار مسکن داشته باشیم.

• Heatmap محله * کیفیت

```
# 4. Heatmap قیمت: محله * کیفیت
pivot = df_clean.pivot_table(
    values='SalePrice',
    index='Neighborhood',
    columns='OverallQual',
    aggfunc='median'
) / 1000


# فقط محله هایی که داده کافی دارند
pivot = pivot.dropna(thresh=3)

fig, ax = plt.subplots(figsize=(14, 10))
sns.heatmap(pivot, cmap='YlOrRd', annot=True, fmt='.0f',
            linewidths=0.3, ax=ax,
            cbar_kws={'label': 'میانگین قیمت (هزار دلار)'})

ax.set_title(fa('میانگین قیمت فروش (هزار دلار): محله * کیفیت'), fontsize=14, pad=15)
ax.set_xlabel(fa('کیفیت کلی'), fontsize=12)
ax.set_ylabel(fa('محله'), fontsize=12)
plt.tight_layout()
plt.show()

print('با کیفیت ۸+ بالاترین قیمت ها رو داره NoRidge محله')
print('در محله های ارزان تر حتی کیفیت بالا هم قیمت رو خیلی بالا نمیره')
```

خروجی:



محله NoRidge با کیفیت بالا تر از 8 بالاترین قیمت ها رو داره

در محله های ارزان تر حتی کیفیت بالا هم قیمت رو خیلی بالا نمیره

تحلیل:

Purpose: بررسی اثر تعاملی (Interaction Effect) دو عامل مهم محله و کیفیت بر قیمت مسکن از طریق Heatmap که برای هر ترکیب محله؛ کیفیت، میانۀ قیمت را نشان می دهد.

Main Findings: گران ترین ترکیب در کل ماتریس، محله NridgHt با کیفیت 9 است و میانۀ \$ 317k.

ارزان ترین ترکیب، محله Edwards با کیفیت 1 است و میانۀ \$ 61k.

سلول های خالی نشان دهنده ترکیب هایی هستند که در دیتاست وجود ندارند، مثلاً هیچ خانه ای با کیفیت ۱۰ در محله MeadowV وجود ندارد.

نکته اینکه در محله های ارزان تر مانند IDOTRR و MeadowV، حتی با افزایش کیفیت تا سطح 6، قیمت از \$ 154k بیشتر نرفته استن و در مقابل، در محله StoneBr حتی خانه های با کیفیت 7 نیز میانه قیمت \$ 239k دارند.

Practical Interpretation: این Heatmap مفهوم سقف قیمت محله ای را به خوبی نشان می دهد(در محله های ارزان قیمت، هر چقدر هم کیفیت ساخت را بهبود بدهید، قیمت از یک حد مشخص بالاتر نمی رود.)

این نتیجه اهمیت عملی بالایی برای سرمایه گذاران دارد:

سرمایه گذاری در بازسازی یک خانه در محله MeadowV برای افزایش کیفیت از 4 به 7 احتمالاً بازگشت سرمایه خوبی نخواهد داشت، چون سقف قیمت محله مانع افزایش متناسب قیمت می شود.

این اثر تعاملی بین محله و کیفیت نشان می دهد که مدل های رگرسیون خطی ساده که این اثر را نادیده می گیرند، دقت کمتری خواهند داشت.

• تحلیل فصلی

```
# تحلیل فصلی فروش
fig, axes = plt.subplots(1, 2, figsize=(14, 5))


# تعداد فروش * ماه * سال
pivot_time = df_clean.pivot_table(
    values='SalePrice',
    index='MoSold',
    columns='YrSold',
    aggfunc='count'
)

sns.heatmap(pivot_time, annot=True, fmt='.0f', cmap='Blues',
             ax=axes[0], linewidths=0.3)
axes[0].set_title(fa('تعداد فروش به تفکیک ماه و سال'), fontsize=12)
axes[0].set_xlabel(fa('سال'), fontsize=11)
axes[0].set_ylabel(fa('ماه'), fontsize=11)

# میانگین قیمت * ماه
month_price = df_clean.groupby('MoSold')['SalePrice'].median() / 1000
axes[1].plot(month_price.index, month_price.values,
             color=BLUE, linewidth=2.5, marker='o', markersize=7)
axes[1].fill_between(month_price.index, month_price.values,
                    month_price.min(), alpha=0.15, color=BLUE)
axes[1].set_title(fa('میانگین قیمت به تفکیک ماه فروش'), fontsize=12)
axes[1].set_xlabel(fa('ماه'), fontsize=11)
axes[1].set_ylabel(fa('میانگین قیمت (هزار دلار)'), fontsize=11)
axes[1].set_xticks(range(1, 13))
axes[1].grid(True, alpha=0.3)

plt.tight_layout()
plt.show()
```


خروجی:



تحلیل:

Purpose: بررسی الگوی فصلی بازار مسکن Ames از دو دید(تعداد معاملات به تفکیک ماه و سال (Heatmap) و میانۀ قیمت ماهانه (Line Chart)) برای کشف رفتار فصلی بازار.

Main Findings: Heatmap تعداد فروش نشان می دهد که در تمام سال های 2006 تا 2009، ماه های 5، 6 و 7 پر ترافیک ترین ماه های فروش هستند، بیشترین معامله ثبت شده ماه 7 سال 2006 با 62 معامله است.

داده های سال 2010 ناقص هستند(این سال تنها 6 معامله در ماه 7 ثبت کرده در حالی که سال های قبل 47 تا 62 معامله داشتند).

نمودار خطی، میانۀ قیمت ماهانه نوسانات غیرمنتظره ای را نشان می دهد(ماه ۹ با \$ 179k بالا ترین و ماه 1 با \$ 143k پایین ترین میانۀ قیمت را دارد).

تفاوت 25 درصدی بین این دو ماه قابل توجه است.

Practical Interpretation: الگوی فصلی پر فروش بودن تابستان (ماه های 5 تا 7) با رفتار خریداران

مسکن در آمریکا همخوانی دارد، خانواده ها ترجیح می دهند قبل از شروع سال تحصیلی جدید نقل مکان

کنند تا فرزندان شان در اول ماه تحصیلی در مدرسه جدید حاضر باشند.

نوسانات میانه قیمت ماهانه احتمالا ناشی از ترکیب متفاوت خانه های فروخته شده در هر ماه است نه تغییر

واقعی قیمت بازار، در تابستان خانه های بزرگ تر و گران تر (مناسب خانواده) بیشتر معامله می شوند در

حالی که در زمستان آپارتمان های کوچک تر و ارزان تر بیشتر فروش می روند.


ناقص بودن داده های 2010 باید در تفسیر نتایج مربوط به این سال مدنظر قرار گیرد.

• همبستگی نهایی

```
# همبستگی ساده 6.
# SalePrice مهمترین ویژگی ها بر اساس همبستگی با
corr_vals = df_clean[num_cols + ['SalePrice']].corr()['SalePrice']\
    .drop('SalePrice').abs().sort_values(ascending=True).tail(15)

fig, ax = plt.subplots(figsize=(10, 7))
colors_fi = [BLUE if v > 0.6 else GREEN if v > 0.4 else '#B5D4F4'
             for v in corr_vals.values]
ax.barh(corr_vals.index, corr_vals.values, color=colors_fi,
        edgecolor='white', linewidth=0.5)
ax.set_title(fa('مهمترین ویژگی ها بر اساس همبستگی با قیمت'), fontsize=13, pad=12)
ax.set_xlabel(fa('ضریب همبستگی (قرمطلق)'), fontsize=11)
ax.axvline(0.6, color='gray', linestyle='--', alpha=0.5, label=f('آستانه ۰.۶'))
ax.legend(fontsize=9)
for i, v in enumerate(corr_vals.values):
    ax.text(v + 0.005, i, f'{v:.2f}', va='center', fontsize=9)
plt.tight_layout()
plt.show()
```

خروجی:



تحلیل:

Purpose: ارائه تصویر جامع از قوی ترین همبستگی های عددی با قیمت فروش از طریق نمودار افقی رنگ بندی شده، به منظور اولویت بندی ویژگی ها برای مدل سازی و تایید یافته های بخش های قبلی.

Main Findings: OverallQual با ضریب همبستگی 0.79 در پیش بینی قیمت قوی ترین است.

GrLivArea با 0.68 دومین است.

GarageCars با 0.63 و GarageArea با 0.61 هر دو در دسته آبی تیره (بالای 0.6) قرار دارند.

YearBuilt با 0.59، TotalBsmtSF با 0.58 و FullBath با 0.57 در دسته سبز (0.4 تا 0.6) قرار دارند.

در آخر لیست، MasVnrArea، OpenPorchSF، LotFrontage و GarageYrBlt همگی ضریب همبستگی 0.32 دارند.

Practical Interpretation: نکته در همبستگی بالای GarageCars (0.63) نسبت به

GarageArea (0.61) است یعنی تعداد ماشین هایی که گاراژ جا می دهد رابطه قوی تری با قیمت نسبت به مساحت خود گاراژ دارد.

این به این معناست که خریداران بیشتر به عملکرد (اینکه چند ماشین جا می شود) توجه می کنند تا اندازه. همچنین پایین بودن همبستگی LotFrontage (0.32) و LotArea (که در top 15 نیست) نشان می دهد که مساحت زمین در این بازار قدرت پیش بینی قوی ای ندارد و احتمالا به این دلیل که در Ames زمین های بزرگ اغلب در محله های ارزان قیمت حومه شهر قرار دارند. این 15 ویژگی به عنوان ورودی مدل های آماری بخش بعدی انتخاب شدند.

• رگرسیون خطی (Linear Regression)

```
# مدل آماری - پیش بینی قیمت
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import r2_score, mean_squared_error
from sklearn.preprocessing import LabelEncoder
import numpy as np

# آماده سازی داده
df_model = df_clean.copy()
features = ['OverallQual', 'GrLivArea', 'TotalBsmtSF',
            'GarageCars', 'YearBuilt', 'FullBath',
            'TotRmsAbvGrd', 'Fireplaces']

X = df_model[features]
y = df_model['SalePrice']

# train و test تقسیم داده به
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=2)

print(f'تعداد داده آموزشی: {len(X_train)}')
print(f'تعداد داده تست: {len(X_test)}')

# آموزش مدل
model = LinearRegression()
model.fit(X_train, y_train)

# پیش بینی
y_pred = model.predict(X_test)
```

```
r2 = r2_score(y_test, y_pred)
rmse = np.sqrt(mean_squared_error(y_test, y_pred))
print(f'\nR² Score: {r2:.3f}')
print(f'RMSE: {rmse:.0f}')
print(f'\nR² یعنی {r2*100:.1f}٪ تغییر قیمت رو توضیح میده')

# نمودارهای نتایج
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# Predicted vs Actual
axes[0].scatter(y_test/1000, y_pred/1000,
                alpha=0.4, s=20, color=BLUE, edgecolors='none')
axes[0].plot([y_test.min()/1000, y_test.max()/1000],
             [y_test.min()/1000, y_test.max()/1000],
             color=ORANGE, linewidth=2, linestyle='--', label=f'خط ایدهآل')
axes[0].set_title(f'تفاوت پتانسیل شد vs قیمت واقعی', fontsize=12)
axes[0].set_xlabel(f'قیمت واقعی (هزار دلار)', fontsize=11)
axes[0].set_ylabel(f'قیمت پیش بینی (هزار دلار)', fontsize=11)
axes[0].legend(fontsize=9)
axes[0].text(0.05, 0.92, f'R² = {r2:.3f}', transform=axes[0].transAxes,
            fontsize=11, color='darkred', fontweight='bold')

# ضرایب ویژگی ها
coef = pd.Series(model.coef_, index=features).sort_values()
colors_c = [GREEN if v > 0 else ORANGE for v in coef.values]
axes[1].barh(coef.index, coef.values, color=colors_c,
             edgecolors='white', linewidth=0.5)
axes[1].axvline(0, color='gray', linewidth=1)
axes[1].set_title(f'تأثیر هر ویژگی بر قیمت (ضرایب مدل)', fontsize=12)
axes[1].set_xlabel(f'ضرایب رگرسیون', fontsize=11)

plt.suptitle(f'نتایج مدل رگرسیون خطی', fontsize=14, y=1.02)
plt.tight_layout()
plt.show()

print('\nضرایب عبارتند از:')
for feat, coef_val in sorted(zip(features, model.coef_),
                             key=lambda x: abs(x[1]), reverse=True):
    print(f'    {feat}: {coef_val:+.0f} = به ازای هر واحد افزایش')
```

خروجی:


تعداد داده آموزشی: 1098

تعداد داده تستی: 275

R^2 Score: 0.783

RMSE: \$25,928

یعنی مدل 78.3٪ از تغییرات قیمت رو توضیح میدهد



تفسیر ضرایب:

OverallQual: به ازای هر واحد افزایش $\leq +14,800$ \$ تغییر قیمت

GarageCars: به ازای هر واحد افزایش $\leq +8,701$ \$ تغییر قیمت

Fireplaces: به ازای هر واحد افزایش $\leq +7,563$ \$ تغییر قیمت

FullBath: به ازای هر واحد افزایش $\leq -3,795$ \$ تغییر قیمت

TotRmsAbvGrd: به ازای هر واحد افزایش $\leq -2,282$ \$ تغییر قیمت

YearBuilt: به ازای هر واحد افزایش $\leq +412$ \$ تغییر قیمت

GrLivArea: به ازای هر واحد افزایش $\leq +53$ \$ تغییر قیمت

TotalBsmtSF: به ازای هر واحد افزایش $\leq +28$ \$ تغییر قیمت

تحلیل:

Purpose: ساخت یک مدل رگرسیون خطی چندگانه برای پیش بینی قیمت فروش خانه (SalePrice) بر اساس 8 ویژگی مهم، ارزیابی عملکرد مدل و تفسیر ضرایب برای درک تاثیر کمی هر ویژگی بر قیمت.

Main Findings: داده ها با نسبت 80 به 20، به 1098 نمونه آموزشی و 275 نمونه تستی تقسیم شدند.

مدل رگرسیون خطی، $R^2=0.783$ و $RMSE=\$25,928$ به دست آورد که یعنی مدل 78.3٪ از تغییرات قیمت را توضیح می دهد و میانگین خطای پیش بینی حدود 26 هزار دلار است.

ضرایب مدل نشان می دهند OverallQual با ضریب +14800 \$ بیشترین تاثیر مثبت را دارد.

GarageCars با + 8701 \$ و Fireplaces با + 7563 \$ در رتبه های بعدی قرار دارند.

ضرایب منفی FullBath (- 3795 \$) و TotRmsAbvGrd (- 2282 \$) در نمودار مشاهده می شوند.

نمودار Predicted vs Actual نشان می دهد که انحراف نقاط از خط مرجع در قیمت های بالای 200k \$ بیشتر است.

Practical Interpretation: $R^2=0.783$ برای یک مدل خطی ساده با فقط 8 ویژگی، عملکرد قابل قبولی است.

$RMSE=\$25,928$ در مقیاس بازار مسکن Ames (میانگین 180k \$) معادل خطای 14.3٪ است که برای اهداف عملی قابل استفاده است.

ضریب منفی FullBath و TotRmsAbvGrd پدیده همخطی چندگانه (Multicollinearity) را نشان می دهد (این دو ویژگی با GrLivArea همبستگی بالایی دارند و اطلاعات مشابهی به مدل می دهند، به همین دلیل ضرایب غیر منطقی به نظر می رسند).

ضعیف تر بودن مدل در پیش بینی خانه های لوکس (بالای 200k \$) نشان می دهد که قیمت گذاری در بخش لوکس بازار پیچیدگی های بیشتری دارد که رگرسیون خطی ساده قادر به capture کردن آن ها نیست.

• درخت تصمیم (Decision Tree)

```
# درخت تصمیم
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.metrics import classification_report, confusion_matrix

# ساختن برجسته
df_model['PriceCategory'] = (
    df_model['SalePrice'] >= df_model['SalePrice'].median()
).astype(int)

features_dt = ['OverallQual', 'GrLivArea', 'TotalBsmtSF',
               'GarageCars', 'YearBuilt', 'FullBath']

X_dt = df_model[features_dt]
y_dt = df_model['PriceCategory']

X_train_dt, X_test_dt, y_train_dt, y_test_dt = train_test_split(
    X_dt, y_dt, test_size=0.2, random_state=42)

# آموزش
dt = DecisionTreeClassifier(max_depth=4, random_state=42)
dt.fit(X_train_dt, y_train_dt)

y_pred_dt = dt.predict(X_test_dt)
acc = dt.score(X_test_dt, y_test_dt)
print(f'دقت درخت تصمیم: {acc*100:.1f}%')
print()
print(classification_report(y_test_dt, y_pred_dt,
                           target_names=['ارزون', 'گران']))

# رسم درخت
fig, ax = plt.subplots(figsize=(22, 9))
plot_tree(dt,
          feature_names=features_dt,
          class_names=['Cheap', 'Expensive'],
          filled=True, rounded=True,
          fontsize=9, ax=ax)
```

```
filled=True, rounded=True,
          fontsize=9, ax=ax)
ax.set_title(fa('درخت تصمیم - دستبندی خانه به گرون و ارزون'),
            fontsize=14, pad=15)
plt.tight_layout()
plt.show()

# Confusion Matrix
fig, ax = plt.subplots(figsize=(6, 5))
cm = confusion_matrix(y_test_dt, y_pred_dt)
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues', ax=ax,
            xticklabels=[fa('ارزون'), fa('گران')],
            yticklabels=[fa('ارزون'), fa('گران')])
ax.set_title(fa('ماتریس درهم ریختگی (Confusion Matrix)'), fontsize=12)
ax.set_xlabel(fa('پیش بینی مدل'), fontsize=11)
ax.set_ylabel(fa('مقدار واقعی'), fontsize=11)
plt.tight_layout()
plt.show()


print(f'تأ رو درست دستبندی میکنه {acc*100:.0f} از هر ۱۰۰ خانه مدل')
```

خروجی:


دقت درخت تصمیم: 88.4%

	precision	recall	F1-score	support
ارزون	0.89	0.89	0.89	149
گرون	0.87	0.87	0.87	126
Accuracy			0.88	275
Macro avg	0.88	0.88	0.88	275
Weighted avg	0.88	0.88	0.88	275

درخت تصمیم — دسته‌بندی خانه به گرون و ارزون (max_depth=4)



ماتریس درهم‌ریختگی (Confusion Matrix)



از هر 100 خانه، مدل 88 تا رو درست دسته بندی میکنه.

تحلیل:

Purpose: ساخت یک مدل دسته بندی برای تفکیک خانه ها به دو دسته گران (بالا تر از میانه قیمت) و ارزان (پایین تر از میانه قیمت) با استفاده از درخت تصمیم با عمق 4 و تفسیر ساختار درخت برای درک منطق تصمیم گیری مدل.

Main Findings: مدل دقت کلی 88.4٪ به دست آورد که از هر 100 خانه، 88 تا درست دسته بندی می شوند.

Precision برای دسته ارزان 0.89 و برای دسته گران 0.87 است.

F1-Score متعادل برای هر دو دسته نشان دهنده عملکرد یکسان مدل روی هر دو گروه است.

ساختار درخت نشان می دهد ریشه درخت از $OverallQual \leq 5.5$ تقسیم می شود، در شاخه چپ (کیفیت پایین)، $GrLivArea \leq 1382.5$ معیار تقسیم بعدی است، در شاخه راست (کیفیت بالا)، $GrLivArea \leq 1143$ معیار تقسیم کننده بعدی است و در سطح سوم، $YearBuilt$ ، $TotalBsmtSF$ و $GarageCars$ نقش مهمی دارند.

ماتریس درهم ریختگی نشان می دهد از 149 خانه ارزان، 133 تا درست شناسایی شدند (16 خطا) و از 126 خانه گران، 110 تا درست شناسایی شدند (16 خطا).

Practical Interpretation: انتخاب $OverallQual$ به عنوان اولین گره تقسیم درخت تایید می کند که کیفیت کلی مهم ترین عامل تمایز بین خانه های گران و ارزان است، این نتیجه با نتیجه تحلیل همبستگی ($r=0.79$) کاملاً همخوانی دارد.

تعادل خطاها در دو طرف (هر بار 16 خطا) نشان دهنده عملکرد یکسان مدل روی هر دو دسته است و مدل تمایلی به پیش بینی یک دسته خاص ندارد. محدود کردن عمق درخت به 4 سطح ($max_depth=4$) یک

تصمیم خوب برای جلوگیری از Overfitting است زیرا یک درخت عمیق تر ممکن است روی داده های آموزشی دقت 100٪ داشته باشد اما روی داده های جدید عملکرد ضعیفی داشته باشد.

• خوشه‌بندی (K-Means Clustering)

```
# خوشه بندی
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler

# آماده‌سازی
features_km = ['OverallQual', 'GrLivArea', 'TotalBsmtSF',
               'GarageCars', 'SalePrice']
X_km = df_clean[features_km].dropna()

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X_km)

# آموزش KMeans
kmeans = KMeans(n_clusters=4, random_state=42)
df_clean['Cluster'] = kmeans.fit_predict(X_scaled)

# مصورسازی
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# scatter کلاسترها
scatter = axes[0].scatter(df_clean['GrLivArea'],
                        df_clean['SalePrice']/1000,
                        c=df_clean['Cluster'],
                        cmap='Set1', alpha=0.5, s=20)
axes[0].set_title(fa('خوشه‌بندی K-Means, k=4'), fontsize=12)
axes[0].set_xlabel(fa('نسبت (فوت مربع)'), fontsize=11)
axes[0].set_ylabel(fa('قیمت (هزار دلار)'), fontsize=11)
plt.colorbar(scatter, ax=axes[0], label=f('خرنه'))


# میانگین هر خوشه
cluster_means = df_clean.groupby('Cluster')[features_km].mean()
cluster_means['SalePrice'] = cluster_means['SalePrice']/1000
axes[1].bar(cluster_means.index.astype(str),
            cluster_means['SalePrice'],
            color=PALETTE, edgecolor='white')
for i, v in enumerate(cluster_means['SalePrice']):
    axes[1].text(i, v+2, f'$({v:.0f})K', ha='center', fontsize=9)
```

```
axes[1].set_title(fa('میانگین قیمت هر خوشه'), fontsize=12)
axes[1].set_xlabel(fa('خوشه'), fontsize=11)
axes[1].set_ylabel(fa('میانگین قیمت (هزار دلار)'), fontsize=11)

plt.suptitle(fa('نتیج خوشه‌بندی K-Means'), fontsize=14, y=1.02)
plt.tight_layout()
plt.show()

print('مشخصات هر خوشه:')
print(cluster_means.round(1).to_string())
```

خروجی:



مشخصات هر خوشه:

Cluster	OverallQual	GrLivArea	TotalBsmtSF	GarageCars	SalePrice
0	5.7	1264.6	1164.8	2.0	157.6
1	7.6	1865.6	1476.9	2.4	256.7
2	4.8	1117.7	779.9	0.9	114.8
3	6.4	1767.2	799.4	1.9	182.8

تحلیل:

Purpose: کشف الگوهای پنهان در داده‌ها از طریق گروه‌بندی خودکار خانه‌ها به 4 خوشه بر اساس 5 ویژگی مهم (OverallQual, GrLivArea, TotalBsmtSF, GarageCars, SalePrice)، بدون استفاده از برچسب از پیش تعیین شده.

Main Findings: الگوریتم K-Means با $k=4$ چهار خوشه متمایز شناسایی کرد،

خوشه 2 با میانگین کیفیت 4.8، زیربنای 1118 فوت، زیرزمین 780 فوت، گاراژ 0.9 ماشین و میانگین قیمت \$ 115k خوشه اقتصادی و کوچک است.

خوشه 0 با کیفیت 5.7، زیر بنای 1265 فوت، زیر زمین 1165 فوت، گاراژ 2 ماشین و قیمت 158k \$ خوشه متوسط با زیر زمین خوب است.

خوشه 3 با کیفیت 6.4، زیر بنای 1767 فوت، زیر زمین 799 فوت، گاراژ 1.9 ماشین و قیمت 183k \$ خوشه بزرگ بدون زیر زمین است.

خوشه 1 با کیفیت 7.6، زیر بنای 1866 فوت، زیر زمین 1477 فوت، گاراژ 2.4 ماشین و قیمت 257k \$ خوشه لوکس و بزرگ است.

نمودار Scatter Plot نشان می دهد خوشه ها در فضای زیر بنا و قیمت، به خوبی از هم تفکیک شده اند. Practical Interpretation: مقایسه خوشه های 0 و 3، نتایج جالبی را نشان میدهد،

هر دو زیر بنای شبیه به همی دارند اما خوشه 0 زیر زمین بزرگ تری (1165 فوت) و قیمت پایین تر (158k \$) دارد، در حالی که خوشه 3 زیر زمین کوچک تری (799 فوت) اما قیمت بالاتر (183k \$) دارد. این تفاوت 25k \$ نشان می دهد که خریداران به زیر بنای بالای زمین (فضای زندگی قابل استفاده روزانه) بیشتر از زیر زمین ارزش می دهند،

نتایجی که با نتیجه تحلیل همبستگی ($r=0.68$ GrLivArea: در مقابل $r=0.58$ TotalBsmtSF) نیز همخوانی دارد.

این چهار خوشه می توانند به عنوان بخش بندی بازار (Market Segmentation) برای هدف گذاری برنامه ریزی های بازاریابی و سرمایه گذاری در حوزه مسکن استفاده شوند.

6 نتیجه گیری (Conclusion)

این پژوهش با هدف تحلیل و مصور سازی عوامل موثر بر قیمت فروش مسکن در شهر Ames آمریکا انجام شد.

پس از طی مراحل کامل تحلیل داده از پاکسازی تا مدل سازی، مهم ترین نتایج به شرح زیر است:

1. کیفیت، مهم ترین عامل تعیین کننده قیمت است.

کیفیت کلی خانه (OverallQual) با ضریب همبستگی 0.79 قوی ترین رابطه را با قیمت دارد.

به ازای هر سطح افزایش کیفیت، قیمت به طور میانگین 14800 دلار افزایش می یابد.

میانگین قیمت از 50150 دلار در کیفیت 1 به 310,000 دلار در کیفیت 10 رسیده (6.2 برابر افزایش).

این یافته توسط هر سه مدل آماری (رگرسیون خطی، درخت تصمیم و K-Means) تأیید شد.

2. موقعیت مکانی، تفاوت چشمگیری ایجاد می کند.

اختلاف قیمت بین گران ترین محله (NridgHt با \$ 270k) و ارزان ترین محله (MeadowV با \$ 88k) معادل 3.1 برابر است.

تحلیل Heatmap محله × کیفیت نشان داد که محله می تواند اثر کیفیت را محدود کند، پدیده سقف قیمت محله ای، به گونه ای که در محله های ارزان تر، افزایش کیفیت تا سطح 6 قیمت را از \$ 154k بالاتر نمی برد.

3. مساحت، رابطه مستقیم با قیمت دارد.

زیربنای زندگی (GrLivArea) با همبستگی 0.68 دومین عامل مهم است.

به ازای هر 100 فوت مربع افزایش زیربنا، قیمت به طور میانگین 9,000 دلار افزایش می یابد.

مقایسه خوشه های K-Means نشان داد که خریداران به زیربنای بالای زمین بیشتر از زیرزمین ارزش می دهند.

4. خانه های جدید تر، گران تر هستند.

میانگین قیمت خانه های دهه 2000 (\$ 213k) نسبت به دهه 1870 (\$ 108k) تقریباً دو برابر است.

سال ساخت با ضریب +412\$ به ازای هر سال، تاثیر مثبت پایداری بر قیمت دارد، با این حال، این رابطه خطی نیست و بازسازی های اخیر می توانند ارزش خانه های قدیمی را به طور قابل توجهی افزایش دهند.

5. بازار مسکن، فصلی است.

بیشترین معاملات در ماه های تابستان انجام می شود، ماه 7 سال 2006 با 62 معامله پرتراфик ترین دوره بود.

میانۀ قیمت در ماه 9 (\$ 179k) نسبت به ماه 1 (\$ 143k) تفاوت 25 درصدی دارد که احتمالاً ناشی از ترکیب متفاوت خانه های فروخته شده در هر ماه است.

6. مدل رگرسیون خطی، عملکرد قابل قبولی دارد.

مدل رگرسیون خطی با $R^2=0.783$ توانست 78.3% از تغییرات قیمت را توضیح دهد.

RMSE=\$25,928 در مقیاس بازار مسکن Ames (میانگین \$ 180k) معادل خطای % 14.3 است.

مدل در پیش بینی خانه های لوکس (بالای \$ 200k) عملکرد ضعیف تری دارد که نشان دهنده پیچیدگی بیشتر قیمت گذاری در بخش لوکس بازار است.

7. درخت تصمیم، دسته بندی دقیقی ارائه می دهد.

درخت تصمیم با دقت % 88.4 توانست خانه ها را به دو دسته گران و ارزان تقسیم کند.

مهم ترین معیار تصمیم گیری درخت، کیفیت کلی ($OverallQual \leq 5.5$) است که تایید می کند کیفیت مهم ترین عامل تفاوت و تمایز است.

تعادل خطاها در هر دو دسته نشان دهنده عملکرد یکسان و بدون تعصب مدل است.

8. خوشه بندی، چهار دسته مسکن را شناسایی کرد.

الگوریتم K-Means چهار گروه متمایز شناسایی کرد:

اقتصادی (\$ 115k).

متوسط (\$ 158k).

بزرگ بدون زیرزمین (\$ 183k)

و لوکس (\$ 257k).

این دسته بندی می تواند برای هدف گذاری بازار مسکن، سیاست گذاری مسکن شهری و برنامه ریزی سرمایه گذاری مفید باشد.

جمع بندی نهایی: قیمت مسکن در شهر Ames نتیجه تعامل پیچیده عوامل متعددی است که در

راس آن ها کیفیت ساخت، موقعیت مکانی و مساحت قرار دارند.

هیچ عاملی به تنهایی تعیین کننده نیست، یک خانه با کیفیت بالا در محله نامناسب یا یک زمین بزرگ در موقعیت بد، لزوماً قیمت بالایی ندارند.

این پیچیدگی چندعاملی مشکل اصلی مدل سازی قیمت مسکن است و نشان می دهد که مدل های پیشرفته تر مثل Random Forest یا Gradient Boosting که اثرات تعاملی را بهتر capture می کنند، می توانند دقت پیش بینی را به طور قابل توجهی بهبود بخشند.